T.C.
PAMUKKALE ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ
ELEKTRİK-ELEKTRONİK MÜHENDİSLİĞİ ANABİLİM DALI

BİYOMEDİKAL İŞARETLERİN ZAMAN-FREKANS YÖNTEMLERİ İLE ANALİZİ VE SINIFLANDIRILMASI

DOKTORA TEZİ

ALİ KIRKBAŞ

DENİZLİ, TEMMUZ - 2025

T.C.
PAMUKKALE ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ
ELEKTRİK-ELEKTRONİK MÜHENDİSLİĞİ ANABİLİM DALI

BİYOMEDİKAL İŞARETLERİN ZAMAN-FREKANS YÖNTEMLERİ İLE ANALİZİ VE SINIFLANDIRILMASI

DOKTORA TEZİ

ALİ KIRKBAŞ

DENİZLİ, TEMMUZ - 2025

Bu tezin tasarımı, hazırlanması, yürütülmesi, araştırmalarının yapılması ve bulgularının analizlerinde bilimsel etiğe ve akademik kurallara özenle riayet edildiğini; bu çalışmanın doğrudan birincil ürünü olmayan bulguların, verilerin ve materyallerin bilimsel etiğe uygun olarak kaynak gösterildiğini ve alıntı yapılan çalışmalara atfedildiğine beyan ederim.

ALİ KIRKBAŞ

ÖZET

BİYOMEDİKAL İŞARETLERİN ZAMAN-FREKANS YÖNTEMLERİ İLE ANALİZİ VE SINIFLANDIRILMASI
DOKTORA TEZİ
ALİ KIRKBAŞ
PAMUKKALE ÜNİVERSİTESİ FEN BİLİMLERİ ENSTİTÜSÜ
ELEKTRİK-ELEKTRONİK MÜHENDİSLİĞİ ANABİLİM DALI
(TEZ DANIŞMANI:PROF.DR. AYDIN KIZILKAYA)

DENİZLİ, TEMMUZ - 2025

Yapılan çalışmada az sayıda elektrokardiyogram (EKG) sinyali kullanarak kardiyak aritmilerinin yüksek başarımla sınıflandırılması problemi ele alınmıştır. Bu probleme makul bir çözüm bulmak için, zaman frekans analiz yöntemleri ile Ortak Matris Yaklaşımına (OMY) dayalı sınıflandırıcı modelin birleştirilerek kullanılması önerilmiştir. EKG verilerinin zaman-frekans (Z-F) gösterimlerinin oluşturulmasında Fourier Ayrıştırma Yöntemi (FAY) ile Kısa Zamanlı Fourier Dönüşümü (KZFD) yöntemleri kullanılmıştır. Sınıflandırmada kullanılan öznitelik matrisleri; EKG sinyallerinin zaman bölgesi, frekans bölgesi ve Z-F bölgesi gösterimlerinden oluşturulan veri matrislerine iki-boyutlu temel bileşen analizi uygulanarak elde edilmiştir. Veri matrisleri, iki farklı Z-F gösterim biçimi ile ayrı ayrı oluşturulduğundan dolayı EKG aritmi sınıflandırması amacıyla önerilen yöntemler FAY-OMY ve KZFD-OMY şeklinde iki farklı başlık altında sunulmuştur. Bu yöntemlerin etkinliği, halka açık üç farklı veri tabanı olan MIT-BIH, Chapman ve PTB-XL veri tabanlarından sağlanan EKG işaretleri üzerinde gerçekleştirilen sınıflandırma deneyleriyle gösterilmiştir. MIT-BIH veri tabanı kullanılarak yapılan değerlendirmelerde, hasta-içi ve hastalar-arası sınıflandırma senaryoları altında dört aritmi türüne ilişkin EKG sinyallerinin sınıflandırılmasında FAY-OMY ile sırasıyla %99,87 ve %99,84 genel doğruluk oranlarına ulaşılırken; KZFD-OMY ile bu oranlar sırasıyla %99,97 oranı elde edilmiştir. Her iki yöntem ile V ve S tip aritmilerin teşhisinde beş performans ölçütünde neredeyse %99'u aşan oranlara ulaşılarak güncel çalışmaların çoğundan daha iyi başarım sağlanmıştır. Gürültülü EKG sinyallerinin mevcudiyeti durumunda her iki yöntemin sınıflandırma başarımı test etmek için Chapman veri tabanında alınan gürültülü ve gürültüsüz EKG sinyalleri üzerinde deneyler gerçekleştirilmiştir. Dört aritmi sınıfına ilişkin gürültülü ve gürültüsüz EKG kayıtları ile eğitilen ve test edilen FAY-OMY yöntemi sırasıyla %99,58 ve %99,05 genel sınıflandırma doğruluğuna ulaşılırken; bu oranlar KZFD-OMY ile %99,92 ve %99,90 olarak elde edilmiştir. PTB-XL veri tabanıyla beş farklı aritmi türünde ise FAY-OMY ve KZFD-OMY yöntemleri aritmi sınıflandırmasında sırasıyla %98,49 ve %99,97 genel doğruluk oranlarına ulaşmıştır. Elde edilen sonuçlar, önerilen yöntemlerin veri tabanından bağımsız olarak az sayıda eğitim kümesi ile yüksek sınıflandırma başarımı sağladığını göstermiştir.

ANAHTAR KELİMELER: Elektrokardiyogram**,** Aritmi Sınıflandırma, Ortak Matris Yaklaşımı, Zaman-Frekans Analizi, Fourier Ayrıştırma Yöntemi, Kısa Zamanlı Fourier Dönüşümü, Yapay-Zekâ

ABSTRACT

ANAYLSIS AND CLASSIFICATION OF BIOMEDICAL SIGNALS BY TIME-FREQUENCY METHODS
PH.D THESIS
ALI KIRKBAS

PAMUKKALE UNIVERSITY INSTITUTE OF SCIENCE
ELECTRICAL AND ELECTRONICS ENGINEERING
(SUPERVISOR:PROF. DR. AYDIN KIZILKAYA)

DENİZLİ, JULY 2025

This thesis seeks the classification problem of cardiac arrhythmias with a high accuracy by using a small number of electrocardiogram (ECG) signals. To find a reasonable solution to this problem, we advise using a common matrix approach (CMA)-based classifier model fused with time-frequency analysis methods. Fourier Decomposition Method (FDM) and Short Time Fourier Transform (STFT) methods were used to generate time-frequency (T-F) representations of ECG data. The feature matrices used in classification were obtained by applying two-dimensional principal component analysis to data matrices generated from time domain, frequency domain and T-F domain representations of ECG signals. Since the data matrices are generated separately with two different T-F representations, the proposed methods for ECG arrhythmia classification are introduced under two different topics as FDM-CMA and STFT-CMA. The effectiveness of these methods is evaluated over classification assessments on ECG signals from three different publicly available databases: MIT-BIH, Chapman and PTB-XL. With the experiments conducted using the MIT-BIH database, FDM-CMA achieved 99.87% and 99.84% overall accuracy scores for the classification of ECG signals of four arrhythmia types under intra-patient and inter-patient classification scenarios, while STFT-CMA achieved 99.97% accuracy rates, respectively. With both methods, Classification of the V and S type arrhythmias reach to the rates exceeding almost 99% on the five-performance metrics was observed as a better performance than the most recent methods. To test the classification performance of both methods in the presence of noisy ECG signals, experiments were performed on noisy and noise-free ECG signals from the Chapman database. FDM-CMA method trained and tested with noisy and noise-free ECG recordings related to four arrhythmia classes achieved overall classification accuracies of 99.58% and 99.05%, respectively, while these scores were obtained 99.92% and 99.90% with STFT-CMA. The FDM-CMA and STFT-CMA methods achieved overall accuracy rates of 98.49% and 99.97%, respectively for the five different arrhythmia types taken from PTB-XL database. The obtained results show that the proposed methods resulted in high classification performance with a small number of training sets regardless of the database.

KEYWORDS: Electrocardiogram**,** Arrhythmia Classification, Common Matrix Approach, Time-frequency Analysis, Fourier Decomposition Method, Short Time Fourier Transform, Artifical Intelligence

İÇİNDEKİLER

Sayfa

ÖZET i
ABSTRACT ii
İÇİNDEKİLER iii
ŞEKİL LİSTESİ v
TABLO LİSTESİ vii
KISALTMALAR viii
ÖNSÖZ ix
1. GİRİŞ 1
1.1 Giriş 1
1.2 Literatürdeki Aritmilerin Sınıflandırılması ile İlgili Çalışmalar 2
1.3 Tezin Temel Katkıları 9
2. EKG ve KALP ARİTMİLERİ TANIMI 10
2.1 EKG Morfolojisi 10
2.2 EKG İşaretinin Ölçülmesi 11
2.3 Kalp Aritmi Türleri 15
3. ÇALIŞMADA KULLANILAN EKG VERİ TABANLARI 18
3.1 MIT-BIH Veri Tabanı 18
3.2 Chapman Veri Tabanı 20
3.3 PTB-XL Veri Tabanı 21
4. DEĞERLENDİRME METRİKLERİ 22
4.1 Kesinlik (Precision) 23
4.2 Genel Doğruluk (Overall Accuracy) 24
4.3 Hassasiyet (Sensivity) 24
4.4 F1-Skor 25
4.5 Özgüllük (Specifity) 25
5. ÖZNİTELİK ÇIKARMADA KULLANILAN YÖNTEMLER 26
5.1 Fourier Ayrıştırma Yöntemi (FAY) 26
5.1.1 AFTBF'lerin İleri Yönde Aranması: DYFT Yordamı 28
5.1.2 AFTBF'lerin Geri Yönde Aranması: YDFT Yordamı: 29
5.1.3 AFTBF'lerin YDFT Yordamı Üzerinden HFD ile Hesaplanması 30
5.2 Kısa Zamanlı Fourier Dönüşümü (KZFD) 31
5.3 İki-Boyutlu Temel Bileşen Analizi (2BTBA) 33
6. SINIFLANDIRMA YÖNTEMİ 35
6.1 OMY 35
6.1.1 OMY Eğitim Safhası 36
6.1.2 OMY Test Safhası 38
7. ÖNERİLEN EKG ARİTMİ SINIFLANDIRMA YÖNTEMLERİ ve DEĞERLENDİRMELERİ 40
7.1 FAY-OMY Yaklaşımında Kullanılan Veri Matrisinin Oluşturulması ve Öznitelik Matrisinin Elde Edilmesi 41
7.1.1 MIT-BIH Veri Tabanını Kullanarak Yapılan Performans Değerlendirmeleri: 42
7.1.1.1 Hasta-içi Senaryosu Temelinde EKG Aritmi Sınıflandırma Performansının Değerlendirilmesi: 43

7.1.1.2 Hastalar-Arası Senaryo Altında EKG Aritmi Sınıflandırma Performansının Değerlendirilmesi: 47
7.1.2 Chapman Veri Tabanını Kullanılarak Yapılan Deneylerin Performans Değerlendirmeleri....52
7.1.2.1 Gürültülü EKG Kayıtlarıyla Yapılan Deneyler....52
7.1.2.2 Gürültüsüz EKG Kayıtlarıyla Yapılan Deneyler 54
7.1.3 PTB-XL Veri Tabanıyla Yapılan Deneylerin Performans Değerlendirmeleri 57
7.1.4 FAY-OMY Yöntemi İçin Ablasyon Çalışması 59
7.2 KZFD-OMY Modelinde Kullanılan Veri Matrisinin Oluşturulması ve Öznitelik Matrisinin Elde Edilmesi 61
7.2.1 MIT-BIH Veri Tabanını Kullanarak Yapılan Performans Değerlendirmeleri 63
7.2.2 Chapman Veri Tabanını Kullanılarak Yapılan Deneylerin Performans Değerlendirmeleri....65
7.2.2.1 Gürültülü EKG Kayıtlarıyla Yapılan Deneyler....66
7.2.2.2 Gürültüsüz EKG Kayıtlarıyla Yapılan Deneyler 67
7.2.3 PTB-XL Veri Tabanını Kullanarak Yapılan Deneylerin Performans Değerlendirmeleri....68
7.2.4 KZFD-OMY Yaklaşımın Diğer Yöntemler ile Karşılaştırılması 69
7.2.5 KZFD-OMY Yöntemi ile Gerçekleştirilen Sınıflandırma Sürecinde Harcanan Sürenin Analizi....72
7.2.6 KZFD-OMY Yöntemi İçin Ablasyon Çalışması....73
8. TARTIŞMA 75
9. SONUÇ 77
10. KAYNAKLAR....79
11. ÖZGEÇMİŞ....93

ŞEKİL LİSTESİ

Sayfa

Şekil 2.1: Örnek EKG sinyali (Klabunde 2023). 11
Şekil 2.2: Einthoven üçgenine dayalı EKG işaretinin elde edilmesi. 12
Şekil 2.3: On adet probun vücudun üzerindeki konumları. 14
Şekil 3.1: MIT-BIH veri tabanındaki aritmi türleri ve sayıları. 19
Şekil 3.2: EKG sinyalinin bölütlenmesi. 19
Şekil 4.1: İki sınıftan oluşan karışıklık matrisi örneği. 23
Şekil 4.2: Çoklu sınıftan oluşan karışıklık matrisi örneği. 23
Şekil 5.1: KZFD'nin sistematiği. 33
Şekil 6.1: *i*. sınıf için OMY eğitim modülü. 38
Şekil 6.2: OMY test modülü. 39
Şekil 7.1: Aritmi sınıflandırması için önerilen yaklaşımların genel yapısı. 40
Şekil 7.2: FAY-OMY kapsamında veri matrisi oluşturma modülü. 41
Şekil 7.3: FAY-OMY kapsamında *i*. aritmi sınıfına ilişkin öznitelik matrisinin oluşturulması. 42
Şekil 7.4: FAY-OMY sınıflandırma modelinin hasta-içi sınıflandırma senaryosu altında eğitilmesi ve test edilmesi neticesinde elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrislerine dayalı sonuçlar, b) 62×30 öznitelik matrislerine dayalı sonuçlar. 44
Şekil 7.5: Hasta-içi senaryosu altında MIT-BIH veri tabanından alınan EKG işaretlerinde altı aritmi türünün tespiti için toplam eğitim ve test süreleri: a) 62×20 boyutlu öznitelik matrisi ile elde edilen sonuçlar, b) 62×30 boyutlu öznitelik matrisi ile elde edilen sonuçlar. 45
Şekil 7.6: FAY-OMY sınıflandırma modelinin hastalar-arası sınıflandırma senaryosu altında eğitilmesi ve test edilmesi neticesinde elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrislerine dayalı sonuçlar, b) 62×30 öznitelik matrislerine dayalı sonuçlar. 49
Şekil 7.7: FAY-OMY sınıflandırma modelinin Hastalar-arası senaryosu altında MIT-BIH veri tabanından alınan EKG işaretlerinde altı aritmi türünün tespiti için harcanan toplam eğitim ve test süreleri: a) 62×20 öznitelik matrisi ile elde edilen sonuçlar, b) 62×30 öznitelik matrisi ile elde edilen sonuçlar. 50
Şekil 7.8: Chapman veri tabanındaki ham (gürültülü) EKG kayıtları kullanılarak elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrisleri ile elde edilen sonuçlar, b) 62×30 öznitelik matrisleri ile elde edilen sonuçlar. 53
Şekil 7.9: Chapman veri tabanından alınan gürültüden arındırılmış EKG işaretleri kullanılarak elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrisleriyle elde edilen sonuçlar, b) 62×30 öznitelik matrisleriyle elde edilen sonuçlar. 54
Şekil 7.10: Chapman veri tabanından alınan EKG verileri ile yapılan sınıflandırma işlemi için harcanan toplam eğitim ve test süreleri: a) Gürültü işaretler, b) Gürültüsüz işaretler. 56
Şekil 7.11: FAY-OMY ile PTB-XL veri tabanından alınan EKG işaretlerinin eğitilmesi ve test edilmesiyle elde edilen karışıklık matrisi

sonuçları: a) 62×20'lik öznitelik görüntüleriyle elde edilen sonuçlar, b) 62×30'luk öznitelik görüntüleriyle elde edilen sonuçlar. 58
Şekil 7.12: FAY-OMY ile PTB-XL veri tabanından alınan tabanından alınan gürültülü ve gürültüsüz EKG verileri ile yapılan sınıflandırma işlemi için harcanan toplam eğitim ve test süreleri.....59
Şekil 7.13: KZFD-OMY yaklaşımında kullanılan öznitelik matrisi elde etme sürecinin blok şeması. 62
Şekil 7.14: KZFD-OMY sınıflandırma modelinin hastalar-arası sınıflandırma senaryosu altında eğitilmesi ve test edilmesi neticesinde elde edilen karışıklık matrisi. 64
Şekil 7.15: Chapman veri tabanındaki gürültülü EKG işaretleri ile gerçekleştirilen sınıflandırma deneyleri sonrası elde edilen sonuçlar.....66
Şekil 7.16: Chapman veri tabanındaki gürültüsüz EKG işaretleri ile gerçekleştirilen sınıflandırma deneyleri sonrası elde edilen sonuçlar.....67
Şekil 7.17: PTB-XL veri tabanından sağlanan EKG işaretleri kullanılarak gerçekleştirilen sınıflandırma sürecine ilişkin karışıklık matrisi. 69
Şekil 7.18: Veri matrisini oluşturan matrislerin sınıflandırmaya etkisi. 74

TABLO LİSTESİ

Sayfa

Tablo 1.1: Geleneksel makine öğrenimi ile otomatik aritmi sınıflandırma yöntemlerinin karşılaştırılması 3
Tablo 1.2: Derin öğrenme yöntemlerini kullanan otomatik aritmi sınıflandırma yöntemlerinin karşılaştırılması....7
Tablo 2.1: 12 EKG Derivasyonun hesaplanmasında kullanılan eşitlikler 14
Tablo 3.1: MIT-BIH veri tabanında bulunan aritmi türleri ve etiketleri....20
Tablo 3.2: Chapman veri tabanında bulunan aritmi türleri ve etiketleri....21
Tablo 3.3: PTB-XL veri tabanında bulunan aritmi türleri ve etiketleri 21
Tablo 7.1: Hasta-içi senaryosu altında FAY-OMY yönteminin sınıflandırma başarımına ilişkin performans metrikleri. 43
Tablo 7.2: FAY-OMY yaklaşımının hasta-içi senaryosu altında MIT-BIH veri tabanını kullanan güncel EKG sınıflandırma yöntemleri ile karşılaştırılması. 46
Tablo 7.3: Hastalar-arası paradigma çerçevesinde eğitim ve test kümelerini oluşturan EKG işaret sayısı ve kayıt numaraları....48
Tablo 7.4: Hastalar-arası senaryosunda önerilen yöntemin tek koşturmasıyla elde edilen performans metrikleri. 49
Tablo 7.5: FAY-OMY yaklaşımının hastalar-arası senaryosu altında MIT-BIH veri tabanını kullanan güncel EKG sınıflandırma yöntemleri ile karşılaştırılması 51
Tablo 7.6: Chapman veri tabanından sağlanan gürültülü (ham) EKG işaretlerinin sınıflandırılmasına ilişkin performans metrikleri....53
Tablo 7.7: Chapman veri tabanından alınan gürültüsüz işaretlerin sınıflandırılması ile ilgili performans metrikleri 55
Tablo 7.8: Chapman veri tabanından alınan EKG işaretlerini kullanan sınıflandırma yöntemleri ile FAY-OMY yönteminin karşılaştırması. 57
Tablo 7.9: PTB-XL veri tabanından alınan gürültülü işaretlerin sınıflandırılmasına ilişkin performans metrikleri....58
Tablo 7.10: MIT-BIH, Chapman ve PTB-XL veri tabanlarından temin edilen EKG kayıtları ile yapılan ablasyon çalışmaları 60
Tablo 7.11: Hastalar-arası paradigma temelinde sınıflandırma başarımı için MIT-BIH veri tabanında kullanılan veri kümeleri 63
Tablo 7.12: MIT-BIH veri tabanı hastalar-arası senaryosu altında KZFD-OMY yöntemi ile elde edilen sınıflandırma sonuçlarına karşı düşen karışıklık matrisinden hesaplanan performans metrikleri....64
Tablo 7.13:Chapman veri tabanındaki gürültülü ve gürültüsüz EKG kayıtlarını kullanarak gerçekleştirilen sınıflandırmaya ilişkin performans metrikleri....66
Tablo 7.14: PTB-XL veri tabanından sağlanan EKG işaretleri ile gerçekleştirilen sınıflandırma sürecine ilişkin performans metrikleri. 68
Tablo 7.15: KZFD-OMY yönteminin başarımının genel karşılaştırılması....70
Tablo 7.16: KZFD-OMY yöntemi ile gerçekleştirilen sınıflandırma süreçlerinde harcanan süreler 73

KISALTMALAR

OMY : Ortak Matris Yaklaşımı
FAY : Fourier Ayrıştırma Yöntemi
KZFD : Kısa Zamanlı Fourier Dönüşümü
EKG : Elektrokardiyogram
2BTBA : İki-Boyutlu Temel Bileşen Analizi
HFD : Hızlı Fourier Dönüşümü
AAMI : Tıbbi Cihaz Geliştirme Derneği
AFTBF : Analitik Fourier Temel Bant Fonksiyonu
FTBF : Fourier Temel Bant Fonksiyonları
AFD : Ayrık Fourier Dönüşümü
TAFD : Ters Ayrık Fourier Dönüşümü
DYFT : Düşükten Yükseğe Frekans Taraması
YDFT : Yüksekten Düşüğe Frekans Taraması
KVH : Kardiyovasküler hastalıklar
S-A : Sino-Atriyal düğüm
AFIB : Atriyal fibrilasyon
AF : Atriyal Flutter
AVR : Atriyoventriküler Bağlantı Ritmi
SVT : Supraventriküler Taşikardi
VF : Ventriküller Fibrilasyon
VT : Ventriküller Taşikardi
PVC : Erken Ventriküller Kasılma
R : Sağ Dal Vuru Bloğu
L : Sol Dal Vuru Bloğu
F : Füzyon atım
KM : Karışıklık Matrisi
TD : Toplam doğruluk
PRE : Kesinlik
SEN : Hassasiyet
SPE : Özgüllük
DP : Doğru Pozitif
DN : Doğru Negatif
YP : Yanlış Pozitif
YN : Yanlış Negatif
GSO : Gram-Schmidt dikleştirmesi

ÖNSÖZ

Araştırmalarımın ve akademik gelişimimin şekillenmesinde sınırsız rehberliği, uzmanlığı, coşkusu ve teşviki ile büyük katkıları olan değerli danışmanım Prof. Dr. Aydın KIZILKAYA minnettarım.

Ayrıca sınav komitemde bulanan Prof. Dr. Kadir Kavaklıoğlu, Prof. Dr. Ender Mete EKŞİOĞLU, Doç. Dr. Meriç Çetin, Dr. Öğr. Üyesi Osman Safa Çifçi'ye değerleri görüşleri, yapıcı eleştirileri ve çalışmamım kalitesinin artırılması konusundaki sarsılmaz kararlılıkları için içten teşekkürlerimi sunarım.

Doktora çalışmam boyunca sarsılmaz sevgileri ve destekleri ile bana güç veren eşim Ayşe Gül, oğlum Cengiz Aydın ve kızım Azra'ya en içten şükranlarımı sunuyorum.

Son olarak maddi manevi desteklerini eksik etmeyen Prof. Dr. Selami KESLER, Prof. Dr. Selim KÖROĞLU, Dr. Öğr. Üye. Mustafa TÜMBEK, Dr. Öğr. Üye. Akif DEMİRÇALI ve Dr. Öğr. Üye. Hatice Hilal Ezercan KAYIR'a teşekkür ederim.

1. GİRİŞ

1.1 Giriş

Kardiyovasküler hastalıkların ortaya çıkışı ve yaygınlığı son yıllarda artış göstermiştir. Dünya Sağlık Örgütü'nün raporuna göre, 2019 yılında kardiyovasküler hastalıklara bağlı genel ölüm oranı tahmini 18,8 milyon olarak gerçekleşmiştir (Score ve diğ. 2021). Modern dünyada kardiyovasküler hastalıklara bağlı ölüm oranlarındaki bu artış, pıhtı atması, şişmanlık, diyabet, sigara kullanımı ve yaşam tarzı değişikliklerine bağlı olarak artan hasta sayısına bağlanmaktadır. Kardiyovasküler hastalıkların komplikasyonlarından biri de kalp ritim bozukluklarına bağlı olarak ortaya çıkan kalbin üst ve alt odacıklarına bağlı aritmilerdir. Aritmi ifadesi kalbin atış hızında veya ritminde meydana gelen düzensizlik olarak tanımlanabilir. Normalde kalp, düzenli bir sinüs ritmiyle atar ve bu ritim kalbin elektriksel sistemi tarafından kontrol edilir. Kalbin elektriksel aktivitesinin anormal olduğu birtakım bütünsel karışık olaylar için aritmi tanımı yapılabilir. Aritmiye neden olan pek çok unsur vardır. Bu unsurlar arasında en önemlileri genetik faktörler, elektrolit dengesizlikleri, hormonsal değişiklikler, stres, yüksek tansiyon ve kalp/damar hastalıklarıdır. Kalp aritmilerinin bazıları yaşamı tehdit eden acil tıbbi vakalar olup tıbbi müdahale gerektirebilir (Huikuri ve diğ. 2001).

Elektrokardiyogram (EKG), kalp durumunun izlenmesinde ve hastalıklarının tanısında kullanılan önemli araçlardan biridir. EKG işaretlerinin doğru ve hızlı bir şekilde yorumlanması; kalp krizleri, ritim bozuklukları ve diğer kalp hastalıklarının erken aşamada tespit edilmesine olanak tanır. Böylece, hastalar daha hızlı bir şekilde uygun tedaviye yönlendirilir ve olası komplikasyonların önüne geçilir. Alınacak basit önlemler ile hastanın hayata tutunması ya da konforu artırılır. Son zamanların popüler konusu olan örüntü tanıma ve makine öğrenmesi algoritmalarının medikal alanda kullanılması, doktorların teşhis süreçlerinde daha güvenilir ve kesin sonuçlar elde etmelerini kolaylaştırmaktadır. Özellikle büyük veri kümeleri üzerinde eğitilen makine öğrenmesi yöntemleri, klinisyenlerin gözden kaçırabileceği ince detayları bile fark

edebilmektedir. O nedenle makine tarafından gerçekleştirilen aritmi teşhisindeki başarım, EKG sinyallerinin işlenmesine veya EKG sinyallerindeki saklı özniteliklerin ortaya çıkarılmasını gerektirir. Son yıllarda bu alanda yapılan nitelikli çalışmaların sayıları artmakta birlikte yeni yöntemler önerilmeye devam etmektedir.

Makine öğrenmesi, çeşitli verilerdeki belirli yapıların veya özelliklerin otomatik olarak tanımlanmasını veya sınıflandırılmasını kapsayan bir yapay zekâ alanıdır. Bu süreç, bilgisayarlara görüntülerde, seslerde, metinlerde ve diğer veri türlerinde yer alan karmaşık örüntüleri tanıma yeteneği kazandırmayı amaçlar. Makine tanıma teknolojisi son yıllarda güçlü donanımlara erişimin artmasıyla, yüz tanıma, parmak izi analizi, sesli komut tanıma ve medikal işaret tanıma gibi birçok cihazda kullanılmaktadır. Bu alandaki yeni gelişmeler, sağlık, güvenlik, finans ve eğlence gibi birçok sektörde önemli yeniliklere kapı aralamakta olup makine öğrenme yöntemlerinin daha geniş bir yelpazede kullanılmasını sağlamaktadır.

1.2 Literatürdeki Aritmilerin Sınıflandırılması ile İlgili Çalışmalar

Gerçek zamanlı toplanan ya da kaydedilmiş EKG sinyallerinin analizinde ve değerlendirilmesinde genellikle uzman bilgisine ihtiyaç vardır. Fakat, uzun vadeli etkilerin sonucu olarak ortaya çıkan kardiyak aritmilerinin gözetime takılması güç olabilmektedir. Bu nedenle, aritminin türünü ve yerini belirlemek için uzmanlar tarafından olay bazında yapılan inceleme, zaman alıcı olup yanlış bir tanıya yol açabilir. Bu nedenle, EKG sinyallerinden kardiyak aritmilerin otomatik sınıflandırması, hastalardaki şikayetlerin teşhisiyle tedavisine yardımcı olacak ve tıbbi müdahaleleri kolaylaştıracaktır (Xu ve diğ. 2019). Fakat, ham EKG işaretleri genellikle karmaşık, çok boyutlu ya da gürültülü oldukları için analizleri güç olabilmektedir. O nedenle EKG sinyallerinin son aşaması olan sınıflandırma işleminden önce gürültü giderme, bölütleme ve öznitelik çıkarma gibi bir takım ön işlemlere tabi tutulması gerekebilmektedir (Wasimuddin ve diğ. 2020). Sınıflandırma başarımını doğrudan etkileyen öznitelik çıkarma işlemi, doğrudan EKG verileri üzerinden veya EKG'lerin dönüştürülmüş sürümleri üzerinden zaman ortamında ya da frekans alanında gerçekleştirilir. Son yıllarda yapılan çalışmalarda EKG sinyallerinden dönüştürülmüş frekans veya zaman-frekans (Z-F) tabanlı ayrıntıların aritmi

sınıflandırmasına daha fazla katkı sağladığı bildirilmiştir (Arora ve Mishra 2021). Çünkü EKG'lerin Z-F gösterimleri, dinamik değişimler ve ayırt edici bilgileri daha iyi yansıttığı için aritmi sınıflandırma yöntemlerinde kullanıldığında daha yüksek doğruluk sağladığı tespit edilmiştir (Yang ve Yan 2021; Tripathi ve diğ. 2022; Bechinia ve diğ. 2024). O nedenle yeni geliştirilen Z-F yöntemleri ile bu yöntemlerin birlikte kullanılabileceği öğrenme modeli topolojileri aritmi alanında çalışan araştırmacıların ilgisini yoğun biçimde çekmeye devam etmektedir (Peng ve diğ. 2024).

EKG sinyallerinin sınıflandırılmasında kullanılan güncelliğini yitirmeyen yöntemler, temel olarak makine öğrenmesi ve derin öğrenme yöntemleri olmak üzere iki kategoride toplanır (Serhii ve diğ 2025). Destek Vektör Makineleri (DVM), K-En Yakın Komşuluk (KNN), Rastgele Orman (RF) ve Karar Ağaçları (DT), EKG verilerinden elle çıkarılan veya mühendislik ürünü olan öznitelik kümeleri ile çalışan makine öğrenme modellerinin en belirgin örnekleri olup; EKG sinyallerinin sınıflandırılmasında düşük kaynak gereksinimleriyle hızlı prototiplemeye olanak tanımaktadır. Bu yöntemler, doğru özniteliklerin tercih edildiği senaryolarda halen etkili çözümler üretmektedir. Bu nedenlerden dolayı geleneksel makine öğrenmesine dayalı birçok aritmi sınıflandırma çalışması gerçekleştirilmiştir. Yapılan çalışmalar arasından otomatik sınıflandırma yaklaşımı sunan temel çalışmalar, kullanılan öznitelik türü ve sınıflandırıcıya göre Tablo 1.1 ile özetlenmiştir.

Tablo 1.1: Geleneksel makine öğrenimi ile otomatik aritmi sınıflandırma yöntemlerinin karşılaştırılması

Referans Çalışma	Öznitelik Yöntemi	Sınıflandırıcı	Doğruluk (%)	Sınıf Sayısı
Kampouraki ve diğ. (2008)	Kalp hızı verileri	DVM	100	2
Martis ve diğ. (2012)	QRS kompleks + TBA	LS-DVM	98,11	5
Ince ve diğ. (2009)	Ayrık Dalgacık Dönüşümü + Temel bileşen Analizi	DVM	95,58	5
Raj ve diğ. (2016)	Ayrık Stockwell Dönüşümü	PSO-DVM	99,81	16
Martis ve diğ. (2013)	Dalgacık Dönüşümü + Bağımsız Bileşen Analizi	DVM	98,36	5
Bong ve diğ. (2012)	Kalp hızı verileri	KNN	77,69	2
Yusuf ve diğ. (2019)	Melkepstrum katsayıları	KNN	84	2
Venkatesan ve diğ. (2018)	Kalp hızı verileri	KNN	97,5	2
Arif (2010)	Dalgacık Dönüşümü + Temel bileşen Analizi	Fuzzy KNN	97,35	6
Zhang ve diğ. (2010)	Ayrık Dalgacık Dönüşümü + Temel bileşen Analizi	DT	96,31	6
Mert ve diğ. (2012)	Zaman öznitelikleri	DT	99,34	6
Li ve Zhou (2016)	Dalgacık entropi + RR aralığı	RF	94,61	5
Alarsan ve Younes (2019)	Morfolojik Öznitelikler	RF	98,03	4
Golgowski and Osowski (2020)	Ayrık Dalgacık Dönüşümü	Extra RF	97,78	3

Tabloya göre geleneksel makine öğrenimi ile yapılan çalışmalarda tatmin edici sınıflandırma sonuçları elde edilmiştir. Fakat yayınlarda kullanılan öznitelikler problem tabanlı tercih edilmiştir. Bu durum, uygun özniteliklerin uygulamanın yanı sıra sonucu etkileyebilecek diğer faktörlere bağlı olarak dikkatlice seçilmesi gerektiğini göstermektedir. Daha yüksek miktarda veri içeren öznitelik kombinasyonları, doğru sınıflandırma için daha zor olan karmaşık örüntüler oluşturacaktır. Ayrıca, geleneksel makine öğrenmesi yöntemleri genellikle çok kanallı EKG sinyalleri arasından yalnızca tek bir kanaldan elde edilen verileri kullanması, bu yöntemlerin karmaşık aritmi sınıflandırma görevlerinde yetersiz kalmasına neden olabilmektedir. Araştırmacılar bu dezavantajları aşabilmek için büyük veri kümelerini işleyerek otonom öznitelik çıkarma ve sınıflandırma gerçekleştirebilmeyi vaat eden derin öğrenme tabanlı topolojiler geliştirmişlerdir. Z-F temsillerini kullanan derin öğrenme tabanlı çalışmaların özeti Tablo 1.2 ile verilmiştir.

Bir grup bilim adamı, EKG sinyallerinin sınıflandırılmasına yönelik olarak, kalp atımlarından kısa zamanlı Fourier dönüşümü aracılığıyla elde edilen Z-F temsillerini girdi olarak kullanan çeşitli iki-boyutlu evrişimli sinir ağı mimarileri önermişlerdir (Xie ve diğ. 2019; Huang ve diğ. 2019; Ullah ve diğ. 2020; Jeong ve Lim 2021). Başka bir grup çalışma ise, kalp atımı sinyallerinin sürekli dalgacık dönüşümü aracılığıyla elde edilen skalogram temsillerinin, evrişimli sinir ağları modellerine girdi olarak kullanıldığı bir sınıflandırma yaklaşımını önermektedir (Oliveira ve Nobrega 2019; Lai ve diğ. 2021; Mohonta ve diğ. 2022; Ozaltin ve Yeniay 2023). Yapılan başka bir çalışmada EKG sinyallerinin modifiye edilmiş frekans dilimi dalgacık dönüşümünden elde edilen Z-F görüntüleri derin sinir ağları ile sınıflandırılmıştır (Luo ve diğ. 2017). Allam ve diğ. (2020) beş farklı aritmiden oluşan sınıflandırma problemini, Stockwell dönüşümünden gelen Z-F görüntülerinin Türkçe karşılığı artık ağ (ResNet) olan derin öğrenme modeli eşliğinde çözmeye çalışmışlardır. EKG sinyallerinin sınıflandırması üzerine yapılan bir başka çalışmada atriyal fibrilasyon (AFIB) patolojisinin otomatik tespiti için çift yönlü uzun kısa vade hafıza ağlarını önermiştir (Radhakrishnan ve diğ. 2021). Önerilen derin öğrenme tabanlı yaklaşımda EKG sinyallerinin chirplet dönüşümünden elde edilen Z-F görüntüleri çift yönlü uzun kısa vade hafıza ağlarına girdi olarak uygulanmıştır (Radhakrishnan ve diğ. 2021). AFIB tespiti için önerilen bir başka EKG sınıflandırma yaklaşımında EKG bölütlerinin Kalman tabanlı izgesel-zamansal tahminlerinin

ortalamasını işleyen bir derin evrişimli sinir ağı modeli kullanılmıştır (Zhao ve diğ. 2020). Mjahad ve arkadaşları (2017), ventriküler aritmilerin tespiti amacıyla, sözde Wigner-Ville dağılımı kullanılarak elde edilen Z-F temsillerini makine öğrenimi tabanlı sınıflandırıcılarla besleyen bir yaklaşım önermiştir. Yakın tarihli yapılan bir başka çalışmada, beş aritmi türünden oluşan sınıflandırma probleminin çözümünde çok başlı dikkat mekanizması sınıflandırıcısı ile zaman atamalı eşzamanlı sıkıştırma dönüşümüyle elde edilen Z-F haritalarından yararlanılmıştır (Bing ve diğ. 2022). EKG sinyallerinden türetilen farklı Z-F haritalarının sınıflandırma başarımına katkısını araştırmak için de çeşitli çalışmalar yayınlanmıştır. Bu doğrultuda Wu ve diğ. (2019) tarafından yapılan çalışmada, on iki sınıflı EKG ritimlerini ayırt etmek üç çeşit Z-F analiz yöntemi (KZFD, sürekli dalgacı dönüşümü ve sözde Wigner-Wille dağılımı) kullanarak elde edilen Z-F haritaları sabit evrişimli sinir ağı modeline uygulanmıştır (Wu ve diğ. 2019). Benzer şekilde, Xia ve diğ. (2018) tarafından EKG bölütlerinin KZFD ve durağan dalgacık dönüşümü temsilleri, iki farklı evrişimli sinir ağı modelinde AFIB ataklarının tespitinde kullanılmıştır. Yukarıda sunulan çalışmalardan farklı olarak, bazı araştırmacılar aritmi tanılama ve sınıflandırma süreçlerinde derin öğrenme mimarilerini sıfırdan oluşturmak yerine, daha önce büyük ölçekli veri kümeleri üzerinde eğitilmiş modellerden yararlanmayı tercih etmişlerdir. Bu doğrultuda, Cinar ve Tuncer (2021) EKG sinyallerinden anormal aritmi, normal sinüs ritmi ve ödemli kalp yetmezliği aritmilerini sınıflandırmada AlexNet modeli ile DVM'den oluşan hibrit bir yapı kullanılmasını önermiştir. Bu amaçla, AlexNet girişleri KZFD'den elde edilen spektrogramlar uygulanarak öznitelik matrislerine dönüştürülmüştür. Daha sonra bu öznitelik matrisleri DVM algoritmasında kullanarak sınıflandırılmıştır (Cinar ve Tuncer 2021). Benzer bir çalışmada dört aritmi türünün sınıflandırılması için EKG verilerinin spektrogram görüntülerini işlemek üzere DenseNet-DVM yapısı önerilmiştir (Salem ve diğ. 2018). Aynı şekilde on beş kardiyak aritmi türünün teşhisi için uzun süreli EKG verilerinin KZFD'sini kullanarak önceden eğitilmiş altı evrişimli sinir ağı tabanlı sınıflandırıcının verimliliği üzerine bir karşılaştırma çalışması yayınlanmıştır (Toma ve diğ. 2022). Kardiyak aritmileri tespit etmek ve sınıflandırmak için EKG kayıtlarının Z-F spektrogramlarını kullanan önceden eğitilmiş evrişimli sinir ağına dayanan başka bir yöntem, Tripathi ve diğ. (2022) tarafından yakın tarihli bir makalede önerilmiştir. İlgili makalede EKG kayıtlarının Z-F spektrogramlarını elde etmek için süperlet dönüşümü kullanılmış ve ventriküller fibrilasyon (VF), AFIB ve sağlıklı bir kalp işaretleri olmak üzere üç

sınıftan oluşan aritmi problemine çözüm aramışlardır. Eltrass ve diğ. (2021) EKG verilerinin sabit durağan olmayan Gabor dönüşümünden elde edilen Z-F görüntülerini, önceden eğitilmiş AlexNet modeline uygulayarak önerdikleri yöntem ile ödemli kalp yetmezliği, aritmi ve normal sinüs ritmi olmak üzere üç tür kalp rahatsızlığını sınıflandırmayı amaçlamışlardır. Ayrıca, Zhang ve diğ. (2021) ResNet-101 modelini kullanan transfer öğrenmesine dayalı olarak önerdikleri yöntemde EKG kayıtlarının Z-F haritalarını üretmede Hilbert dönüşümü ve Wigner Vielle dağılımını kullanmışlardır. Elde edilen Z-F haritaları daha sonra toplam on dokuz kalp atışı kategorisine göre sınıflandırılmak üzere öğrenme modeline uygulanmıştır. Al Rahhal ve diğ. (2018) ve Rashed-Al-Mahfuz (2021) EKG kalp aritmilerinin sınıflandırması için süreli dalgacık dönüşümünden elde edilen Z-F harita girdileri kullanan önceden eğitilmiş VGGNet tabanlı sinir ağı modeli önermiştir. Alqudah ve diğ. (2022) altı farklı aritmi türünün sınıflandırılmasında önceden eğitilmiş evrişimli sinir ağı mimarisinin performansı üzerine bir karşılaştırma çalışması sunmuşlardır. Yapılan çalışmada, derin öğrenme modelleri sırası ile ikili-spektrum, üçüncü dereceden kümülant, log-ölçekli KZFD öel-ölçekli KZFD'nin ürettiği Z-F gösterimleri ile beslenmiştir.

Yukarıda bahsedilen çalışmalarda, derin öğrenme mimarileriyle birleştirilmiş Z-F temsillerinin, elle öznitelik çıkarma işlemine gerek kalmadan kalp aritmi sınıflandırmasında tatmin edici bir başarıma ulaşmıştır. Bu çalışmalar aritmi sınıflandırması için otomatik yaklaşımlar veya sistemler olarak duyurulmuş olsa da Z-F temsillerinin elde edilmesinin yanı sıra derin öğrenme mimarilerinin tasarımıyla da ilgilendikleri için problem tabanlıdırlar. Her iki açıdan da kullanıcı tanımlı parametrelere ihtiyaç duymaktadır. Örneğin, EKG sinyallerinin Z-F gösterimleri için kullanılan KZFD, durağan dalgacık ve sözde Wigner-Vielle dağılımı teknikleri pencere fonksiyonlarının seçimine ve uygulanmasına bağlıdır (Wu ve diğ. 2019). Benzer şekilde, chirplet dönüşümü ve Stockwell dönüşümünde kullanılan Gauss pencere parametrelerinin önceden belirlenmesini gerekir (Beuter ve Oleskovicz 2020; Radhakrishnan ve diğ. 2021). Ayrıca, süperlet dönüşümünde dalgacık fonksiyonlarının sayısı, döngü sayıları ve standart sapma değeri gibi bazı tasarım parametrelerinin belirlenmesine bağımlıdır (Tripathi ve diğ. 2022).

Tablo 1.2: Derin öğrenme yöntemlerini kullanan otomatik aritmi sınıflandırma yöntemlerinin karşılaştırılması

Referans Çalışma	Öznitelik Yöntemi	Sınıflandırıcı	Doğruluk	Sınıf Sayısı
Xie ve diğ. (2019)	KZFD Z-F haritası	2B ESA	%99,20	2
Huang ve diğ. (2019)	KZFD Z-F haritası	2B ESA	%99,00	5
Ullah ve diğ. (2020)	KZFD Z-F haritası	2B ESA	%99,11	8
Jeong ve Lim (2021)	KZFD Z-F haritası	2B ESA	%78,49	9
Oliveira ve Nobrega (2019)	Sürekli Dalgacık Dönüşümü	2B ESA	%95,30	5
Lai ve diğ. (2021)	Sürekli Dalgacık Dönüşümü	2B ESA	%99,24	-
Mohonta ve diğ. (2022)	Sürekli Dalgacık Dönüşümü	2B ESA	%99,65	5
Ozaltin ve Yeniay (2023)	Sürekli Dalgacık Dönüşümü (Skalogram)	2B ESA	%98,00	3
		ESA-SVM	%99,21	3
Luo ve diğ. (2017)	Modifiye Frekans Dilimi Dalgacık Dönüşümü	2B ESA	%97,5	4
Allam ve diğ. (2020)	Stockwell Dönüşümü	ResNet	%99,73	5
Radhakrishnan ve diğ. (2021)	Chirplet Dönüşümü	BİLSTM	%99,18	2
Zhao ve diğ. (2020)	Kalman Tabanlı İzge	2B ESA	%82,70	4
Mjahad ve diğ. (2017)	Sözde Wigner-Ville Dağılımı	Doğrusal Sınıflandırıcılar	%98,96	4
Bing ve diğ. (2022)	Zaman Atamalı Eşzamanlı Sıkıştırma dönüşümü (TSST)	Transformer (ConVit)	%99,50	5
Wu ve diğ. (2019)	KZFD, SDD ve SWVD	2B ESA	%96,65	12
Xia ve diğ. (2018)	KZFD, DDD	2B ESA	%98,63	2
Cinar ve Tuncer (2021)	KZFD + AlexNEt	SVM	%96,77	3
Salem ve diğ. (2018)	Spektogram	DenseNet-SVM	%97,23	4
Toma ve diğ. (2022)	KZFD	2B ESA	%93,70	15
Tripathi ve diğ. (2022)	Süperlet Dönüşümü	2B ESA	%97,10	3
Eltrass ve diğ. (2021)	Gabor Z-F	AlexNet	%98,82	4
Zhang ve diğ. (2021)	Wigner Ville Dönüşümü + Hilbert Dönüşümü	ResNet+ Transfer Öğrenme	%99,62	5
Al Rahhal ve diğ. (2018)	Sürekli Dalgacık Dönüşümü	ImageNet	%99,90	2
Rashed-Al-Mahfuz (2021)	Sürekli Dalgacık Dönüşümü	VGG16-Net	%99,90	5

Z-F analiz yöntemlerinde olduğu gibi, EKG verilerinin Z-F görüntülerini sınıflandırma görevleri için kullanan derin öğrenme modellerinin tasarımı da probleme

dayalı ve kullanıcı tanımlıdır. Derin öğrenme mimarilerinin tasarımı hiper-parametrelerin (gizli katman sayısı, gizli katman başına düşen düğüm sayısı, öğrenme oranı, yığın boyutu, epoklar, düzenlileştirme parametreleri, momentum parametresi, vb.) seçimine bağlı olup problem bazlı ayarlanması gerekir. Yukarıdaki değerlendirmelere dayanarak, akıllı öğrenme modelleriyle entegre edilmiş Z-F gösterimleri ile EKG aritmilerinin sınıflandırması için yeni bir yöntemin benimsenmesi gerektiği ortaya çıkmaktadır. Yeni yöntem uygulanması kolay ve kullanıcı parametre ayarlarından olabildiğince bağımsız olmalıdır. Bu amaçla, mevcut çalışmada Ortak Matris Yaklaşımına dayalı sınıflandırıcı modelini kullanan iki farklı aritmi sınıflandırma yaklaşımı önerisinde bulunulmuştur. Yöntemlerden ilki Fourier ayrıştırma yöntemi (FAY) ile üretilen Z-F gösterimlerini kullanarak oluşturulan veri matrisinden türetilen öznitelik matrisini Ortak Matris Yaklaşımı (OMY) tabanlı sınıflandırıcı modele girdi olarak kullanan sınıflandırma yaklaşımıdır. FAY, doğrusal ve durağan olmayan zaman serilerine uygulanabilen veri odaklı uyarlanabilir bir sinyal ayrıştırma aracıdır (Singh ve diğ. 2017). Bir sinyalin hem analitik gösterimini hem de Hilbert dönüşümünü sunma özelliğinden dolayı FAY, çeşitli sinyallerin Z-F analizi için de uygun bir araçtır (Singh ve diğ. 2017; Singh ve diğ. 2018; Bajestaeni ve diğ. 2019; Jafari 2021;). EKG sinyallerinin Z-F haritalarını üretmek için titiz bir matematiksel temele sahip olduğu ve parametre ayarı gerektirmediği için FAY'nin kullanılması tercih edilmiştir. FAY uygularken, yakın zamanda geliştirilen hızlı sürümünden yararlanılarak hesap süresi kısaltılmıştır (Kizilkaya ve Elbi 2023). Önerilen ikinci yaklaşımda, gerçek zamanlı uygulanabilirlik göz önünde bulundurularak OMY tabanlı sınıflandırıcı modeline girdi oluşturan öznitelik matrislerinin türetildiği veri matrisinin oluşturulmasında KZFD ile elde edilen Z-F gösterimlerinden faydalanılmıştır. Önerilen her iki yaklaşımda da öznitelik görüntüsü elde etmek için veri matrisi kümesine iki boyutlu temel bileşen analizi (2BTBA) uygulanarak zaman eksenindeki boyut indirgenmiştir (Yang ve diğ. 2004). Veri matrisi, EKG'nin kendisi, Fourier Dönüşümünün mutlak değeri ve Z-F temsilinden gelen matrisin birleştirilmesiyle elde edilmiştir. Birleştirme yapılmadan önce tüm veriler bireysel olarak normalize edilmiştir. Tez kapsamında yeni bir öneri olan veri matrisi bileşen unsurlarının başarıma olan etkileri araştırılmıştır. OMY, Turhal ve diğ. (2005) tarafından yüz tanıma uygulamaları için keşfedilmiş alt uzay tabanlı bir görüntü sınıflandırma yöntemidir. OMY'nin en büyük üstünlüğü, kullanıcı tanımlı ayar parametresi gerektirmemesi ve az miktarda veri ile yüksek sınıflandırma performansı

sağlamasıdır. OMY'nin çalışma mantığı eğitim aşamasında, her bir aritmi sınıfındaki öznitelik görüntülerinin ortak özelliklerini sembolize eden ortak bir matris elde etmesine dayanır. Elde edilen ortak matrisler test aşamasında deneğin bilinmeyen sınıfa atama kriterinde kullanılır. OMY'nin hesaplanması hakkında çok sayıda çalışma mevcuttur (Turhal ve diğ. 2005; Ergin ve diğ. 2015[a]; Ergin ve diğ. 2015[b]). Yapılan çalışmada Ergin ve diğ. (2015[a]) makalesinde verilen yönergeler izlenerek Gram-Schmidt dikleştirmesine (GSO) dayalı OMY hesabı gerçeklenmiştir.

1.3 Tezin Temel Katkıları

Yapılan tez çalışmasının temel katkıları ve yenilikleri aşağıdaki şekilde özetlenmiştir:

- EKG aritmilerini otomatik ve yüksek başarımla sınıflandırmak için FAY ya da KZFD ile birleştirilmiş OMY tabanlı bir sınıflandırıcı yaklaşım önerilmiştir.
- Veri matrisinde kullanılan Z-F temsilleri, tamamen uyarlanabilir veri güdümlü bir sinyal ayrıştırma yöntemi olan FAY ve süre anlamında verimli çalışan KZFD ile elde edilmiştir.
- Sınıflandırma işlemi öznitelik matrisleri kullanılarak gerçekleştirilmiştir. Baskın olarak Z-F gösteriminden oluşan veri matrisleri, 2BTBA uygulanarak boyutu azaltılmış öznitelik matrislerine dönüştürülmüştür.
- Ablasyon çalışmasında, veri matrisini oluşturan yapıların sınıflandırma performansına etkileri araştırılmıştır.
- Sınıflandırıcı model olarak, kullanıcı parametre ayarlarından bağımsız olarak çalışabilen OMY tabanlı bir model kullanılmıştır. Önerilen yöntem ile az miktarda eğitim verisi ile üstün sınıflandırma performansı elde edilmiştir.
- Önerilen yöntem az miktarda veri ile çalışabildiğinden az verinin olduğu problemlerden etkilenmemektedir.
- Yapılan çalışma da kullanılan OMY tabanlı sınıflandırıcı model EKG işaretlerinden aritmi sınıflandırmasında kullanılan ilk girişimidir.

2. EKG ve KALP ARİTMİLERİ TANIMI

Bu bölümün birinci kısmında EKG dalga formunun morfolojisi ve elde edilmesi hakkında bilgiler verilmiştir. İkinci kısımda ise tez kapsamında yapılan çalışmalarda kullanılan aritmi türleri detaylıca açıklanmıştır.

2.1 EKG Morfolojisi

Kalbin birincil işlevi, hücrelerin hayatta kalması için oksijen bakımından zengin olan kanı organlara pompalamaktır. Vücutta kan dolaşımının sağlanabilmesi kalbin ritmik kasılma ve gevşeme döngüsünün sürekli devam etmesine bağlıdır. Bu döngü, kardiyak dokunun periyodik olarak elektriksel polarizasyonu ve depolarizasyonu yoluyla sağlanır. Kalbin bir döngü zamanı içerisindeki elektriksel aktivitesindeki değişimler ile oluşan sinyale EKG adı verilir. 100 yılı aşkın süre önce Hollandalı fizyolog Willem Einthoven tarafından keşfedilen EKG, halen kardiyoloji alanında en kullanışlı ve en kolay ulaşılabilir tetkik aracı olma özelliğini sürdürmektedir (Cajavilca ve Varon 2008). Vücut yüzeyine bağlanan metal elektrotlarla ölçülen EKG sinyali süresi ve genlikleri farklı olan üç blok dalgadan oluşur (Ingale ve diğ. 2020). Kardiyak döngünün aşamalarını temsil eden bu dalgaların isimleri sırasıyla P dalgası, QRS kompleksi ve T dalgası olup örnek bir EKG sinyali Şekil 2.1'de gösterilmiştir. P dalga bloğu, sino-atriyal (S-A) düğümden kalp kulakçıkları boyunca ilerleyen elektrik sinyali dağılımına atfedilen ve kasılmayı indükleyen atriyal depolarizasyona karşılık gelir. S-A düğümünden üretilen elektriksel dürtünün ilk dalga şeklindeki tezahürüdür. Kanı karıncıklara pompalayan kulakçık kasılmalarının başladığını gösteren P dalgasının uzunluğu genellikle 80 ile 100 mili-saniye civarındadır. P dalgası ekseriyetle düzleştirilmiş bir tepe noktasına sahiptir ve QRS kompleksi ile T dalgasından daha düşük bir genliğe sahiptir. QRS kompleksi, kalbin ana kasılmasına yol açan ventriküller depolarizasyonun görsel tezahürüdür. İsmini alfabedeki sıralı Q, R, S harflerinden alan kompleks Q dalgası, R dalgası ve S dalgasından oluşan bir sinyal bloğu olup kanın ciğerlere pompalandığı zamandır. Q ve S dalgası izoelektrik çizgiden negatif sapmalardır (Rao ve diğ. 2016, Peterkova ve Stremy 2016). Bir başka değişle elektrik akımı dokudan elektroda doğru ilerlediğinde, EKG'de pozitif sapma olarak görünür. Elektrik akımı elektrottan uzaklaştığında

EKG'de negatif potansiyel oluşur. R dalgası da genellikle izoelektrik çizginin üzerinde oluşan dalgadır. İzoelektrik çizgi ile ifade edilen durum EKG kaydındaki kalp atışları arasında herhangi bir elektriksel olayın olmadığı düz trend çizgisinin ifadesidir. EKG'deki QRS kompleksinde ortaya çıkan dalgalar P dalgalarından önemli ölçüde daha yüksek bir genliğe sahiptir.

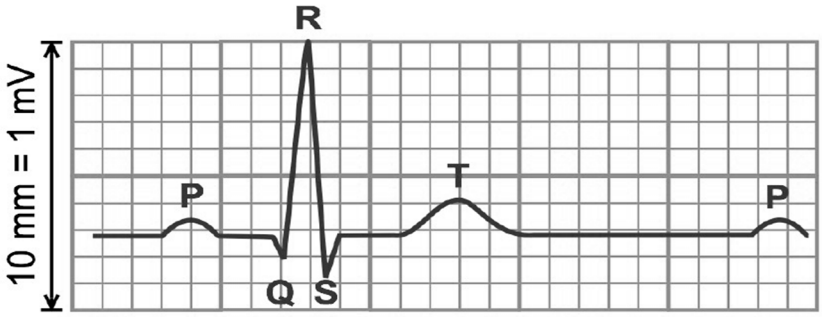

Şekil 2.1: Örnek EKG sinyali (Klabunde 2023).

Normal koşullar altında QRS kompleksinin 0,06-0,11 saniye süreye sahip olması beklenir. Daha geniş olması durumu anormal olarak algılanır (Rao ve diğ. 2016, Peterkova ve Stremy 2016). QRS kompleksinin ardından gelen T dalgası ise her iki ventrikülün repolarizasyonu veya toparlanmasını ifade eder. Örnek bir T dalgasının süresi 0,10 ila 0,25 saniye arasında değişir ve çoğu derivasyonda pozitif bir sapmadır. T dalgasının sönümlenmesi kardiyak döngünün sonunun geldiğini gösterir. T dalgaları genellikle P dalgalarından daha yüksek genliktedir. T dalgasındaki anormallik repolarizasyonun bozulmasına işarettir (Sattar ve Chhabra 2019; Gupta ve Mittal 2020; Klabunde 2023).

2.2 EKG İşaretinin Ölçülmesi

Kalp davranışının elektriksel imzası olan EKG sinyalleri, insan vücut derisi üzerine önceden belirlenmiş farklı konumlara yerleştirilen elektrotlardan toplanan sinyallerin diferansiyel geriliminin yükseltilip kaydedilmesiyle elde edilir. İlk olarak 1903 yılında Willem Einthoven tarafından keşfedilen yöntem, günümüzde kullanılan gelişmiş modelin basit hali olup, vücudun sağ ve sol kolu ile sol bacağının elektriksel bağlantı noktalarını temsil eden üçgenden elde edilen potansiyellerin farkına dayanır. Şekil 2.2 ile gösterilen ölçme yönteminde elektrotlar hastanın sağ ve sol bileği ile sol

bacağına bağlanır. İlgili bölgeden ölçülen gerilimler sırasıyla V_{SolK} $V_{SağK}$ ve V_{SolB} ile gösterilirse Einthoven derivasyonları:

$$\mathrm{DI} = V_{SolK} - V_{SağK} \tag{2.1a}$$

$$\mathrm{DII} = V_{SolB} - V_{SağK} \tag{2.2b}$$

$$\mathrm{DIII} = V_{SolB} - V_{SolK} \tag{2.1c}$$

eşitlikleri ile hesaplanır (Cajavilca ve Varon 2008). Kirchhoff yasasına göre, bu derivasyon gerilimleri $\mathrm{DII} = \mathrm{DI} + \mathrm{DIII}$ ilişkisi ile doğrulanır.

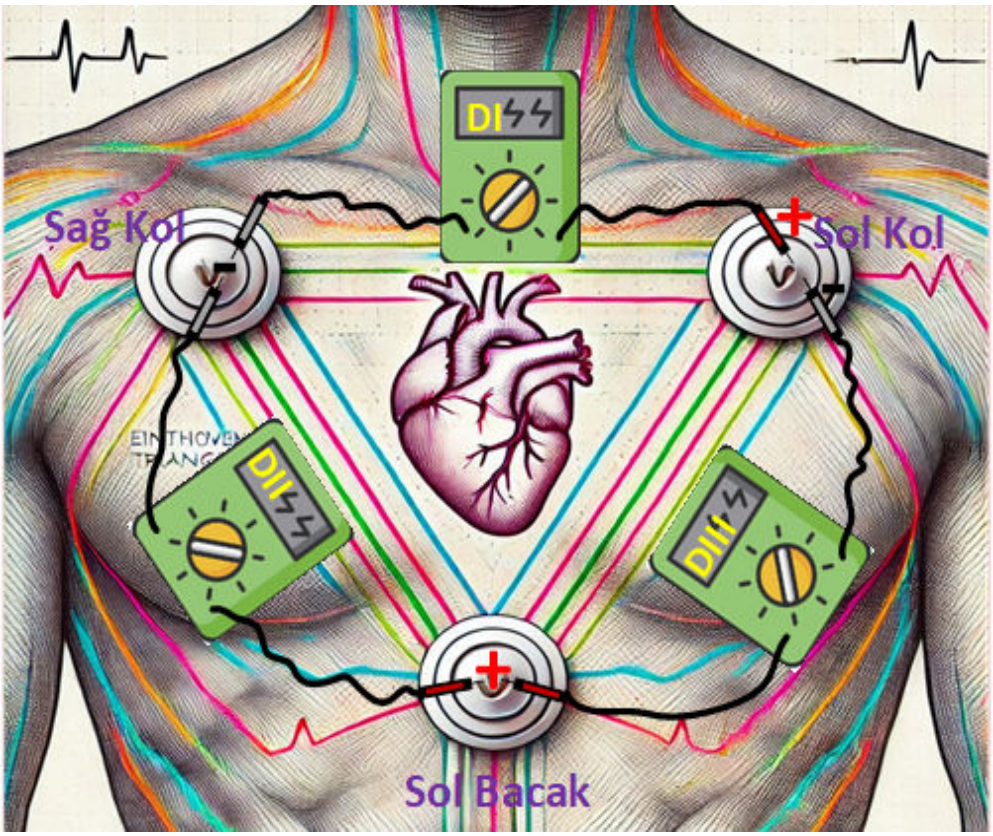

Şekil 2.2: Einthoven üçgenine dayalı EKG işaretinin elde edilmesi.

İnsan kalbinin elektriksel aktivitesini kapsamlı kaydetmek için günümüzde kullanılan modern konvansiyonel EKG cihazları 12 derivasyon ile kayıt alır. 12 derivasyonun 6 tanesi uzuv derivasyonlarından oluşurken kalan 6 tanesi göğüs derivasyonlarından oluşur. 12 derivasyonun elde edilmesinde 10 adet elektrot kullanılır. Bunların 6 tanesi göğüs üzerine konumlandırılırken 4 tanesi de uzuvlara yerleştirilen elektrotlar olup; vücut yüzeyindeki konumları Şekil 2.3'te verilmiştir. Sağ bacak terminali, sıfır

seviyesinde toprak görevi gören kayıtsız terminaldir. Böylece olası her bir derivasyon ile kalbin elektriksel aktivitesinin benzersiz bir perspektifi açığa çıkarılır. 6 adetten oluşan uzuv derivasyonları iki alt kümeden oluşur. Bunlarda 3 tanesi Einthoven üçgenine göre hesaplanan çift kutuplu standart derivasyonlar olup kutupların pozitif terminalleri Şekil 2.2'de gösterilmiştir. Geriye kalan üç derivasyon ise çift kutuplu derivasyon terminallerinden alınan bilgilerin harmanlanmasıyla elde edilmiş tek kutuplu derivasyonlardır (AlGhatrif ve Lindsay 2012). Elde edilen üç adet tek kutuplu derivasyonlar sıfır potansiyele sahip kaydedilmeyen bir elektrotla ilişkili tek bir noktadaki "V" gerilimini tanımlar. Matematiksel ifadesi Eşitlik (2.2) ile tanımlanan artırılmış derivasyonlar, küçük "a" ile ifade edilirken detaylı açıklaması aşağıda verilmiştir.

- aVsol: Sağ kol ile ortalama merkezi nokta arasındaki potansiyel farkı ölçer. Kalbin sağ tarafını temsil eder.
- aVsağ: Sol kol ile ortalama merkezi nokta arasındaki potansiyel farkı ölçer. Kalbin sol tarafını temsil eder.
- aVön: Sol bacak ile ortalama merkezi nokta arasındaki potansiyel farkı ölçer. Kalbin alt tarafını temsil eder.

$$\mathrm{aVsol} = \mathrm{V}_{SolK} - (\mathrm{V}_{Sağ K} + \mathrm{V}_{SolB})/2 \tag{2.2a}$$

$$\mathrm{aVsağ} = \mathrm{V}_{Sağ K} - (\mathrm{V}_{SolK} + \mathrm{V}_{SolB})/2 \tag{2.2b}$$

$$\mathrm{aVön} = \mathrm{V}_{SolB} - (\mathrm{V}_{Sağ K} + \mathrm{V}_{SolK})/2 \tag{2.2c}$$

Yatay düzlemde kalbin elektriksel aktivitesini yakalamak için kullanılan ve (V1-V6) sembolleri ile tanımlanan derivasyonların değerleri doğrudan ilgili göğüs elektrotlarından ölçülür (McLaren ve diğ. 2020). Vücut yüzey potansiyel referansı üç uzuv derivasyonunun ortalaması alınarak bulunur ve Wilson merkez terminali olarak adlandırılır (Gargiulo 2015). Daha sonra göğüs terminallerinden elde edilen gerilimler Wilson merkezi referans geriliminden çıkartılarak göğüs derivasyonlarının potansiyelleri bulunur. Tablo 2.1 ile eşitlikleri verilen derivasyonların türetilmesinde kullanılan elektrotlarının konumları Şekil 2.3'te verilen resim üzerinde gösterilmiştir.

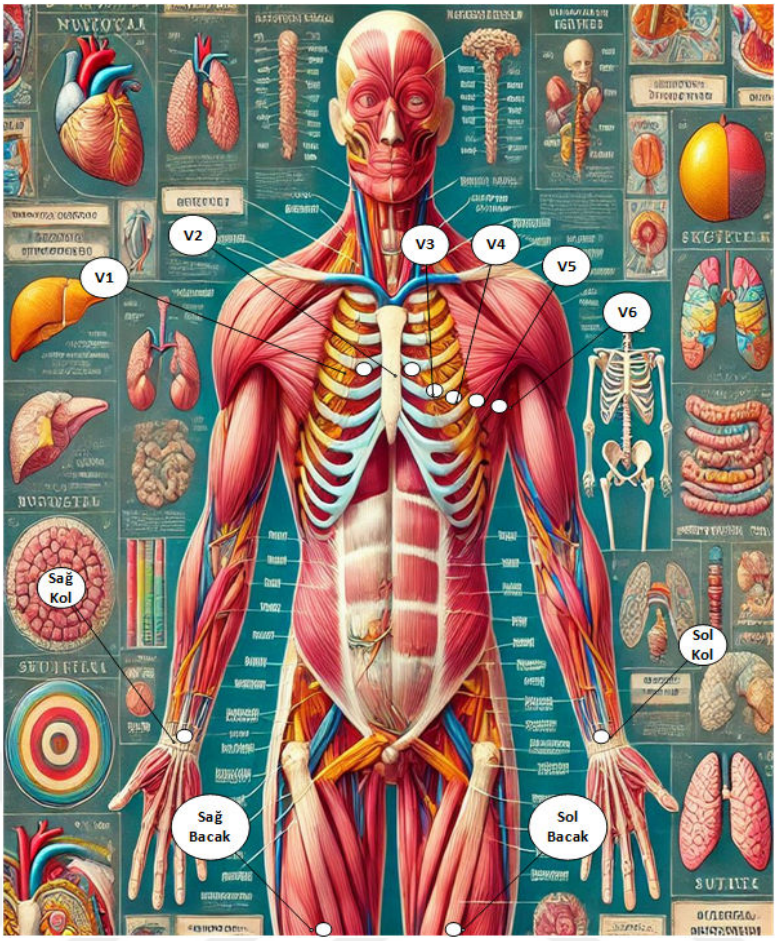

Şekil 2.3: On adet probun vücudun üzerindeki konumları.

Göğüs derivasyonları özellikle ventrikülleri etkileyen durumların teşhisi için çok önemliyken, uzuv derivasyonları kalbin aktivitesi hakkında daha geniş bir görüş sağlar. Her bir derivasyon kümesi kalbin elektriksel fonksiyonunun kapsamlı değerlendirmesinde tamamlayıcı öneme sahiptir (Klabunde 2023).

Tablo 2.1: 12 EKG Derivasyonun hesaplanmasında kullanılan eşitlikler

$V_w = \frac{1}{3}(V_{SolK} + V_{SağK} + V_{SolB})$	
$DI = V_{SolK} - V_{SağK}$	$V_1 = (v_1 - V_w)$
$DII = V_{SolB} - V_{SağK}$	$V_2 = (v_2 - V_w)$
$DIII = V_{SolB} - V_{SolK}$	$V_3 = (v_3 - V_w)$
$aVsol = \frac{3}{2}(V_{SolK} - V_w)$	$V_4 = (v_4 - V_w)$
$aVsağ = \frac{3}{2}(V_{SağK} - V_w)$	$V_5 = (v_5 - V_w)$
$aVön = \frac{3}{2}(V_{SolB} - V_w)$	$V_6 = (v_6 - V_w)$

2.3 Kalp Aritmi Türleri

Kardiyak aritmiler kalp ritmindeki sinüs ritminin bozulması ya da kalp atışlarının düzensizliği olarak tanımlanır. Geniş bir yelpazede karşılaşılan aritmilerin bazı türleri zararsız olup semptomları fark edilmez iken bazı türleri kalbin düzensiz kasılmasına neden olarak kalp krizi, inme veya ölüme sebep olabilecek kadar ciddi olabilmektedir. Aritmi türlerinin tasnifi düzenleyici kurumlara göre değişse de genellikle kalbin etkilendiği bölüme göre, kalbin çalışma hızına göre ve atımın düzenli-düzensiz olup olmadığına göre yapılır. Bu bağlamda genel olarak aritmi türleri sırasıyla supraventriküler (kalbin üst odacıkları kaynaklı), ventriküller (kalbin alt odacıkları kaynaklı) ve bradikardi (atım hızına bağlı) olmak üzere üç grup altında sınıflandırılmıştır (Atlee 2006).

Supraventriküler aritmiler kulakçıklarda veya alt odacıklara açılan kapılarda başlayan aritmi türleridir. Bu aritmilerin en önemlileri atriyal fibrilasyon (AFIB), atriyal flutter (AF), atriyoventriküler bağlantı ritmi (ABR) ve supraventriküler taşikardi (SVT) olarak isimlendirilir (Atlee 2006).

- **Atrial fibrilasyon (AFIB):** EKG dalga formundaki P dalgalarının kalbin hızlı çalıştığı durumlarda ortadan kaybolması ya da genliğinin neredeyse yok olma durumudur (Atlee 2006).
- **Atriyal flutter (AF):** Tıpa tıp AFIB'e benzeyen AF'da elektriksel aktivasyon S-A düğüm yerine atriyoventriküler düğüm içinde veya etrafında başlama durumudur. Fakat elektriksel dürtüler AFIB'e göre daha tutarlıdır. P dalgası seri şekilde ortaya çıkar ve testere dişine benzer (Atlee 2006).
- **Atriyoventriküler bağlantı ritmi (AVR):** Kalpteki elektriksel dürtü iletiminin bozulmasıyla uyarıların iletilememesi ya da baskılanmasıyla tetiklenen bir kalp aritmisidir. (Atlee 2006).
- **Supraventriküler taşikardi (SVT):** Halk arasında kalp çarpıntısı olarak bilinen SVT, kalbin iki kulakçığından kaynaklanan kalbin normal durumuna nazaran daha hızlı atması durumudur (Lilly ve Braunwald 2012).

Ventriküller aritmiler kalbin ventrikül adı verilen alt odacıklarında (karıncık) başlayıp genellikle hemen medikal aksiyon alınması gereken ciddi aritmi tipidir. Karıncıkların birinden 30 saniyeden uzun süren sıralı olarak üç veya daha fazla atım

olması durumunda teşhis edilir. Tür olarak üç çeşit olarak karşımıza çıkan ventriküller aritmilerin isimleri ventriküller fibrilasyon (VF), ventriküller taşikardi (VT) ve Bradikardi olup açıklamaları aşağıda verilmiştir (Lilly ve Braunwald 2012).

- **Ventriküller fibrilasyon (VF)**: Elektrik sinyallerinin alt odacıklardaki ventriküllerin normal pompalama yerine titremesine neden olduğunda ortaya çıkan aritmi türüdür. Karıncıkların vücuda kan pompalamaması durumunda kalp durabilir ve birkaç dakika içinde ölüm gerçekleşebilir. Acil durumlarda ortaya çıkan VF ile kalp çarpıntısı, göğüs rahatsızlığı, bayılma, kafa dönmesi, solunum problemlerine neden olabilir (Lilly ve Braunwald 2012).
- **Ventriküller taşikardi (VT)**: Kalbin karıncıklarından (ventriküller) kaynaklanan ve anormal derecede hızlı bir kalp ritmiyle karakterize edilen bir tür ritim bozukluğudur. Bu durum, kalbin normalden daha hızlı atmasına neden olur. Kalp karıncıklarının birkaç saniye veya çok daha uzun sürebilen düzensiz atışları olarak da ifade edilen aritmi türüdür. Genellikle birkaç sefer tekrarı sorun teşkil etmez. Ancak sürenin birkaç saniyeden daha uzun olması durumunda VF'ye dönüşmesi tehlikeli olur (Lilly ve Braunwald 2012)
- **Bradikardi**: Kalp atış hızının normalden daha yavaş olması durumudur. Yetişkinlerde nominal kalp atım hızı genellikle dakikada 60 ile 100 arasında normal kabul edilir. Bradikardi durumu kalp atım hızının dakikada 60'ın altına düşmesi olarak tanımlanır. Ancak, bazı bireyler (örneğin, iyi kondisyonlu sporcular) için bu durum normal olabilir ve semptomlara yol açmayabilir (Lilly ve Braunwald 2012).

Bir başka düzenleyici kurum olan Tıbbi Cihaz Geliştirme Derneği (AAMI) standartlarına göre hayatı tehdit etmeyen 15 farklı kalp aritmi türü beş sınıfta toplanmıştır. Bunlar sırasıyla: Sol Dal Vuru Bloğu (L), Sağ Dal Vuru Bloğu (R), ektopik olmayan ya da Normal (N) atım, supraventriküler ektopik (S), ventriküller ektopik (V), füzyon (F) ve bilinmeyen (Q) sınıf olarak adlandırılan aritmilerin tanımları aşağıda verilmiştir (Acharya ve diğ. 2017).

- **Sağ dal vuru bloğu (R):** Kalbin elektrik sinyalinin yayılımının sağ dalında engellenmesi ya da izole olması nedeniyle sağ ventrikülün depolarizasyonunun geç kalması durumudur. Bu durum, kalbin sol

ventrikülüne göre sağ ventrikülün kasılmaya başlamasında bir gecikme oluşturur (Strauss ve diğ 2011).

- **Sol dal vuru bloğu (L):** İsminden de anlaşılacağı gibi sol ventriküllere iletilen elektriksel sinyalin yolda kaybedilmesiyle ya da blokesiyle ortaya çıkan sol ventrikülün depolarizasyonunun gecikmesine neden olan anormalliktir. QRS kompleksinde gecikme ve bulanıklık meydana getirir (Strauss ve diğ 2011).
- **Erken ventriküller kasılma (PVC):** Ventriküller ektopik (V) olarak da bilinen erken ventriküller kasılmalar, ventriküller aktivasyonun yavaşlığından kaynaklanan ve EKG'de geniş QRS kompleksi olarak gelişen erken atımlardır. Normal döngüden daha erken ortaya çıktıkları için erken atım olarakda adlandırılırlar. Üç veya daha fazla ardışık PVC ortaya çıkması durumu (VT) olarak adlandırılır (Wasimuddin 2023).
- **Erken atriyal kasılma (PAC):** Bir diğer ismi supraventriküler ektopik (S) olan erken atriyal kasılma (kalpteki elektrik dürtü iletiminin bozulmasıyla tetiklenen bir kalp aritmisidir) aritmisi, kulakçıkların kasılmasının erken başladığı durumlarda meydana gelen, ekstra kalp vurusu durumudur. PAC ile kalp erken kasılır böylece kan olmayan kalpte dar bir QRS kompleksi oluşur ya da atımın atlanmasına sebebiyet verilir (Fukuata ve diğ 2008).
- **Füzyon (F):** Kalbin elektriksel döngüsünde meydana gelen bir tür aritmi olarak bilinir. Bu durum, kalbin farklı bölgelerinde aynı anda birden fazla elektriksel döngü oluşmasına neden olur. Bu da kalp döngüsünün dengesiz hale gelmesine ve aritmilerin ortaya çıkmasına yol açar (Strauss ve diğ 2011).

3. ÇALIŞMADA KULLANILAN EKG VERİ TABANLARI

Tez kapsamında yapılan çalışmalarda, önerilen yöntemin aritmi sınıflandırma başarısı, MIT-BIH, Chapman ve PTB-XL olmak üzere halka açık üç veri tabanından alınan farklı sınıflardan oluşan EKG sinyalleri kullanılarak değerlendirilmiştir.

3.1 MIT-BIH Veri Tabanı

Yapılan çalışmada kullanılan EKG işaretlerinin yer aldığı MIT-BIH aritmi veri tabanı aritmi çalışmaları için iyi bilinen ve yaygın olarak kullanılan bir veri koleksiyonudur. Bu veri koleksiyonu Beth Israel Hastanesi (şimdiki adıyla Beth Israel Deaconess Tıp Merkezi) ve Massachusetts Teknoloji Enstitüsü (MIT) laboratuvarlarının iş birliği ile toplanmıştır. Hastalardan veri toplama işlemi 1975 yılında başlamıştır. Veri tabanı 1980 yılında halka erişime açılmıştır. Tarihsel olarak aritmi tiplerinin tespiti, test edilmesi ve değerlendirilmesi için halka açık hale getirilen ilk standart veri tabanı olarak günümüze kadar temel kardiyak analizi için 3800'den fazla çalışmaya referans teşkil etmiştir (Moody ve Mark 2001).

MIT-BIH aritmi veri tabanı, 47 bireyden toplanan 48 adet çift kanallı EKG kaydından oluşmaktadır (Moody ve Mark 2001). Her kayıt yaklaşık 30 dakika uzunluğundadır ve saniyede 360 örnek ile sayısallaştırılmıştır. Toplanan EKG sinyalleri derivasyon (lead) II kanalından elde edilmiştir. Tüm kayıtlar iki kardiyolog tarafından incelenip aritmilerin yerleri ve türleri etiketlemiştir. Herhangi bir tutarsızlık durumu doktorlar arası fikir birliği ile çözülmüştür Tablo 3.1 ile gösterilen 16 farklı etiketten oluşan veri tabanı yaklaşık 109000 kalp atımı içermektedir. Etiket türleri AAMI standardına göre beş ana sınıfta toplanmıştır. Bu aritmi sınıfları ektopik olmayan atımlar (N), supraventriküler ektopik atımlar (S), ventriküller ektopik atımlar (V), füzyon atımlar (F) ve bilinmeyen atımlar (Q) olup; veri tabanındaki hiyerarşisi ve örnek sayısı Şekil 3.1'de verilmiştir. Tez kapsamında yapılan simülasyonlarda 44 kayıt kullanılırken 102, 104, 107 ve 217 numaralı dört kayıt yetersiz kaliteleri nedeniyle hariç tutulmuştur. Ayrıca, Q sınıfı kalp atışları içeren kayıt sayısının az olması nedeniyle anlamlı bir şekilde sınıflandırılamamaktadır. Bu nedenle Q sınıfı kalp atışları performans değerlendirmelerine dahil edilmemiştir.

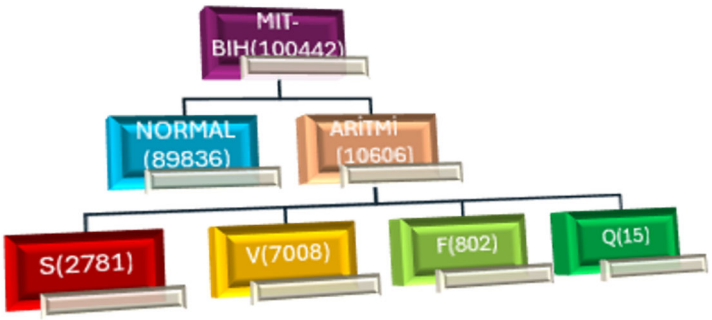

Şekil 3.1: MIT-BIH veri tabanındaki aritmi türleri ve sayıları.

MIT-BIH veri tabanından alınan kayıtların uzunluğu nedeniyle doğrudan sınıflandırma işlemine tabi tutulması mümkün değildir. O nedenle mevcut çalışmada MIT-BIH veri tabanına dayalı bilgisayar benzetimleri parçalara bölünmüş EKG sinyalleri üzerinden yapılmıştır.

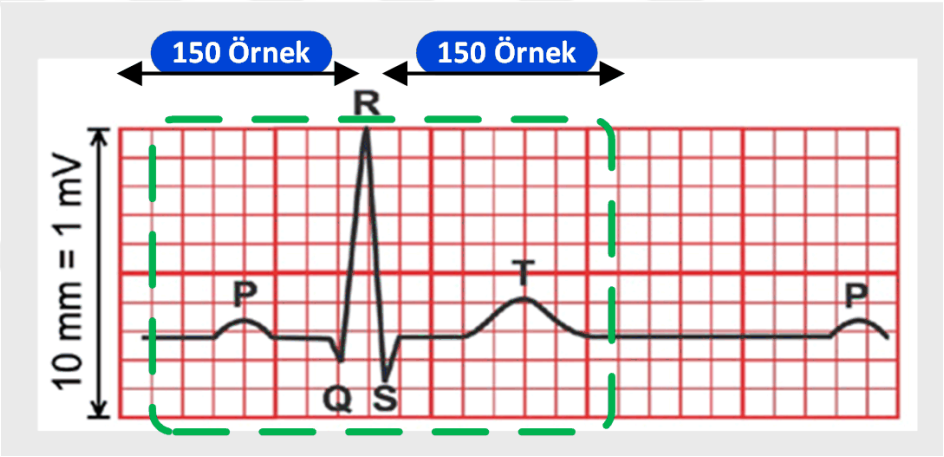

Şekil 3.2: EKG sinyalinin bölütlenmesi.

Bu doğrultuda 30 dakika uzunluğundaki EKG sinyalleri tek bir PQRST kombinasyonunu içerecek biçimde, Şekil 3.4'te gösterildiği gibi R-tepe noktasının sağından ve solundan 150 örnek noktası alınarak 301 noktadan oluşan EKG sinyal parçalarına bölünerek veri tabanı hazırlanmış ve sınıflarda yer alan veri sayıları Tablo 3.1 ile verilmiştir (Bi ve diğ. 2024). Tez kapsamında yapılan çalışmaların ilkinde performans değerlendirme aşamasında N sınıfı; normal atımlar (N), sol dal bloğu atımları (L) ve sağ dal bloğu atımları (R) olmak üzere üç sınıfa genişletilmiştir. Böylece performans değerlendirmesi N, L, R, V, S ve F olmak üzere altı aritmi sınıfı üzerinden yapılmıştır. Yapılan çalışmanın ikincisinde L ve R sınıfı verileri N sınıfında birleştirilerek ele alınmıştır.

Tablo 3.1: MIT-BIH veri tabanında bulunan aritmi türleri ve etiketleri

Kalp Atım Sınıfı	Kalp Atım Türü	Kalp Atım Etiketi	Örnek Sayısı
Ektopik Olmayan Atımlar (N)	Normal atımlar Sol dal bloğu atımları Sağ dal bloğu atımları Düğüm kaçış atımları Atriyal kaçış atımları	N L R j e	89836
Supraventriküler Ektopik Atımlar (S)	Kusurlu atriyal prematüre atımlar Supraventriküler prematüre atımlar Atriyal erken kasılma Nodal (kavşak) prematüre atımlar	a S A J	2781
Ventriküller Ektopik Atımlar (V)	Ventriküller çırpınış dalgası Ventriküller kaçış atımları Erken ventriküller kasılma	! E V	7008
Füzyon Atımlar (F)	Ventriküller ve normal atımların birleşimi	F	802
Bilinmeyen Atımlar (Q)	Tempolu atımlar Sınıflandırılamayan atımlar Tempolu ve normal atımların birleşimi	/ Q f	15

3.2 Chapman Veri Tabanı

Chapman veri tabanı, 10646 hastadan saniyede 500 örnekle toplanan 12 derivasyonlu (lead) EKG sinyallerinden oluşmaktadır (Zhang ve diğ. 2020). Her bir EKG kaydının süresi 10 saniye olup tümü profesyonel kardiyologlar tarafından etiketlenmiş 11 aritmi ve 56 tip kardiyovasküler durum içerir. Kardiyologların önerileri doğrultusunda, bu veri tabanındaki bazı nadir aritmi türleri hiyerarşik olarak üst düzey aritmi türleriyle birleştirilmiştir. Böylece, 11 kalp ritmi Tablo 3.2'de gösterildiği gibi dört tip aritmi sınıfı altında gruplandırılmıştır. Bu veri tabanında, ham EKG kayıtları taban hattı kayması, şebeke gürültüsü, elektromiyografi ve rastgele gürültü nedeniyle kirlenmiştir. Gürültülü EKG işaretleri yerel olmayan ortalamalı süzgeçleme, Butterworth düşük geçişli filtrelemeye ve yerel polinom regresyon ile yumuşatma işlemine tabi tutularak gürültüden arındırılmış sürümleri elde edilmiştir. Tez kapsamında önerilen sınıflandırma yöntemlerinin başarımlarını değerlendirmede derivasyon (lead) II kanalından elde edilen gürültülü (ham) EKG kayıtları ile gürültüsü süzülmüş EKG kayıtları kullanılmıştır (Zhang ve diğ. 2020). Böylece önerilen yöntemin gürültüye maruz kalmış işaretlerdeki davranışı incelenmiştir.

Tablo 3.2: Chapman veri tabanında bulunan aritmi türleri ve etiketleri

Kalp Atım Sınıfı	Kalp Atım Türü	Kalp Atım Etiketi	Örnek Sayısı
Sinüs Bradikardi (SB)	Sinüs Bradikardi	SB	3889
Genel Supraventriküler Taşikardi (GSVT)	Sinüs taşikardi Supraventriküler taşikardi Atriyal taşikardi Atriyoventriküler düğüm girintili taşikardi Atriyoventriküler girintili taşikardi Sinüs atriyumundan atriyuma dolaşma ritmi	ST SVT AT AVNRT AVRT SAAWR	2307
Atriyal Fibrilasyon (AFIB)	Atriyal fibrilasyon atımlar Atriyal flutter atımlar	AFIB AF	2225
Sinüs Ritim (SR)	Normal sinüs ritmi atımlar Düzensiz sinüs atımlar	SR SI	2225

3.3 PTB-XL Veri Tabanı

PTB -XL veri tabanı, 18885 hastadan 12 derivasyon (lead) ile toplanmış 21837 adet EKG kaydından oluşmaktadır. Tıbbi araştırma topluluğu içinde çok çeşitli EKG analiz görevleri için değerli bir kaynak olarak hizmet vermektedir. Her kayıt 10 saniye uzunluğunda olup 500 Hz ile örneklenmiştir. Üç adet alt kümeden oluşan veri tabanında toplam 71 adet etikete sahip aritmi vardır.

Tablo 3.3: PTB-XL veri tabanında bulunan aritmi türleri ve etiketleri

Aritmi Türü ve Etiketi	Kalp Atım Türü	Örnek Sayısı
NORM	Normal sinüs ritmi	9069
CD	İletim bozukluğu	1708
HYP	Hipertrofi	535
MI	Kalp krizi	2532
STTC	ST bölgesi değişimi	2400

Kayıtların bazılarında birden fazla etiket mevcuttur. Kardiyak bozukluğu işaretlerine sahip diagnostik kümesi 44 adet etiketten oluşur. Tüm kayıtlar, ST/T değişikliği (STTC), hipertrofi (HYP), iletim bozukluğu (CD), normal EKG (NORM) ve miyokard enfarktüsü (MI) olarak adlandırılan beş ana tanısal aritmi sınıfında birleştirilerek süper üst sınıflar oluşturulmuştur. Bu çalışmada kullanılan aritmi türleri ve sayıları Tablo 3.3'te verilmiş olup çoklu etiket içermeyen 16244 EKG kaydı üzerinde benzetim analizleri gerçekleştirilmiştir. Bu kayıtların 9069'u NORM, 1708'i CD, 535'i HYP, 2532'si MI ve 2400'ü STTC sınıflarına aittir (Wagner 2020).

4. DEĞERLENDİRME METRİKLERİ

Makine öğrenimi modelinin performans ve etkinliğini ölçmede kullanılan tarafsız kıstaslara değerlendirme metrikleri adı verilir. Değerlendirme metrikleri ile modellerin ne kadar iyi çalıştığına karar verilir. Sınıflandırmada daha şeffaf sonuçlar elde etmek için probleme göre değerlendirme metrikleri seçilir. Probleme uygun metriklerin olmadığı durumlarda ise probleme özgü yeni metrikler de geliştirilebilir. Sınıflandırma ya da ayırt etme problemlerinde yaygın olarak kullanılan metrikler genel doğruluk, kesinlik, hassasiyet, özgüllük ve F1-skor olup; bu metriklerin hesaplanmasında kullanılan kavramlar aşağıda açıklanmıştır.

- **Doğru Pozitif (DP):** Model tarafından doğru tahmin edilen pozitif sınıf sonuçlarını gösterir.
- **Doğru Negatif (DN):** Model tarafından doğru tahmin edilen negatif sınıf sonuçlarını gösterir.
- **Yanlış Pozitif (YP):** Gerçekte negatif sınıfa ait olan deneğin model tarafından pozitif olarak yanlış sınıfa atanmasıdır.
- **Yanlış Negatif (YN):** Gerçekte pozitif sınıfa ait olan deneğin model tarafından negatif olarak tahmin edilmesidir.
- **Karışıklık Matrisi (KM):** Karışıklık matrisi (KM) sınıflandırma modelinin performansını özetleyen bir tablo olup; satır ve sütun sayısı sınıf sayısına eşit olan bir kare matristir. Yatay eksen modelin tahmin edip atadığı sınıfları temsil ederken, dikey eksen deneğin referans sınıfını temsil eder. Ana köşegen üzerindeki elemanlar, yüzde ya da sayı olarak DP'lerin ortaya çıkma frekansını belirler. Matrisin ana köşegen dışında kalan elemanları hatalı sınıflara atanmış deneklere karşılık gelir. Ana köşegen değerlerinin üstü ve altı YP ile temsil edilirken sağı ve solu YN temsil edilir. Ana köşegen değeri ve bunların dışındakiler DN'yi temsil eder. Değerlendirme metriklerinin hesaplanmasında KM'den yararlanılır. Bir girdi verisinin iki sınıftan birisine atandığı ikili sınıflandırma modelinde KM'nin nasıl oluşturulduğu Şekil 4.1'de gösterilmiştir. Sınıf sayısının ikiden fazla olduğu durumlarda çoklu karışıklık matrisi durumu ortaya çıkar. Bu durumda, her sınıf için bire-karşı hepsi strateji yaklaşımıyla ayrı ayrı ikili karışıklık matrisi oluşturulur ve tüm sınıflar arasında genel bir değerlendirme yapılır.

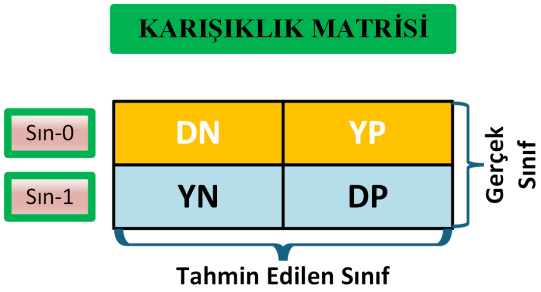

Şekil 4.1: İki sınıftan oluşan karışıklık matrisi örneği.

Üç sınıftan oluşan karışıklık matrisi Şekil 4.2 ile gösterilmiştir. Çok sınıflı karışıklık matrisi, sınıfları oluşturan verilerinin dengesizliğinin olduğu veri kümelerinde model performansının daha doğru bir şekilde değerlendirilmesinde efektif bir çözüm sunar. Tüm sınıflandırma modellerinde kullanılan değerlendirme metriklerinin tanımları ile eşitlikleri aşağıdaki başlıklarda verilmiştir.

ÇOK SINIFLI KARIŞIKLIK MATRİSİ

	Tahmin: A	Tahmin: B	Tahmin: C	
GERÇEK: A	856 28,98%	58 1,96%	130 4,4%	1044 35,34%
GERÇEK: B	0	765 25,9%	136 4,6%	901 30,5%
GERÇEK: C	69 2,34%	33 1,12%	907 30,7%	1009 34,16%
	925 31,31%	856 29,86%	1173 39,71%	2954 %100

Şekil 4.2: Çoklu sınıftan oluşan karışıklık matrisi örneği.

4.1 Kesinlik (Precision)

Kesinlik (Pre), doğru tahmin edilen pozitif deneklerin pozitif olarak tahmin edilen tüm deneklere oranını ölçer.

$$\mathrm{Pre} = \frac{\mathrm{DP}}{\mathrm{DP} + \mathrm{YP}} = \frac{1}{1 + \frac{\mathrm{YP}}{\mathrm{DP}}} \tag{4.1}$$

Pre metriği, modelin YP'lerden kaçınma yeteneği hakkında bilgi verir. Yani negatif deneklerin pozitif olarak sınıflandırılmasını en aza indirirken pozitif denekleri doğru bir şekilde tanıma becerisi hakkında fikir sağlar. Dolayısıyla yüksek Pre skoru, YP oranının düşük olmasını, modelin daha güvenilir tahmin yaptığını gösterir. Pre metriğinde, DP her zaman maksimize edileceğinden dolayı YP'lerin minimize edildiği yerlerde kullanılır.

4.2 Genel Doğruluk (Overall Accuracy)

Genel Doğruluk (GD), sınıflandırma modellerinin performansını değerlendirmek için yaygın olarak kullanılan bir metriktir. GD, her bir sınıf için doğru pozitif olarak tahmin edilen denek sayılarının toplamının toplam denek sayısına oranı olarak tanımlanır.

$$\mathrm{GD} = \frac{\sum_{i=1}^{K} \mathrm{DP}^{(i)}}{\mathrm{DP} + \mathrm{DN} + \mathrm{YP} + \mathrm{YN}} \tag{4.2}$$

Burada $\mathrm{DP}^{(i)}$, *i.* sınıfa ilişkin doğru pozitifi ifade eder. GD özellikle sınıf dengesizliği yüksek olan veri kümelerinde iyi bir metrik değildir. Çünkü azınlık sınıfta olan elemanların başarısız sınıflandırılmasının toplam doğruluğa katkısı azdır. Başka bir deyişle, baskın olan veri kümesindeki yüksek başarım nedeniyle elde edilen GD oranı, azınlık sınıfının doğru olarak sınıflandırıldığını göstermez. Örneğin ikili sınıflandırma modelinde, tüm veri kümesinin %3'ü azınlık sınıfına ait olsun. Baskın sınıfın hepsinin doğru sınıflandırılmasıyla %97 GD oranı elde edilecektir. Fakat azınlık sınıfın doğru sınıflandırılması kaybedilmiş olacaktır.

4.3 Hassasiyet (Sensivity)

Hassasiyet metriği (Sen) pozitif deneklerin tespitinin önemli olduğu senaryolarda sınıflandırma modelinin başarımını değerlendirmede kullanılır.

$$\mathrm{Sen} = \frac{\mathrm{DP}}{\mathrm{DP} + \mathrm{YN}} = \frac{1}{1 + \frac{\mathrm{YN}}{\mathrm{DP}}} \tag{4.3}$$

Bu metrik, özellikle dengesiz veri setlerinde ve nadir olayların tespitinde büyük önem taşır. Veri kümesindeki bütün pozitif deneklerden kaç tanesinin model tarafından doğru bir şekilde sınıflandırıldığı sorusunun cevabını verir.

4.4 F1-Skor

F1-skoru, Pre ve Sen metriklerinin birleşiminden oluşur. Hem YP'lerin hem de YN'lerin eşit derece önemli olduğu ve ikisinden de kaçınılmaması gerektiği durumlarda kullanılır. Kısaca F1-skoru, Pre ve Sen metriklerinin harmonik ortalamasına karşılık düşer ve Eşitlik 4.4 ile tanımlanır.

$$\mathrm{F1-Skor} = 2 * \frac{\mathrm{Pre} \times \mathrm{Sen}}{\mathrm{Pre} + \mathrm{Sen}} \tag{4.4}$$

4.5 Özgüllük (Specifity)

Özgüllük (Spe), bir sınıflandırma modelinin negatif sınıfları doğru bir şekilde tanımlama yeteneğini ölçen bir performans metriği olup

$$\mathrm{Spe} = \frac{\mathrm{DN}}{\mathrm{DN} + \mathrm{YP}} = \frac{1}{1 + \frac{\mathrm{YP}}{\mathrm{DN}}} \tag{4.5}$$

eşitliği ile hesaplanır. Spe, modelin yanlış pozitif oranının düşük olmasını ve doğru negatif oranının yüksek olmasını sağlar. Yüksek Spe değerleri, modelin negatif sınıfları başarılı bir şekilde ayırt ettiğini gösterir ve bu durum, özellikle yanlış pozitif sonuçların maliyetinin yüksek olduğu durumlarda önemlidir.

5. ÖZNİTELİK ÇIKARMADA KULLANILAN YÖNTEMLER

EKG işaretlerinin klasik makine öğrenmesi yöntemleri kullanarak sınıflandırılması işlemi öznitelik çıkartma ve sınıflandırma sürecini içeren iki adımdan oluşur. Öznitelik çıkartma adımı ham veriden anlamlı ve ayırt edici bilgilerin elde edilmesi sürecini oluştururken sınıflandırma adımı çıkartılan özniteliklerin makine öğrenimi tabanlı sınıflandırıcıya girdi olarak uygulanarak farklı kardiyak durumun tayinine karşı düşer. Makine öğrenmesi modellerinin performansı büyük ölçüde özniteliklerin kalitesine ve temsil yeteneğine bağlıdır. Bu nedenle, öznitelik çıkartma işlemi makine öğrenmesi sürecinin en kritik adımlarından birisi olup otomatik teşhis sistemlerinin geliştirilmesinde kilit bir rol oynamaktadır. Doğru özniteliklerin seçilmesi, modelin daha hızlı çalışmasını, daha az veriye ihtiyaç duymasını ve daha doğru sonuçlar üretmesini sağlar.

Bu bağlamda yapılan çalışmada daha iyi bir sınıflandırma başarımı için ağırlıklı olarak Z-F haritalarından oluşan öznitelik matrislerinden faydalanılmıştır. Bu doğrultuda, EKG işaretlerinin Z-F haritalarına dönüştürülmesinde aynı anda zaman ve frekans lokalizasyonu sağlayan FAY veya KZFD yöntemleri kullanılmıştır. Sınıflandırma modelindeki hesapsal karmaşıklık ve işlem süresini azaltmak için öznitelik matrislerinin boyutları 2BTBA ile indirgenmiştir.

5.1 Fourier Ayrıştırma Yöntemi (FAY)

Singh ve diğ. (2017) tarafından keşfedilen FAY, matematiksel olarak kapalı formda ifade edilebilen, doğrusal ve durağan olmayan analitik işaretlerin analizinde kullanılabilen, parametre seçiminden bağımsız, tamamen uyarlanabilir veri güdümlü bir Z-F ayrıştırma yöntemidir. Kökeni Fourier dönüşümüne dayanan FAY ile herhangi bir işaret, sonlu sayıda Analitik Fourier Temel Bant Fonksiyonu (AFTBF) adı verilen birbirine dik, sıfır ortalamalı işaret bileşenlerine ayrıştırılır. AFTBF'lerin anlık frekansları ile anlık genlikleri daima pozitif değerlerden oluştuğu için işaretin Z-F temsilinde de kullanılabilirler. AFTBF'lerin gerçek kısmına karşılık gelen Fourier Temel Bant Fonksiyonlarının (FTBF) toplanmasıyla asıl işaret geri çatılabilir (Singh

ve diğ. 2017). Sinyal içerisinde gizli kalmış detayları gün yüzüne çıkartma yeteneği, FAY'ı sınıflandırma uygulamaları için cazip kılmıştır. Bugüne kadar sınıflandırma alanında el hareketlerinin tanınması, epileptik nöbetlerin, alkolizmin, miyokard enfarktüsünün, uyku apnesinin, biyometrik kimliğin ve hipertansiyonun tespit edilmesi gibi çalışmalarda FAY'dan yararlanılmıştır (Tripathy 2018; Fatimah ve diğ. 2020; Fatimah ve diğ. 2021; Mehla ve diğ. 2021; Mehla ve diğ. 2021[b;] Fatimah ve diğ. 2021[b]; Fatimah ve diğ. 2022; Parmar ve diğ. 2022).

FAY'ın sistematiği herhangi bir aritmi sınıfına ait N örnekten oluşan gerçek değerli $\{s(n), n = 0, 1, \dots, N-1\}$ işaretinin N noktalı ayrık Fourier dönüşümü (AFD) katsayıları ile ağırlıklandırılmış Fourier tabanlarının toplamı aracılığı ile temsil edilmesine dayanır. Dolayısıyla, FAY'ın ilk adımı işarete ilişkin AFD katsayılarının

$$S(k) = \frac{1}{\mathrm{N}} \sum_{n=0}^{N-1} s(n) e^{-j2\pi kn/N}; k = 0, 1, \dots, N-1 \qquad (5.1)$$

hesabı ile başlar. Burada N noktalı $s(n)$ işaretinin ters ayrık Fourier dönüşümü (TAFD)

$$s(n) = \sum_{k=0}^{N-1} S(k) e^{j2\pi kn/N} \qquad (5.2)$$

ile geri çatılır. Eşitlik (5.2) ile verilen geri çatma denklemi, $s(n)$ işaretinin uzunluğu olan N'nin tek ve çift değerlerine göre eşdeğer olarak ifade edilebilir:

$$s(n) = S(0) + Re\{ z_{ç}(n)\} + (-1)^n S(N/2) \qquad N: çift \qquad (5.3a)$$

$$s(n) = S(0) + Re\{ z_t(n)\} \qquad N: Tek \qquad (5.3b)$$

. Burada $Re\{ z_t(n)\}$ ve $Re\{ z_{ç}(n)\}$ ifadeleri

$$z_t(n) = 2 \sum_{l=1}^{(\frac{N-1}{2})} S(l) e^{j2\pi ln/N} \;\; ve \;\; z_{ç}(n) = 2 \sum_{l=1}^{(\frac{N}{2}-1)} S(l) e^{j2\pi ln/N}. \qquad (5.4)$$

ile tanımlanan $z_t(n)$ ve $z_{ç}(n)$ analitik işaret biçimlerinin reel kısmını ifade eder. Tez bütünlüğünün sağlanması adına FAY çıkarımlarının türetilmesindeki karmaşıklığı

önlemek için bundan sonraki adımlarda işaret uzunluğunun tek olduğu varsayımı altında devam edilecektir.

FAY temelinde Eşitlik (5.4)'de tanımlanan $z_t(n)$ analitik işareti sonlu sayıda bant sınırlı dik bileşene ayrıştırılır:

$$z_t(n) = \sum_{m=1}^{M} a_m(n) e^{j\phi_m(n)} \tag{5.5}$$

Burada $a_m(n)e^{j\phi_m(n)}$ terimi anlık faz ve anlık genliği sırasıyla $\phi_m(n)$ ve $a_m(n)$ olan m. AFTBF'yi ifade ederken, toplam AFTBF sayısı M ile temsil edilir. Ayrıştırma sonucu elde edilen AFTBF'nin bant genişliğini ifade eden alt ve üst frekans indislerinin belirlenmesi FAY'ın kilit adımını oluşturmaktadır. En az sayıda monotonik olarak artan AFTBF'nin çıkarımı, düşükten yüksek frekansa tarama (DYFT) ya da yüksekten düşük frekansa tarama (YDFT) adı verilen iteratif bir yordam ile gerçekleştirilir. Bu yordamların Eşitlik (5.4)'e uygulanması ile iki farklı AFTBF kümesi elde edilebilir (Singh ve diğ. 2017).

5.1.1 AFTBF'lerin İleri Yönde Aranması: DYFT Yordamı

DYFT yordamı AFTBF'lerin frekans bant indislerinin düşük frekanstan yüksek frekansa doğru taranarak bulunması işlemidir. Yordamın birinci adımında, birinci bileşen olan $a_1(n)e^{j\phi_1(n)}$ 'nin $2\sum_{l=1}^{N_1} S(k)e^{j2\pi ln/N}$ ifadesine eşlenmesiyle başlar. Benzer şekilde ikinci bileşen $a_2(n)e^{j\phi_2(n)}$, $2\sum_{l=N_1+1}^{N_2} S(k)e^{j2\pi ln/N}$ ifadesine eşitlenir. Eşitleme işlemi genellenirse m. AFTBF'yi tanımlayan denklem

$$a_m(n)e^{j\phi_m(n)} = 2\sum_{l=N_{m-1}+1}^{N_m} S(k)e^{j2\pi ln/N} \tag{5.6}$$

şeklinde ifade edilir. Eşitlik (5.6)'dan anlaşılacağı üzerine bileşenlerin frekans bant indis aralığı $N_0 = 0$ ve $N_M = (N-1)/2$ ile sınırlıdır. Ayrıştırma çerçevesi kapsamında en az sayıda AFTBF'yi elde etmek için her bileşenin üst frekans indisini en büyükleme

gerekir. Bu doğrultuda m'inci bileşenin üst indisi olan N_m değeri, $N_{m-1}+1$ ile $(N-1)/2)$ aralığında m = 1,2, …, M-1 değerleri için

$$\varphi_m(n) = \phi_m(n+1) - \phi_m(n) \geq 0, \quad \forall n. \tag{5.7}$$

koşulunu sağlayan en yüksek değere atanarak bulunur. Eşitlik (5.7) koşulundaki $\varphi_m(n)$ ifadesi m'inci bileşenin anlık fazına karşılık düşer ve m'inci AFTBF'nin anlık frekans kestirimi, $n = 0, 1, \ldots, N-1$ değerleri için $f_m(n) = \varphi_m(n)/2\pi$ eşitliği ile hesaplanır. Yordam sonucunda elde edilen anlık frekans ve genlikler ile zaman-frekans haritası oluşturulur.

5.1.2 AFTBF'lerin Geri Yönde Aranması: YDFT Yordamı:

YDFT yordamında bileşenlerin frekans indisleri, üst sınır olan $N_0 = (N+1)/2$'den alt sınır olan N_M = 1'e doğru geri yönde frekans tarama işlemi Eşitlik (5.6)'nın üst ve alt sınırlarının $N_{m-1} - 1$ ve N_m ile değiştirilmesiyle gerçekleştirilir. Buna göre YDFT yordamı için genel eşitlik

$$a_m(n)e^{j\phi_m(n)} = 2\sum_{l=N_m}^{N_{m-1}-1} S(k)e^{j2\pi ln/N} \tag{5.8}$$

şeklinde ifade edilir. DYFT işlemine benzer şekilde, Eşitlik (5.8)'e göre minimum sayıda AFTBF elde etmek için her bileşenin frekans indisleri olan $\{N_m\}_{m=1}^{M-1}$ 'nin belirlenmesi gerekir. Yinelemeli bir süreç olan indis belirleme işleminde, herhangi bir m. bileşene ait frekans indisi olan N_m, $[N_{m-1} - 1, N_M]$ aralığında $m = 1, 2, \ldots, M$ değerleri için Eşitlik (5.7) koşulu altında aranır. Arama işlemi için toplam $N_{m-1} - 1$ iterasyon gerekirken, anlık faz ve genlik terimlerin de monoton artanlık ilkesi de sağlanmış olur.

Geleneksel FAY ayrıştırması, yüksek hesaplama maliyeti, uzun hesaplama süreleri ve büyük bellek gereksinimlerinden muztariptir. Özellikle uzun süreli EKG kayıtlarında FAY'ın karmaşıklığı sinyal örnek sayısıyla artış gösterir. Bunun nedeni sinyali AFIBF'lere ayrıştırmak için yapılan frekans tarama sürecidir. Tüm bu gereksinimler, özellikle yüksek örnekleme oranlarına sahip sinyaller için FAY

kullanımını sınırlamaktadır. Bu sınırlamanın üstesinden gelmek için HFD'nin FAY'a entegre sürümü kullnılmıştır (Kizilkaya ve Elbi 2023).

5.1.3 AFTBF'lerin YDFT Yordamı Üzerinden HFD ile Hesaplanması

Eşitlik (5.6) ile tanımlanan AFTBF'lerin doğrudan hesaplanması, çok sayıda karmaşık çarpma ve toplama işlemi nedeniyle ağır bir hesaplama yükü gerektirir. Neyse ki bu elverişsiz durum Ters Hızlı Fourier dönüşümü (THFD) ile aşılabilir. Bu doğrultuda YDFT yordamı çerçevesinde $N_0 = N/2$ ve $N_M = 0$ aralığında, Eşitlik (5.8) ile tanımlanan *m.* AFTBF bileşeni

$$w_m^{(p)}(n) = a_m^{(p)}(n)e^{j\phi_m^{(p)}(n)} = 2\sum_{k=N_{m-1}-p}^{N_{m-1}-1} S(k)e^{\frac{j2\pi kn}{N}} \tag{5.9}$$

$p = 1, 2, \dots, N_{m-1} - N_M$ ve $n = 0, 1, \dots, N-1$ değerleri için Eşitlik (5.9) üzerinden aranır (Kızılkaya ve Elbi 2023). Eşitlik (5.9) *p.* iterasyondaki THFD işlemini temsil eder. Aynı zamanda $a_m^{(p)}(n)$ ve $\phi_m^{(p)}(n)$ ifadeleri de ilgili anlık genlik ve anlık faz değişkenlerine karşılık gelir. Kizilkaya ve Elbi (2023)'de tanıtıldığı gibi, her iterasyondaki THFD katsayıları *N* noktalı ters hızlı Fourier dönüşümü (THFD) metodu kullanılarak işlem yükü açısından verimli bir şekilde aşağıda verilen adımlar ile hesaplanabilir:

$$\boldsymbol{v}_m^{(p)} = \left[v_m^{(p)}(0), v_m^{(p)}(1), \dots, v_m^{(p)}(N-1)\right] = thfd\left(\boldsymbol{u}_m^{(p)}, N\right), \tag{5.10}$$

Buradaki $\mathbf{u}_m^{(p)}$ ifadesi;

$$\boldsymbol{u}_m^{(p)} = \left[\mathbf{0}_{1\times(N_{m-1}-p)}, 2S(N_{m-1}-p), \dots, 2S(-N_M), \mathbf{0}_{1\times(N-N_{m-1})}\right] \tag{5.11}$$

denklemi ile hesaplanır. $\mathbf{v}_m^{(p)}$ ifadesinin $n = 0, 1, \dots, N-1$ değerleri için anlık fazı temsil eden $\phi_m^{(p)}(n)$ terimi her iterasyondan sonra Eşitlik (5.7)'deki gereksinimi karşılayıp karşılamadığını görmek için değerlendirilir. Kizilkaya ve Elbi (2023)'de gösterildiği gibi

$$\boldsymbol{\epsilon}_m^{(p)} = -Re\left\{\boldsymbol{t}_m^{(p)}\right\} \odot Im\left\{\boldsymbol{v}_m^{(p)}\right\} + Im\left\{\boldsymbol{t}_m^{(p)}\right\} \odot Re\left\{\boldsymbol{v}_m^{(p)}\right\} \geq 0 \qquad (5.12)$$

kriterinin sağlanması $\mathbf{v}_m^{(p)}$ teriminin anlık fazının negatif olmaması garanti etmede yeterlidir. Böylece her n değeri için döngü oluşturmaya gerek yoktur. Burada, $\odot$ operatörü eleman-eleman çarpımı simgeler. $Im\{.\}$ ifadesi sanal kısmı, $\mathbf{t}_m^{(p)}$ terimi de $\mathbf{v}_m^{(p)}$ 'nin Eşitlik (5.10)'dan elde edilen elemanlarından üretilen $\mathbf{t}_m^{(p)} = \left[v_m^{(p)}(1), v_m^{(p)}(2), \dots, v_m^{(p)}(N-1), v_m^{(p)}(0)\right]$ dizisine karşılık gelir. Eşitlik (5.12)'deki koşulu $m = 1, 2, \dots, M-1$ için sağlayan p değerinin oluşturduğu küme,

$$\Omega_m = \left\{p \in \beta_m : \boldsymbol{\epsilon}_m^{(p)} \geq 0\right\} \qquad (5.13)$$

olmak üzere m. AFTBF'ye ilişkin frekans indeksi $N_m = N_{m-1} - max(\Omega_m)$ ile elde edilir. Bu kümeyi oluşturan p değerleri $\beta_m = \{1, 2, \dots, N_{m-1} - N_M\}$ kümesinin bir elemanı olup; $max(\Omega_m)$, ifadeside Ω_m kümesi içerisindeki maksimum değeri ifade eder. Böylece $m = 1, 2, \dots, M-1$ için $N_m = N_{m-1} - max(\Omega_m)$ ile elde edilen frekans indisleri Eşitlik (5.9)'da yerine konularak sinyalin AFTBF'leri belirlenir. Son olarak, EKG sinyalinin Z-F görüntüsü tüm AFTBF'lerin anlık frekans ve genliği kullanılarak üretilir.

5.2 Kısa Zamanlı Fourier Dönüşümü (KZFD)

FD analizi, bir sinyaldeki belirgin yerel özelliklerin aksine, daha çok küresel bilgilerin ortalamasını açığa çıkarır. Bu sınırlama nedeniyle zamanla değişen işaretlerin analizinde FD analizi yetersiz kalır. Doğası gereği durağan olmayan biyolojik işaretlerin spektral bileşenlerini belirlemek için KZFD önerilmiştir. KZFD ile analiz edilen sinyal sabit uzunlukta kayan bir zaman penceresi kullanarak, (örtüşen veya örtüşmeyen) dar zaman pencerelerine bölünür ve her bir zaman penceresinin FD'si hesaplanır. Elde edilen her bir pencereye ait spektrumların artarda dizilmesiyle Z-F gösterimi elde edilir. Analiz edilen sinyal pencere fonksiyonu ile çarpılarak spektrumda ortaya çıkan yan loblar ile gürültünün neden olduğu spektral kaçaklar azaltılır. KZFD'deki pencere fonksiyonunun uzunluğu sinyalin çözünürlüğünü etkiler. Uzun pencereler daha yüksek frekans çözünürlüğü sağlar ancak daha düşük zaman

çözünürlüğü sunar. Benzer şekilde, kısa pencereler ile daha yüksek zaman çözünürlüğüne ulaşılırken daha düşük frekans çözünürlüğünü elde edilir. Ayrıca, pencerelemede kullanılan fonksiyonunun türü ve uzunluğu performansla yakından ilişkili olduğundan uygulamaya göre tercih edilmektedir. Bu doğrultuda herhangi bir N uzunluklu $s(n)$ işaretinin KZFD'si; $0 \leq l \leq N\text{-}1$ ve $1 \leq H \leq N$ sınır koşulları ile aşağıdaki eşitlik üzerinden tanımlanır:

$$\mathrm{X}_{KZFD}(k,l) = \sum_{n=0}^{L-1} s(n+lH)p(n)e^{-j\frac{2\pi}{L}nk} \tag{5.14}$$

Burada $s(n)$ herhangi bir aritmi sınıfa ait EKG sinyalini, $p(n)$ pencere fonksiyonunu, l zaman indeksini, k frekans indeksini, L pencere uzunluğunu, H de zıplama örnek sayısını ifade eder. k frekans indeksi $0 \leq k \leq L/2$ ile sınırlı olup; ardışık pencereler arasındaki örtüşme miktarı $L\text{-}H$ ile belirlenir. Buna ek olarak iki ardışık pencere arasındaki örtüşme miktarının oranı $(L\text{-}H)\ /L$ ile bulunur. Zamanın belirli bir anı olan lH anında, EKG işareti pencere fonksiyonu $p(n)$ ile çarpılır. Bu nedenle Eşitlik (5.14) ile tanımlanan KZFD, $s(n+lH)p(n)$ sinyalinin FD'sine karşılık düşer. KZFD işlemcisi pencere fonksiyonu olan $p(n)$'yi zıplama miktarına göre $s(n)$ sinyali boyunca gezdirerek pencere içine düşen örnekler üzerinden FD'yi hesaplayarak zaman içindeki frekansı ölçer. Elde edilen frekanslar düşey eksen boyunca, zamanlar ise yatay eksen boyunca yerleştirilerek işaretin ısı haritasına benzeyen Z-F gösterimi elde edilir. İlgili işlemin özeti Şekil 5.1'de resmedilmiştir (Jeon ve diğ. 2020).

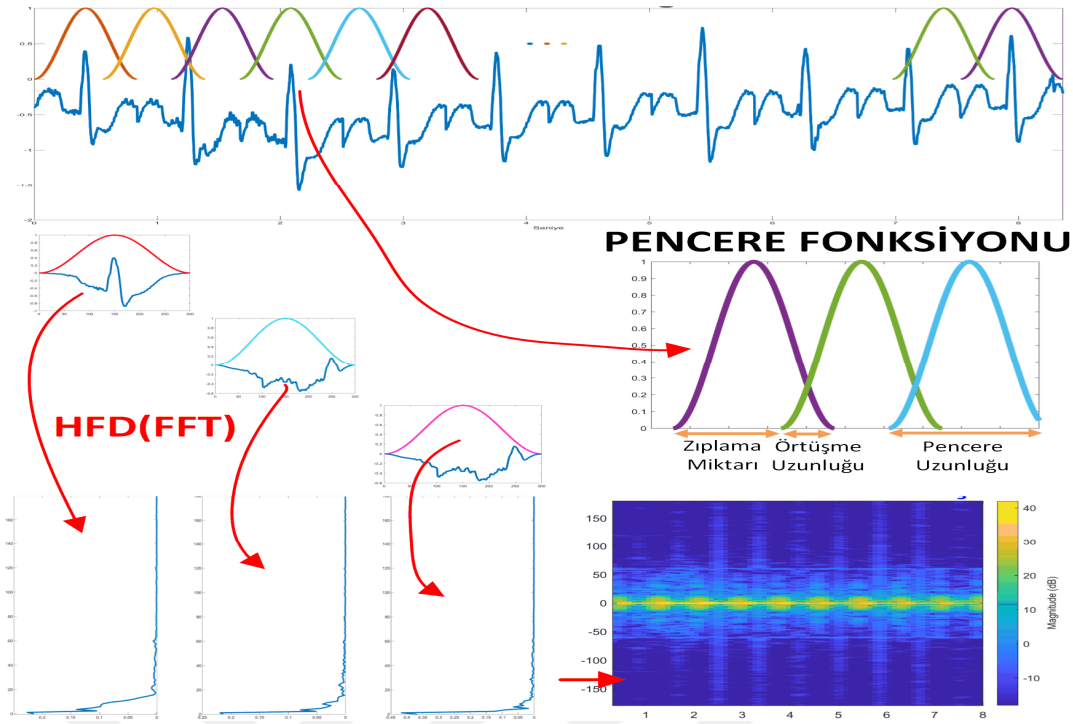

Şekil 5.1: KZFD'nin sistematiği.

5.3 İki-Boyutlu Temel Bileşen Analizi (2BTBA)

Sirovich ve Kirby tarafından ilk olarak insanların yüz resimlerinin temsilinde kullanılan Temel bileşen Analizi (TBA), örüntü tanıma alanında boyut azaltma işleminde kullanılan popüler bir işaret işleme yöntemidir. Temel olarak, birbiriyle ilişkili değişkenlerden oluşan bir dizi gözlemi, doğrusal olarak ilişkisiz değişkenlerden oluşan daha küçük bir kümeye dönüştürmek için dik bir dönüşüm kullanan istatistiksel bir tekniktir. Orijinal veri kümesini TBA alanına taşıyarak, yalnızca en önemli birkaç temel bileşeni koruyarak eğitim sınıfı içerisindeki bilgilerin özünü çıkarmada kullanabilmektedir. Keşfedildiğinde vektörler üzerinde çalışan TBA yöntemi satır ve sütun aritmetiği üzerinden matrislere genişletilmesiyle 2B sürümleri elde edilmiştir. Yapılan çalışmada sütun üzerinden gerçeklenen 2BTBA kullanılmıştır. Bu bağlamda 2BTBA'nın hesaplanması *i.* EKG aritmi sınıfına ait D adet $h \times n$ büyüklüklü $(\mathbf{A}_1, \mathbf{A}_2, \dots, \mathbf{A}_D)$ şeklinde tanımlı öznitelik matrislerin aritmetik ortalamasının:

$$\mathbf{A}_{ortalama} = \frac{1}{\mathrm{D}} \sum_{k=1}^{\mathrm{D}} \mathbf{A}_k \tag{5.15}$$

bulunmasıyla başlanır. Daha sonra, veri kümesindeki öznitelik matrisleri ortalamadan arındırılır. Sıfır ortalamalı öznitelik matrislerinin, sınıf içi kovaryans matrisi,

$$\mathbf{\Phi}_{düşey} = \frac{1}{\mathrm{D}}\sum_{k=1}^{D}(\mathbf{A}_k - \mathbf{A}_{ortalama})^T\,(\mathbf{A}_k - \mathbf{A}_{ortalama}) \tag{5.16}$$

ile hesaplanır. Sınıf içi kovaryans matrisi hesabında, matris sütunundaki değerler, diğer matris sütunundaki değerler ile çarpıldığı için ismine düşey kovaryans matrisi de denir. Hesaplanan $n \times n$ boyutlu kovaryans matrisi özdeğer ve özvektörlerine ayrıştırıldığında n adet özdeğere karşılık n adet özvektör elde edilir. Elde edilen öz değerler içinden en büyük d tanesine karşılık gelen $(\mathbf{p}_l, l = 1,2,\dots,d)$ özvektörler seçilip yan yana dizilerek *i.* aritmi sınıfına ilişkin $(n \times d)$ boyutlu projeksiyon matrisi $\mathbf{P}^{(i)}$ oluşturulur:

$$\mathbf{P}^{(i)} = \begin{bmatrix} \uparrow & \uparrow & \uparrow & \uparrow \\ \mathbf{p}_1 & \mathbf{p}_2 & \cdots & \mathbf{p}_d \\ \downarrow & \downarrow & \downarrow & \downarrow \end{bmatrix} \tag{5.17}$$

$\mathbf{P}^{(i)}$ matrisi kullanılarak *i.* EKG aritmi sınıfının eğitim ya da test kümesindeki veri matrisi $\mathbf{A}_{\mathrm{x}}^{(\mathrm{i})}$'ye ait öznitelik matrisi

$$\mathbf{G}_x = \mathbf{A}_x^{(i)}\mathbf{P}^{(i)} \tag{5.18}$$

doğrusal dönüşümüyle hesaplanır. Bu işlem her bir aritmi sınıfı için tekrar edilir (Yang ve diğ. 2004).

6. SINIFLANDIRMA YÖNTEMİ

Sınıflandırma yöntemleri, makine öğrenmesi ve istatistiksel modelleme alanında kullanılan temel teknikler olup; verileri belirli kategorilere ayırmak için geliştirilmiştir. Sağlık sektöründe, finans alanında, yüz tanımada, nesne algılamada, doğal dil işleme (NLP) uygulamalarında, duygu analizinde ve metin sınıflandırmada olmak üzere geniş bir alanda kullanıma sahiptir (Gülmezoğlu ve diğ. 2001; Kirkbas ve diğ. 2020). Özellikle büyük veri analizinde, karar verme süreçlerini optimize etmede ve otomatik tahmin sistemleri oluşturmada kritik bir rol oynamaktadır. Günümüzde, yapay zekâ ve derin öğrenme tekniklerinin gelişimiyle birlikte sınıflandırma yöntemleri daha karmaşık ve etkili hale gelmiş olup; farklı disiplinlerde yenilikçi çözümler sunmaya devam etmektedir.

Biyomedikal sinyal işleme alanında derin öğrenmenin kullanımı, karmaşık örüntüleri ve zaman serisi verilerini otomatik olarak öğrenerek daha etkin analizler yapılmasını mümkün kılmaktadır. Geleneksel sınıflandırma teknikleri hâlâ birçok problem için etkili çözümler sunarken, derin öğrenme yöntemleri özellikle büyük veri, otomatik öznitelik çıkarımı ve karmaşık veri yapıları üzerinde üstünlük sağlamaktadır. Fakat derin öğrenme yöntemlerinin uygulama alanına göre dikkatlice değerlendirilmesini gerektirir. Bu doğrultuda, yapılan çalışmada, problem bazlı tercih edilen karmaşık hesaplara sahip derin öğrenme yöntemlerinin aksine kullanıcı tarafından belirlenen ayarı olmayan, matematiksel kapalı formda hesaplanabilen, doğrudan matrisler üzerinde çalışan Ortak Matris Yaklaşımı (OMY) yöntemi olarak adlandırılan geleneksel sınıflandırıcı model kullanılmıştır. OMY'nin en büyük üstünlüğü sınırlı veriyle etkili tanıma yapabilmesidir.

6.1 OMY

OMY, örüntünün matris olarak temsil edildiği sınıflandırma problemlerinin çözümünde kullanılan alt uzay tabanlı sınıflandırma yöntemidir. Turhal ve diğ. (2005) tarafından yüz tanıma amacıyla geliştirilmiştir. Günümüze kadar yüz tanıma ve kenar algılama uygulamalarında başarıyla kullanılmıştır (Turhal ve diğ. 2005; Ergin ve diğ. 2015; Işık ve Özkan 2019). Geleneksel yöntemler, sınıf içi varyasyonu modellemek

için çok sayıda örneğe ihtiyaç duyarken; OMY, sınıfın temel özelliklerini daha az veriyle öğrenmeye olanak tanır. Eğitim ve test safhası olarak adlandırılan iki aşamadan oluşan OMY tabanlı sınıflandırma modeli, hiper parametrelere sahip olmadığından validasyon işlemi gerektirmez. Eğitim safhası her örüntü sınıfına ait ortak matrisin (OM) hesaplanmasından oluşur. Test aşamasında, OM'ler referans alınarak bilinmeyen test matrisinin hangi sınıfa ait olduğuna karar verilir (Turhal ve diğ. 2005; Ergin ve diğ. 2015; Işık ve Özkan 2019).

6.1.1 OMY Eğitim Safhası

OMY'nin eğitim süreci örüntü problemine ait her bir sınıfın OM'si ve fark uzaylarının hesaplanması aşamasından oluşur. Buna göre, *i.* EKG aritmi sınıfı içerisindeki *j.* öznitelik matrisi $\mathbf{X}_j^{(i)}$'nin, OM ve fark matrisi olmak üzere iki matrisin toplamından oluştuğu varsayılır.

$$\mathbf{X}_j^{(i)} = \mathbf{X}_{ortak}^{(i)} + \mathbf{X}_{j,fark}^{(i)} \tag{6.1}$$

Burada $\mathbf{X}_{ortak}^{(i)}$, örüntü sınıfındaki değişmeyen ortak özellikleri temsil eden tek bir matrisi tanımlarken; örüntü sınıfı içinde meydana gelen geçici değişiklikler, faz farklılıkları ve ortam gürültüsü gibi istenmeyen çevresel faktörlere ilişkin bilgiler ise fark matrisi bileşeni olarak tanımlanır. Eşitlik (6.1)'in sınıf içindeki tüm öznitelik matrislerine uygulanmasıyla tek bir OM elde edilirken, her bir öznitelik matrisine karşılık farklı fark matrisleri elde edilir (Ergin ve diğ. 2011; Ergin ve diğ. 2015). Bu nedenle, ilgili sınıfı temsil eden OM'nin hesaplanması için tek bir öznitelik matrisine ait fark matrisinin hesaplanması yeterli olacaktır.

Örüntü problemi içindeki herhangi bir sınıfın OM'sini hesaplayabilmek için fark matrisinin içinde bulunduğu farklılık alt uzayını tanımlamak gerekir. Bu doğrultuda, OMY'nin ilk adımında, *i*. sınıfa ait toplam L_i adet EKG işaretine karşılık düşen, $\mathbf{X}_1{}^{(i)}$, $\mathbf{X}_2{}^{(i)}$,…, $\mathbf{X}_{L_i}{}^{(i)}$ ile gösterilen $h \times d$ boyutlu öznitelik matrisleri arasından herhangi birisi referans matris olarak seçilir. Sınıf içindeki öznitelik matrislerinden referans matris çıkartılarak sınıf içi fark matrisleri,

$$\mathbf{Y}_r^{(i)} = \mathbf{X}_{r+1}^{(i)} - \mathbf{X}_1^{(i)},\ r = 1, 2, \dots, L_i - 1, \tag{6.2}$$

eşitliği ile hesaplanır. Elde edilen $\mathbf{Y}_j^{(i)}$ matrisleri *i.* sınıfa ait farklılık alt uzayını geren doğrusal bağımlı matrisleri oluşturur. Bu matrislerin alt uzayı temsil edebilmesi için üzerlerine Gram-Schmidt dikleştirme (GSO) prosedürü uygulanarak doğrusal bağımsız hale getirilir (Ergin ve diğ. 2015; Ergin ve diğ. 2011).

$$\mathbf{Z}_1^{(i)} = \mathbf{Y}_1^{(i)}, \tag{6.3a}$$

$$\mathbf{Z}_k^{(i)} = \mathbf{Y}_k^{(i)} - \sum_{l=1}^{k-1} \left(\langle \mathbf{Y}_k^{(i)}, \mathbf{Z}_l^{(i)} \rangle / \left\| \mathbf{Z}_l^{(i)} \right\|_F^2 \right) \mathbf{Z}_l^{(i)},\ k = 2, 3, \dots, L_i - 1, \tag{6.3b}$$

Burada $\langle \mathbf{Y}_k{}^{(i)}, \mathbf{Z}_l{}^{(i)} \rangle$ifadesi $\mathbf{Y}_k{}^{(i)}$ ve $\mathbf{Z}_l{}^{(i)}$ matrislerinin iç çarpımına karşılık gelir ve $\mathbf{Y}_k{}^{(i)T}\mathbf{Z}_l{}^{(i)}$ işlemiyle elde edilen matrisin ana köşegenindeki elemanlarının toplanmasıyla bulunur. Başka bir ifadeyle iki matrisin iç çarpımı, matrislerin çarpımının izine eşittir. Ayrıca, $\left\| \mathbf{Z}_l{}^{(i)} \right\|_F$ operatörü de matrisin Frobenious normu olup $\langle \mathbf{Z}_l{}^{(i)}, \mathbf{Z}_l{}^{(i)} \rangle$ iç çarpımının karekökünün pozitif değerine eşittir. Eşitlik (6.3) ile elde edilen dik matrisler, Frobenious normlarına bölünerek birim-dik hale dönüştürülür.

$$\mathbf{Q}_r^{(i)} = \mathbf{Z}_r^{(i)} / \left\| \mathbf{Z}_r^{(i)} \right\|_F,\ r = 1, 2, \dots, L_i - 1, \tag{6.4}$$

Elde edilen $\mathbf{Q}_1{}^{(i)}$, $\mathbf{Q}_2{}^{(i)}$, …, $\mathbf{Q}_{L_i-1}{}^{(i)}$ matris kümesi i. sınıfın farklılık alt uzayı $\{\mathbb{D}^{(i)}\}$'yi geren birim-dik taban fonksiyonlarını oluşturur. Sınıf içinden seçilen herhangi bir $\mathbf{X}_j^{(i)}$ öznitelik matrisinin fark matrisi,

$$\mathbf{X}_{j,fark}^{(i)} = \sum_{\mathrm{r}=1}^{L_i-1} \langle \mathbf{X}_j^{(i)}, \mathbf{Q}_r^{(i)} \rangle \mathbf{Q}_r^{(i)}, \tag{6.5}$$

eşitliği yardımıyla hesaplanır. Bu eşitlik *i.* sınıf içerisindeki herhangi bir öznitelik matrisi $\mathbf{X}_j^{(i)}$'nin farklılık alt-uzayı $\mathbb{D}^{(i)}$ üzerine iz düşüme karşı düşer. Öznitelik matrisinden fark matrisinin çıkartılmasıyla *i.* sınıfa ait OM'ye ulaşılır.

$$\mathbf{X}_{ortak}^{(i)} = \mathbf{X}_j^{(i)} - \mathbf{X}_{j,fark}^{(i)}, \tag{6.6}$$

OMY'nin eğitim safhası $i = 1, 2, \dots, K$ olmak üzere, *i.* sınıfın farklılık uzayının$\{\mathbf{Q}_1{}^{(i)}, \mathbf{Q}_2{}^{(i)}, \dots, \mathbf{Q}_{L_i-1}{}^{(i)}\}$ taban fonksiyonları ve $\mathbf{X}_{ortak}^{(i)}$'ın hesaplanmasıyla

tamamlanır. Eğitim safhasında her bir sınıf için elde edilen birim dik taban fonksiyonları ile OM'ler test bölümünde kullanmak üzere saklanır. OMY'nin tek bir sınıf için eğitim süreci Şekil 6.1'de ile özetlenmiştir.

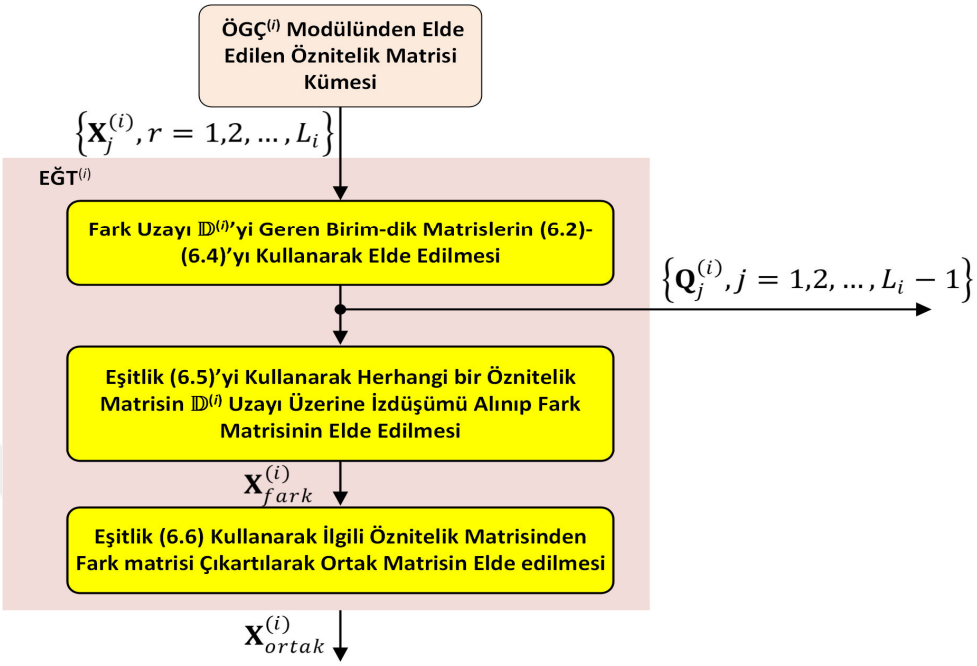

Şekil 6.1: *i*. sınıf için OMY eğitim modülü.

6.1.2 OMY Test Safhası

OMY'nin test safhasında, bilinmeyen EKG sinyaline ait öznitelik görüntüsünü temsil eden $h \times d$ boyutlu test matrisi **T**'nin atanacağı aritmi sınıfına karar verilir. Bunun için, **T** matrisinin *i*. aritmi sınıfının farklılık alt uzayına izdüşümü

$$\mathbf{T}_{fark}^{(i)} = \sum_{j=1}^{L_i-1} \langle \mathbf{T}, \mathbf{Q}_j^{(i)} \rangle \mathbf{Q}_j^{(i)}, \qquad i = 1, 2, \dots, K, \tag{6.7}$$

eşitliği ile hesaplanarak *i*. aritmi sınıfa ilişkin fark matrisine ulaşılır. Test matrisi **T** 'nin $\mathbf{T}_{fark}^{(i)}$ matrisinden çıkartılmasıyla *i.* aritmi sınıfı için **T**'nin OM'si elde edilir:

$$\mathbf{T}_{ortak}^{(i)} = \mathbf{T} - \mathbf{T}_{fark}^{(i)}, \qquad i = 1, 2, \dots, K, \tag{6.8}$$

T matrisi için Eşitlik (6.7) ve (6.8)'deki işlemler $i = 1, 2, \dots, K$ olmak üzere tüm sınıflar için tekrar edilerek K adet OM hesaplanır. Eğitim safhasında elde edilen her bir sınıfın OM'sine olan Frobenius uzaklığı hesaplanır:

$$W^{(i)} = \left\| \mathbf{T}_{ortak}^{(i)} - \mathbf{X}_{ortak}^{(i)} \right\|_F^2, \qquad i = 1, 2, \dots, K, \tag{6.9}$$

Sınıflandırma süreci test matrisi **T**'nin en küçük Frobenius uzaklığını sağlayan sınıfa atanmasıyla tamamlanır.

$$S = \min_{1 \le i \le K} \{W^{(i)}\}, \tag{6.10}$$

OMY ile bilinmeyen test matrisinin ilgili sınıfa atanma işleminin özeti Şekil 6.2'de özetlenmiştir.

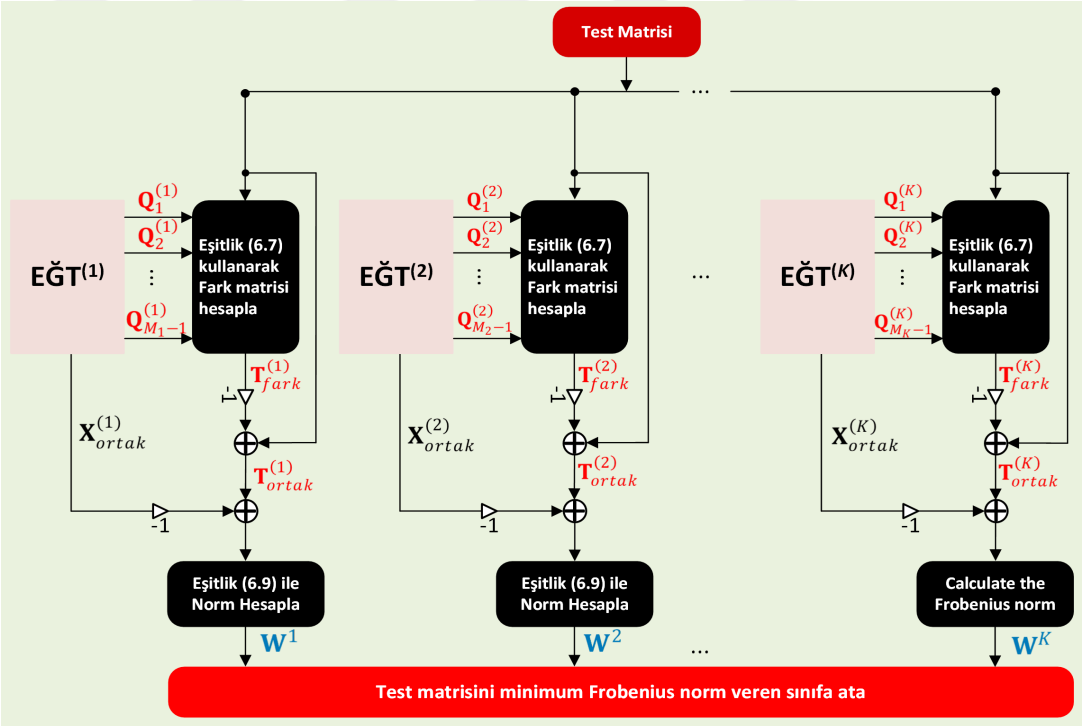

Şekil 6.2: OMY test modülü.

7. ÖNERİLEN EKG ARİTMİ SINIFLANDIRMA YÖNTEMLERİ ve DEĞERLENDİRMELERİ

Yapılan çalışmada, gelişmiş hesaplama teknolojileri kullanarak kardiyak aritmilerin otomatik sınıflandırılması yoluyla manuel tanı koyma maliyetinin azaltılması amaçlanmıştır. Bu amaç doğrultusunda, kullanıcı müdahalelerinden olabildiğince bağımsız çalışabilen yeni öznitelik oluşturma yaklaşımları ile az sayıda veri ile yüksek tanıma yapabilen OMY isimli sınıflandırıcıyı birlikte kullanan yaklaşımlar önerilmiştir. FAY-OMY adı verilen birinci yaklaşımda, OMY sınıflandırıcısına uygulanan öznitelik matrislerinin türetilmesinde ağırlıklı olarak FAY tarafından üretilen Z-F haritalarından oluşan veri matrisleri kullanılmıştır. KZFD-OMY olarak adlandırılan ikinci yaklaşımda OMY girişine uygulanan öznitelik matrisleri, çoğunluğu KZFD ile elde edilen Z-F haritalarından oluşan veri matrislerinden elde edilmiştir. FAY ile elde edilen Z-F haritalarına kırpma işlemi uygulanarak boyutları küçültülürken, KZFD ile elde edilen haritalar olduğu gibi korunarak veri matrisi oluşturma işlemine tabi tutulmuştur. Üzerinde çalışılan özniteliklerin matris olmasından dolayı doğrudan matrisler üzerinde işlem yapabilen OMY tabanlı sınıflandırıcı model benimsenmiştir. Önerilen FAY-OMY ve KZFD-OMY tabanlı EKG aritmi sınıflandırma modellerinin genel yapısı Şekil 7.1'de gösterilmiştir.

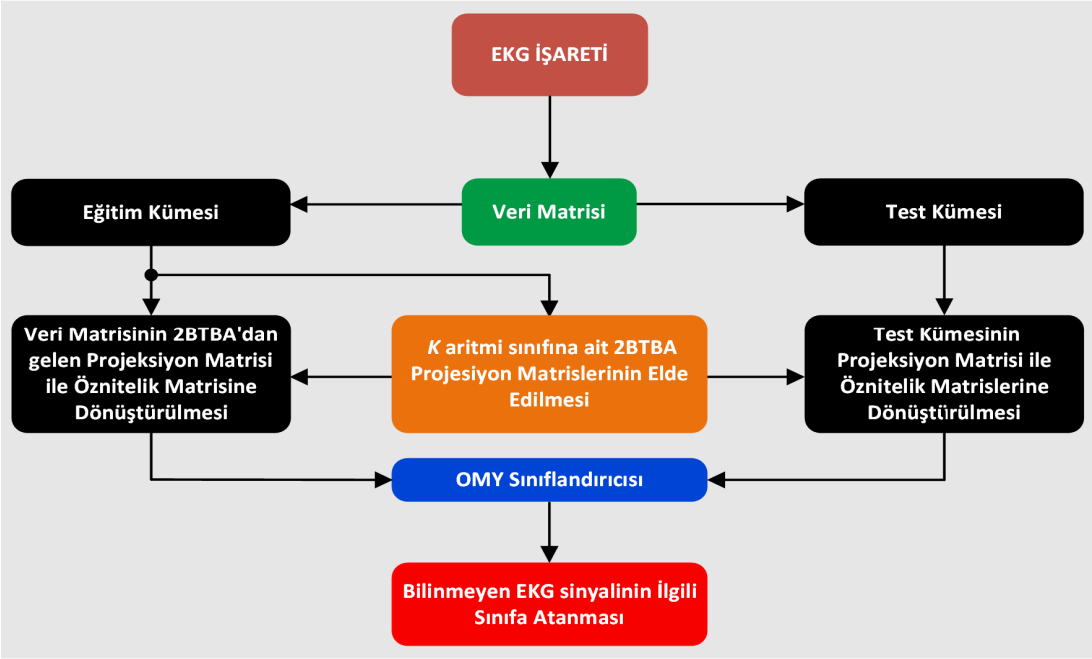

Şekil 7.1: Aritmi sınıflandırması için önerilen yaklaşımların genel yapısı.

7.1 FAY-OMY Yaklaşımında Kullanılan Veri Matrisinin Oluşturulması ve Öznitelik Matrisinin Elde Edilmesi

EKG işaretlerinden kalp aritmilerinin sınıflandırılması amacıyla önerilen FAY-OMY isimli yaklaşımda kullanılan bir EKG işaretine ait veri matrisi, Şekil 7.2'te gösterildiği gibi $\mathbf{DM}_1$, $\mathbf{DM}_2$ ve $\mathbf{DM}_3$ matrislerinin alt-alta konumlandırılmasıyla oluşturulmuştur.

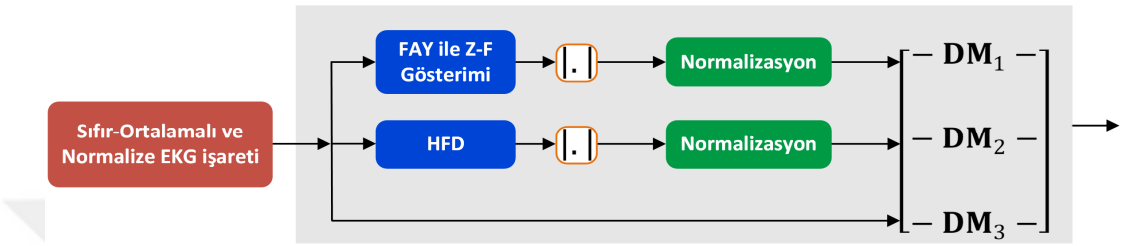

Şekil 7.2: FAY-OMY kapsamında veri matrisi oluşturma modülü.

$\mathbf{DM}_1$ matrisi, sıfır ortalamalı ve normalize edilmiş N uzunluklu EKG sinyaline FAY işlemi uygulanarak elde edilen Z-F temsilinin kırpılmış ve normalize edilmiş versiyonunu ifade eder. $\mathbf{DM}_1$ matrisi oluşturulurken, 0-60 Hz frekans aralığı dışında kalan bölgede ayırt edici bilgi bulunmadığı için bu kısımlar çıkarılarak $60\times N$ boyutunda bir matris olarak bulunur. $\mathbf{DM}_2$ matrisi, sıfır ortalamalı ve normalize edilmiş N uzunluklu EKG sinyalinin AFD katsayılarının mutlak değerlerinin normalize edilmiş formunu içeren $1\times N$ boyutundaki matris olarak tanımlanır. $\mathbf{DM}_3$ matrisi de sıfır ortalamalı ve normalize edilmiş N uzunluklu orijinal EKG verisidir. Üç matrisin alt alta konumlandırılması sonucunda $62\times N$ boyutunda veri matrisi elde edilir. Elde edilen veri matrisinin boyutu incelenen EKG işaretinin uzunluğuna bağlıdır. Bu durum uzun süreli EKG işaretlerinin sınıflandırılması için gereken süreyi artırmakta ve sınıflandırma başarımını ise dramatik olarak azaltmaktadır. O nedenle her bir aritmi sınıfına ilişkin veri matrisleri 2BTBA'ya tabi tutularak elde edilen projeksiyon matrisleri vasıtasıyla, boyutça daha küçük öznitelik matrislerine dönüştürülür (Yang ve diğ. 2004). Şematik gösterimi Şekil 7.3 ile gösterilen öznitelik oluşturma sürecinde 2BTBA'da kullanılan projeksiyon matrisleri, veri matrislerinden Eşitlik (5.16) ile hesaplanan kovaryans matrisinin en büyük d adet özdeğerine karşılık gelen özvektörleri alınarak oluşturulur. Buradaki d değerinin belirlenmesi Ergin ve diğ. (2011) tarafından sunulan çalışmadaki yol izlenerek belirlenmiştir.

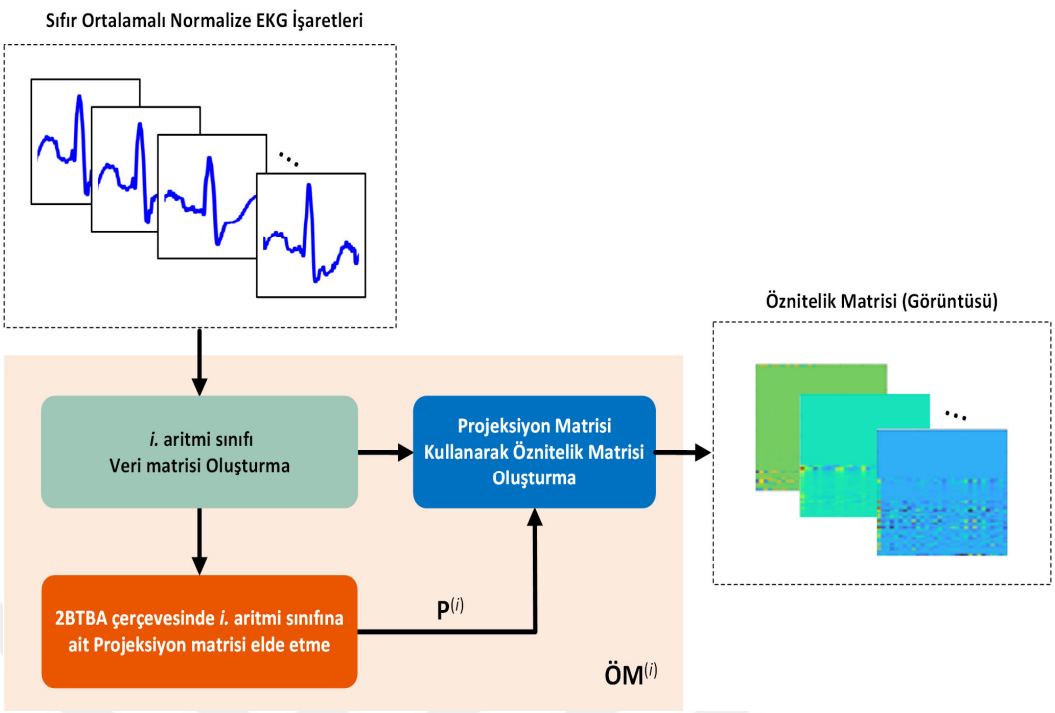

Şekil 7.3: FAY-OMY kapsamında *i.* aritmi sınıfına ilişkin öznitelik matrisinin oluşturulması.

7.1.1 MIT-BIH Veri Tabanını Kullanarak Yapılan Performans Değerlendirmeleri:

Önerilen FAY-OMY tabanlı aritmi sınıflandırma yaklaşımının performansı genel kullanıma açık MIT-BIH veri tababnından sağlanan 6 sınıfa ait aritmi örüntüsü üzerinden yapılan simülasyonlar ile değerlendirilmiştir (Moody ve Mark 2001, Zhang ve diğ. 2020, Wagner 2020). Hasta-içi ve hastalar arası senaryosu altında gerçekleştirilen deneylerde 3.60 GHz hızında çalışan Intel Core i9-9900K CPU ve 32GB RAM'a sahip bir bilgisayar kullanılmıştır.

7.1.1.1 Hasta-içi Senaryosu Temelinde EKG Aritmi Sınıflandırma Performansının Değerlendirilmesi:

Hasta-içi aritmi sınıflandırma senaryosu çerçevesinde detayları Tablo 3.1'de belirtilen MIT-BIH aritmi veri tabanından N, L, R, V ve S aritmi sınıflarının her birinden 1000 EKG işareti, F sınıfından 350 EKG işareti rasgele seçilerek toplamda 5350 EKG işareti ile eğitim kümesi oluşturulmuştur. N, L, R, V, S ve F sınıflarından sırasıyla geriye kalan 73510, 7071, 6255, 6008, 1781 ve 452 EKG işareti ile önerilen yöntem test edilmiştir. Bu doğrultuda her bir aritmi sınıfının eğitim kümesinde bulunan EKG işaretlerine Şekil 7.2'de gösterilen işlemler uygulanarak 62×301 boyutunda veri matrislerine dönüştürülmüştür. Elde edilen veri matrislerinden sırasıyla $d = 20$ ve $d = 30$ seçilerek 62×20 ve 62×30 boyutlarında iki farklı öznitelik matrisleri türetilmiş, sınıflandırma ve performans değerlendirmeleri bu iki farklı boyuttaki öznitelik matrisleri üzerinden gerçekleştirilmiştir.

Tablo 7.1: Hasta-içi senaryosu altında FAY-OMY yönteminin sınıflandırma başarımına ilişkin performans metrikleri.

Veri matrisi	Sınıf	Sen (%) (*Ort±std*)	Spe (%) (*Ort±std*)	Pre (%) (*Ort±std*)	F1-Skor (%) (*Ort±std*)	GD (%) (*Ort±std*)
62×20	N	99,99 (99,98±1,08×10-2)	100,00 (99,99±2,72×10-2)	100,00 (100,00±7,97×10-3)	99,99 (99,99±6,85×10-3)	99,87 (99,87±3,75×10-2)
	L	100,00 (99,98±2,19×10-2)	100,00 (99,99±2,40×10-2)	99,96 (99,84±2,96×10-1)	99,98 (99,91±1,50×10-1)	
	R	100,00 (100,00±4,36×10-3)	99,96 99,92±5,50×10-2	99,49 (98,92±7,60×10-1)	99,74 (99,46±3,85×10-1)	
	V	99,97 (100,00±9,01×10-3)	99,90 (99,96±4,52×10-2)	98,52 (99,43±6,56×10-1)	99,24 (99,71±3,32×10-1)	
	S	100,00 (100,00±5,61×10-3)	100,00 (99,99±5,19×10-3)	99,83 (99,72±2,68×10-1)	99,92 (99,86±1,35×10-1)	
	F	74,56 (77,10±7,72×100)	100,00 (100,00±0,00)	100,00 (100,00±0,00)	85,42 (86,85±4,99×100)	
62×30	N	99,99 (99,98±1,57×10-2)	100,00 (99,99±2,15×10-2)	100,00 (100,00±6,32×10-3)	99,99 (99,99±8,59×10-3)	99,95 (99,94±1,91×10-2)
	L	100,00 (99,98±3,30×10-2)	99,98 (99,99±9,23×10-3)	99,76 (99,92±1,14×10-1)	99,88 (99,95±5,99×10-2)	
	R	100,00 (100,00±1,60×10-3)	99,99 (99,99±1,10×10-2)	99,92 (99,82±1,55×10-1)	99,96 (99,91±7,76×10-2)	
	V	100,00 (100,00±4,54×10-3)	99,98 (99,96±2,19×10-2)	99,67 (99,41±3,20×10-1)	99,83 (99,70±1,62×10-1)	
	S	100,00 (99,98±4,22×10-2)	100,00 (99,99±5,69×10-3)	99,83 (99,71±2,95×10-1)	99,92 (99,84±1,53×10-1)	
	F	92,04 (90,15±2,85×100)	100,00 (100,00±0,00)	100,00 (100,00±0,00)	95,85 (94,80±1,60×100)	

Adil bir sonuç elde etmek için, önerilen FAY-OMY tabanlı sınıflandırma işlemi, Monte Carlo çapraz doğrulamaya (MCÇD) karşılık gelen 100 bağımsız koşturma üzerinden değerlendirilmiştir. Tek bir koşuma dayalı elde edilen performans metrikleri ile MCÇD sonuçlarını karakterize eden ortalama (*ort)* ve standart sapma (*std*) değerleri Tablo 7.1'de paylaşılmıştır. Elde edilen sonuçlar, her program koşumunda rastgele

seçilen 5350 EKG işaretinden elde edilen öznitelik matrisleriyle eğitilen modelin, toplamda 95077 EKG işaretine karşı düşen öznitelik matrisleriyle test edilmesi neticesinde oluşturulan karışıklık matrislerinden hesaplanmıştır. Her bir sınıfa ilişkin Tablonun ilk satırındaki tek koşuma ait performans metriklerinin hesaplandığı karışıklık matrisleri Şekil 7.4'te verilmiştir.

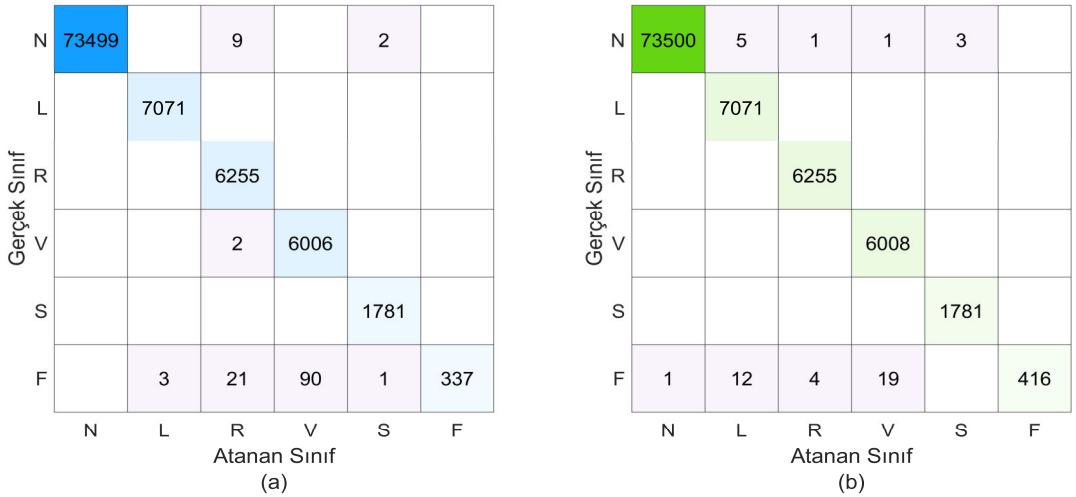

Şekil 7.4: FAY-OMY sınıflandırma modelinin hasta-içi sınıflandırma senaryosu altında eğitilmesi ve test edilmesi neticesinde elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrislerine dayalı sonuçlar, b) 62×30 öznitelik matrislerine dayalı sonuçlar.

Şekil 7.4'ten görüldüğü gibi sınıflandırıcı model 62×20 boyutlu öznitelik matrisleriyle eğitildiğinde N, V ve F sınıflarında sırasıyla 11, 2 ve 115 örneği yanlış teşhis etmiştir. Öznitelik matrisinin boyutlarının 62×30'a yükseltilmesiyle, N ve F sınıfları için sırasıyla 10 ve 36 hatalı atama ile karşılaşılmıştır. İki farklı boyuttaki öznitelik matrisleriyle elde edilen sonuçlardan da anlaşılacağı üzere, hatalı tanınan EKG işaretlerinin çoğunluğu F sınıfına aittir. Bu durum, F sınıfının eğitiminde kullanılan veri sayısının az olmasının sonucudur. Bununla birlikte öznitelik matris boyutunun 62×30'a çıkarılması ile F sınıfı kalp atışlarının sınıflandırma başarımında yaklaşık %17.48'lik bir iyileşme olduğu gözlenmiştir. Ancak N sınıfı için başarımda küçük bir iyileşme olduğu açıktır. Her iki durumda da L, R ve S sınıflarına ait tüm atımlar doğru teşhis edilmiştir. Genel olarak, önerilen sınıflandırıcı model, F sınıfı hariç tüm aritmi sınıfları için kabul edilebilir bir performans sergilemiştir. Şekil 7.4'teki karışıklık matrislerinden hesaplanan performans metriklerinden görüldüğü üzere Sen ve F1-Skor metrikleri dışında, elde edilen bulgular, önerilen yöntemin her iki öznitelik matrisi

boyutunda da birbirine yakın sonuçları verdiğini göstermektedir. Sınıflandırıcı eğitiminde kullanılan F sınıfına ait kalp atışı sayısının son derece az olması nedeniyle, bu iki gösterge değişkendir. Sınıflandırıcı eğitiminde kullanılan aritmi sınıflarında aşırı bir dengesizlik olmadığı sürece, öznitelik matrisi boyutundaki artış sonuçlarda ciddi bir değişikliğe neden olmadığı görülmüştür. Tablo 7.1'de verilen sonuçlarda F sınıfı haricinde, ortalama metriklerin tek koşturmayla elde edilen metriklerle yakından eşleştiği açıkça görülmektedir. Düşük standart sapma değerleri, sınıflandırıcı modelin herhangi bir tek koşturmasının güvenilir sonuçlar verebileceğini göstermektedir. Şekil 7.4 ve Tablo 7.1'deki sonuçlara karşı düşen sınıflandırma süreci için FAY-OMY yönteminin harcadığı toplam süreler Şekil 7.5'te gösterilmiştir. Bu sürelere öznitelik matrislerinin elde edilmesi süreci de dahil edilmiştir.

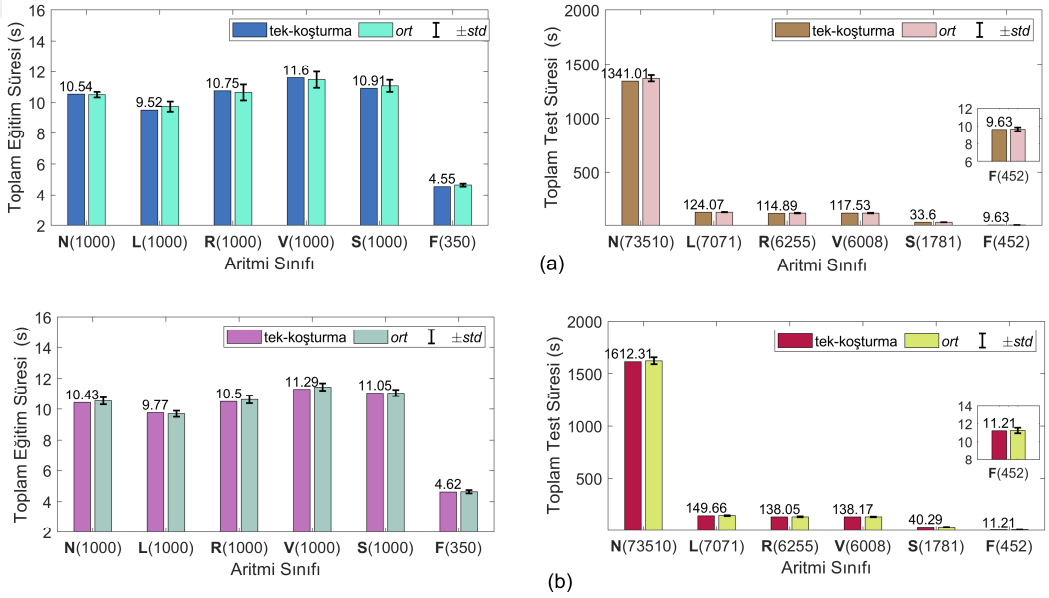

Şekil 7.5: Hasta-içi senaryosu altında MIT-BIH veri tabanından alınan EKG işaretlerinde altı aritmi türünün tespiti için toplam eğitim ve test süreleri: a) 62×20 boyutlu öznitelik matrisi ile elde edilen sonuçlar, b) 62×30 boyutlu öznitelik matrisi ile elde edilen sonuçlar.

Şekil 7.5'teki *ort* ve *std* etiketleri, önerilen yöntemin 100 bağımsız MCÇD koşturması sonucu hesaplanan eğitim ve test sürelerinin aritmetik ortalamaları ve standart sapmalarıdır. Şekil 7.5'e göre önerilen yöntemde 62×20 boyutlarında öznitelik matrisi kullanıldığında N, L, R, V, S ve F aritmi türlerini tanımak için EKG işareti başına sırasıyla 18,24, 17,55, 18,37, 19,56, 18,87 ve 21,31 milisaniyelik ortalama sürelere ihtiyaç duyulur. EKG işaretlerinin 62×30 boyutlu öznitelik matrisiyle sınıflandırılması durumunda elde edilen ortalama süreler işaret başına sırasıyla 21,93, 21,17, 22,07,

23,00, 22,62 ve 24,80 milisaniyedir. Doğal olarak, öznitelik matrisi boyutuyla beraber hesapsal karmaşıklık arttığı için sınıflandırma süreleri de yükselmiştir. Önerilen FAY-OMY tabanlı sınıflandırma yönteminin güncel EKG sınıflandırma yaklaşımlarıyla sınıf bazında karşılaştırması Tablo 7.2'de verilmiştir.

Tablo 7.2: FAY-OMY yaklaşımının hasta-içi senaryosu altında MIT-BIH veri tabanını kullanan güncel EKG sınıflandırma yöntemleri ile karşılaştırılması.

Karşılaştırılan Yöntemler	Örnek Sayısı Eğitim/Test	Sınıf Sayısı	Sınıflar	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
Hassan ve diğ. (2022)	-/17512	5	V	96,33	99,56	94,45	95,38	97,90
			S	80,99	99,53	82,42	81,70	
			F	80,70	99,76	68,66	74,19	
Peng ve diğ. (2022)	300000/21720	5	V	99,22	99,95	99,29	99,25	99,28
			S	96,68	99,63	86,90	91,53	
			F	97,48	99,83	81,15	88,57	
Wang et al. (2023)	70471/30202	4	V	98,48	99,85	98,06	98,27	99,39
			S	91,49	99,84	94,20	92,83	
			F	98,76	99,99	98,76	98,76	
Zhao ve diğ. (2023)	360048/90012	5	V	99,48	99,97	99,89	99,68	99,61
			S	99,37	99,87	99,49	99,43	
			F	99,88	99,87	99,49	99,68	
Zhou ve Wang (2024)	54688/54688	5	V	98,20	99,90	99,10	98,63	99,50
			S	92,40	99,90	95,80	94,08	
			F	99,26	99,99	†98,77	99,01	
Zhou ve Fang (2024)	80490/20140	5	V	99,10	99,94	98,90	99,00	99,60
			S	98,00	99,89	96,60	97,30	
			F	90,68	90,95	94,19	92,40	
Bechinia ve diğ. (2024)	209164/16722	4	V	96,80	-	97,60	97,00	99,22
			S	94,20	-	98,20	96,20	
			F	84,60	-	86,80	85,40	
Islam ve diğ. (2024)	83917/20980	5	V	97,20	99,88	98,41	97,80	99,14
			S	93,49	99,77	92,03	92,75	
			F	83,23	99,87	83,73	83,48	
Peng ve diğ. (2024)	65581/21860	5	V	98,06	99,87	98,19	98,12	99,44
			S	94,69	99,92	97,10	95,88	
			F	86,84	99,87	82,50	84,61	
FAY-OMY (62×20)	**5350/95077**	**6**	**V**	**99,97**	**99,90**	**98,52**	**99,24**	**99,87**
			S	**100,00**	**100,00**	**99,83**	**99,92**	
			F	**74,56**	**100,00**	**100,00**	**85,42**	
FAY-OMY (62×30)	**5350/95077**	**6**	**V**	**100,00**	**99,98**	**99,67**	**99,83**	**99,95**
			S	**100,00**	**100,00**	**99,83**	**99,92**	
			F	**92,04**	**100,00**	**100,00**	**95,85**	

Adil bir karşılaştırma yapmak amacıyla, hasta-içi senaryoyu kullanan ve MIT-BIH veri tabanına dayanan çalışmalar tabloya dahil edilmiştir. Elde edilen karşılaştırmalı sonuçlar, önerilen yöntemin genel doğruluk ve diğer bazı performans ölçütleri açısından mevcut alternatifleri geride bıraktığını ortaya koymaktadır. V ve S sınıfı kalp vuruşlarının sınıflandırılması, ani kalp durmasına neden olabilen kardiyak aritmilerin teşhisi için önemlidir (Allam ve diğ. 2020). Tablo 7.2'de sunulan karşılaştırmalı sonuçlar doğrultusunda, tüm değerlendirme kriterleri açısından önerilen yöntemin S sınıfı için en üstün istatistiksel performansı sergilediği görülmektedir. Şekil 7.4'te sunulan karışıklık matrisi, ilgili değerlendirmeyi

desteklemekte olup, S sınıfına ait tüm örneklerin hatasız bir şekilde sınıflandırıldığını ortaya koymaktadır. Bununla birlikte, bu sınıftaki aritmilerin bazıları Hassan ve diğ. (2022); Peng ve diğ. (2022); Wang ve diğ. (2023); Zhao ve diğ. (2023); Zhou ve Wang (2024); Zhou ve Fang (2024); Bechinia ve diğ. (2024); Islam ve diğ. (2024) ve Peng ve diğ. (2024) tarafından gerçekleştirilen çalışmalarda yer alan karışıklık matrislerinden görüldüğü üzere bu sınıftaki aritmilerin bazıları yanlış olarak teşhis edilmiştir. Peng ve diğ. (2022); Zhao ve diğ. (2023); Zhou ve Wang (2024), Zhou ve Fang (2024), Islam ve diğ. (2024) ve Peng ve diğ. (2024) tarafından gerçekleştirilen çalışmalarda V sınıfı için birkaç metrikte, önerilen FAY-OMY tabanlı yönteme göre küçük bir avantaj sağlasa da karışıklık matrislerine göre bu sınıftaki bazı deneklerin yanlış teşhis edildiği açıktır. Neyse ki önerilen yöntem, Şekil 7.4'te gösterildiği gibi V sınıfının neredeyse tüm örneklerini doğru tespit etmiştir. Bununla birlikte, önerilen yöntemin Sen ve F1-Skor metrik değerleri, F sınıfı aritmileri açısından değerlendirildiğinde, diğer mevcut yöntemlere kıyasla daha düşük seviyede kalmaktadır. Eğitim veri setinde F sınıfına ait kalp atışlarının az sayıda olması nedeniyle, önerilen yöntemin bu sınıfı ayırt etme kapasitesi yetersiz kalmıştır.

7.1.1.2 Hastalar-Arası Senaryo Altında EKG Aritmi Sınıflandırma Performansının Değerlendirilmesi:

Hastalar-arası sınıflandırma senaryosu, eğitim ve test veri kümelerinin tamamen farklı hastalardan elde edilen verilerle oluşturulmasını ifade eder. Böylece, modelin genelleme yeteneği daha gerçekçi bir şekilde test edilir. Hasta-içi senaryoya kıyasla, bu yaklaşım daha zorlu bir test ortamı sunar, çünkü bireysel hasta özellikleri ve sinyal varyasyonları modelin genelleme kapasitesini sınayabilir. Bu nedenle, hastalar-arası sınıflandırma senaryosu, klinik uygulamalarda daha güvenilir ve uygulanabilir modeller geliştirmek için tercih edilir (Xia ve diğ. 2023; Xu ve Xiao 2023). Bu sebeple, yapılan çalışmada önerilen FAY-OMY tabanlı aritmi sınıflandırma modelinin performansı hastalar-arası aritmi sınıflandırma senaryosu altında test edilmiştir. Tablo 3.1'de tanımlanan MIT-BIH veri tabanı tekrar organize edilerek detayları Tablo 7.3 ile verilen DS1 ve DS2 isimli eğitim ve test kümelerine ayrılmıştır. Toplam 50957 örnekten oluşan DS1 kümesinin içinden her bir aritmi sınıfı için 1000

EKG kaydı rasgele seçilerek eğitim kümesi oluşturulmuştur. Diğer taraftan S ve F sınıflarında EKG veri sayısı az olduğu için hepsi eğitim kümesine dahil edilmiştir. OMY tabanlı sınıflandırıcı Şekil 7.3'teki gibi öznitelik çıkarma işlemlerine tabi tutularak 5358 öznitelik matrisi elde edilmiş ve bu öznitelik matrisleri ile modelin eğitimi gerçekleştirilmiştir. Eğitilen model 49470 EKG verisinin yer aldığı DS2 test kümesi üzerinden değerlendirilmiştir.

Tablo 7.3: Hastalar-arası paradigma çerçevesinde eğitim ve test kümelerini oluşturan EKG işaret sayısı ve kayıt numaraları

Veri Kümesi	N	L	R	V	S	F	Veri kayıtları
DS1	1000	1000	1000	1000	944	414	101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205,207, 208, 209, 215, 220, 223, 230
DS2	36426	4124	3475	3220	1837	388	100, 103, 105, 111, 113, 117, 121, 123, 200,202, 210, 212, 213, 214, 219,221, 222, 228, 231, 232, 233, 234

Önerilen aritmi sınıflandırma yönteminin performansı, her koşumda rasgele oluşturulan DS1 eğitim kümesi üzerinden Monte Carlo çapraz doğrulamasına (MCCV) karşılık gelen 100 bağımsız çalıştırma ile doğrulanmıştır. Böylece her seferinde farklı hastadan gelen eğitim kümesi nedeniyle aşırı uyum sorunu aşılmıştır. Tek bir çalıştırma sonucu elde edilen değerlendirme metrikleri ile 100 rastgele çalışma sonucu elde edilen değerlendirme metriklerin ortalama ve standart sapma değerleri Tablo 7.4'te verilmiştir. 62×20 ve 62×30 boyutlarındaki öznitelik matrisleri kullanılarak yapılan 100 bağımsız koşturmayla genel doğruluk oranlarının ortalama ve standart sapma değerleri sırasıyla %99,73 $\pm 1{,}01\times 10^{-3}$ve %99,81 $\pm 5{,}56\times 10^{-4}$ olarak elde edilmiştir. Düşük *std* değerleri, önerilen sınıflandırıcının kararlı çalıştığını ve dolayısıyla tek çalışma sonuçları açısından güvenilir olacağını göstermektedir. Bu bağlamda, her ne kadar Tablo 7.4 iki farklı öznitelik boyutu üzerinden kapsamlı bir sonuç sunsa da okuyuculara fikir vermesi adına tek çalıştırma sonucunda elde edilen karmaşıklık matrisi Şekil 7.6'de paylaşılmıştır. Sınıflandırma işleminde 62×20 boyutlu öznitelik matrisi kullanıldığında, N, L, R, V, S ve F sınıfları için sırasıyla 8, 8, 1, 2, 1 ve 87 adet örnek yanlış sınıfa atanmıştır. Öznitelik matrisi boyutu 62×30'a çıkarıldığında N, L ve F sınıfları için sırasıyla 36, 1 ve 58 test deneğinin sınıflandırılması kaçırılmış fakat R, V ve S sınıflarının tüm kalp atışları doğru tespit edilmiştir. Hasta-içi senaryo durumunda olduğu gibi, yanlış sınıflandırmalar F

sınıfında yoğunlaşmıştır.

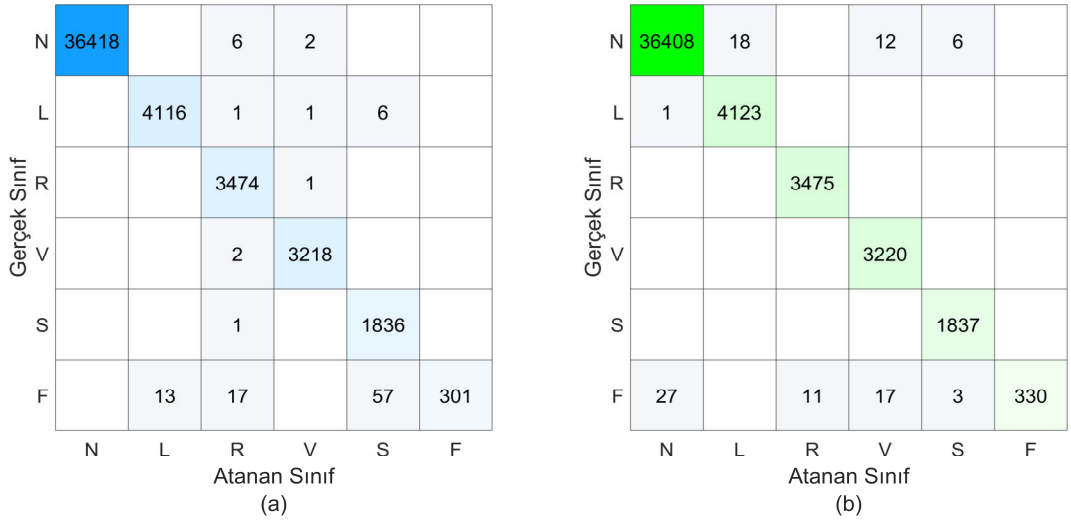

Şekil 7.6: FAY-OMY sınıflandırma modelinin hastalar-arası sınıflandırma senaryosu altında eğitilmesi ve test edilmesi neticesinde elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrislerine dayalı sonuçlar, b) 62×30 öznitelik matrislerine dayalı sonuçlar.

Öznitelik matrisi boyutunun sadece F sınıfına ilişkin sınıflandırma etkilediği görülmektedir. 62×30 boyutlu öznitelik matrisiyle F sınıfı örneklerinin doğru tespitinde yaklaşık %7.47'lik bir iyileşme olduğu gözlemlenirken; F1 metriğinde %3'lük yükselme ve Sen metriğinde yaklaşık %5'lik iyileşme olduğu aşikardır.

Tablo 7.4: Hastalar-arası senaryosunda önerilen yöntemin tek koşturmasıyla elde edilen performans metrikleri.

Öznitelik Boyutu	Sınıf	Sen (%) (*Ort±std*)	Spe (%) (*Ort±std*)	Pre (%) (*Ort ±std*)	F1-Skor (%) (*Ort ±std*)	GD (%)
62×20	N	99,98 (99,95±2,65×10-2)	100,00 (99,85±3,53×10-1)	100,00 (99,95±1,26×10-1)	99,99 (99,95±6,45×10-2)	99,78 (99,73±1,01×10-1)
	L	99,81 (99,28±1,14×100)	99,97 (100,0±3,14×10-3	99,69 (99,9±3,45×10-2)	99,75 (99,63±5,78×10-1)	
	R	99,97 (99,98±1,36×10-2)	99,94 (99,93±5,39×10-2)	99,23 99,12±6,91×10-1	99,60 (99,55±3,51×10-1)	
	V	99,94 (99,96±2,63×10-2)	99,99 (99,97±5,93×10-2)	99,88 (99,55±8,17×10-1)	99,91 (99,75±4,17×10-1)	
	S	99,95 (99,98±2,98×10-2)	99,87 (99,86±3,86×10-2)	96,68 (96,60±9,35×10-1)	98,29 (98,26±4,83×10-1)	
	F	77,58 (79,65±4,48×100)	100,00 (100,0±0,00)	100,00 (100,0±0,00)	87,37 (88,60±3,03×100)	
62×30	N	99,95 (99,92±5,94×10-2)	99,79 (99,96±8,95×10-2)	99,92 (99,99±3,07×10-2)	99,94 (99,95±2,92×10-2)	99,84 (99,81±5,56×10-2)
	L	99,98 (99,95±1,46×10-1)	100,00 (100,00±2,21×10-3)	100,00 (99,98±2,43×10-2)	99,99 (99,97±7,64×10-2)	
	R	100,00 (99,93±1,27×10-1)	99,98 (99,99±5,85×10-3)	99,68 (99,91±7,73×10-2)	99,84 (99,92±6,95×10-2)	
	V	100,00 (100,00±0,00)	99,94 (99,84±6,62×10-2)	99,11 (97,72±9,03×10-1)	99,55 (98,85±4,63×10-1)	
	S	100,00 (99,99±2,33×10-2)	99,98 (99,98±1,11×10-2)	99,51 (99,48±2,82×10-1)	99,76 (99,73±1,42×10-1)	
	F	85,05 (84,42±4,44×100)	100,00 (100,00±0,00)	100,00 (100,00±0,00)	91,92 (91,49±2,67×100)	

Şekil 7.6'daki bulgulara göre, F sınıfı hariç tüm sınıflardaki aritmiler, her iki özellik matrisi boyutunda (62×20 ve 62×30) neredeyse kusursuz bir şekilde sınıflandırılabilmiştir. %99'un üzerindeki ortalama Sen ve Spe değerleri bunun bir göstergesi olup genel doğruluk oranları da bu çıkarımları desteklemektedir. Önerilen yöntem dahilinde MIT-BIH veri tabanından altı aritmiyi sınıflandırmak için harcanan zamanın sınıf bazında öznitelik boyutuna bağlı değişimi Şekil 7.7'de verilmiştir. Paylaşılan sürelere öznitelik çıkarma işlemi dahil olup her aritmi sınıfı için 100 rastgele çalıştırmada zaman tüketiminin ortalama değerleri, tek çalıştırmada harcanan süreyle benzerdir. Şekil 7.7'ye göre, 62×20 boyutlu öznitelik matrisleri ile N, L, R, V, S ve F aritmi türlerini tanımlamak için işaret başına ortalama 21,15, 19,43, 21,55, 22,13, 21,75 ve 25,32 milisaniye sürelere ihtiyaç duyulduğu görülmektedir. 62×30 boyutuna çıkıldığında ise ortalama süreler sırasıyla 22,20, 20,68, 22,71, 23,08, 22,83 ve 26,16 milisaniye tespit edilmiştir. Beklenildiği gibi boyut artışıyla beraber hesap sürelerinde küçük de olsa artışlar olmuştur.

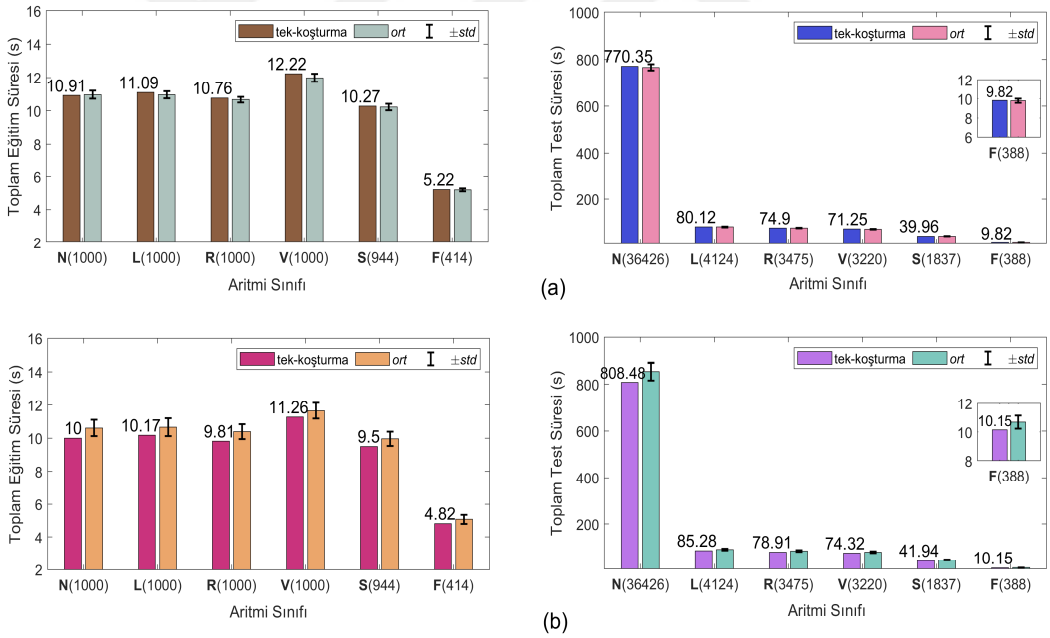

Şekil 7.7: FAY-OMY sınıflandırma modelinin Hastalar-arası senaryosu altında MIT-BIH veri tabanından alınan EKG işaretlerinde altı aritmi türünün tespiti için harcanan toplam eğitim ve test süreleri: a) 62×20 öznitelik matrisi ile elde edilen sonuçlar, b) 62×30 öznitelik matrisi ile elde edilen sonuçlar.

Önerilen FAY-OMY tabanlı yöntemin V, S ve F sınıfları için sınıflandırma performansı, mevcut EKG sınıflandırma teknikleriyle karşılaştırılmış olup karşılaştırma sonuçları Tablo 7.5'te verilmiştir. Bu tabloya göre önerilen yöntem,

genel doğruluk açısından en yüksek orana sahip olduğu görülmektedir. V ve S sınıfı aritmilerin doğru bir şekilde tespit edilmesi, ani kalp durmasına yol açabilen aritmilerin teşhisinde kritik bir rol oynamaktadır. Bu bağlamda, önerilen yöntem, tüm değerlendirme metriklerinde V ve S sınıfları için en yüksek sınıflandırma başarımını göstermiştir. Bu gözlem, Şekil 7.6'daki tahmin sonuçlarıyla da desteklenmektedir. Bununla birlikte, Li ve diğ. (2022) ve Zhou ve Fang (2023) ile karşılaştırıldığında, önerilen yöntem F sınıfı için daha düşük Sen ve F1-Skor sonucu üretmiştir.

Tablo 7.5: FAY-OMY yaklaşımının hastalar-arası senaryosu altında MIT-BIH veri tabanını kullanan güncel EKG sınıflandırma yöntemleri ile karşılaştırılması

Karşılaştırılan Yöntemler	Örnek Sayısı/Eğitim/Test	Sınıf Sayısı	Sınıflar	Sen (%)	Spe (%)	Pre (%)	F1-Skor. (%)	GD (%)
Zhou ve Fang (2024)	51013/41472	5	V	97,60	99,80	97,60	97,60	98,80
			S	81,50	99,80	94,90	87,70	
			F	100,00	99,99	98,97	99,48	
Xu ve diğ. (2023)	51013/49705	4	V	93,45	99,56	93,59	93,52	96,15
			S	76,21	98,14	62,70	68,80	
			F	2,58	99,92	20,83	4,59	
Xia ve diğ. (2023)	50928/49646	5	V	73,92	97,98	71,67	72,78	94,16
			S	70,26	99,44	82,90	76,06	
			F	13,40	99,76	30,41	18,60	
Zhou ve diğ. (2024) (Artırılmış DS1)	66354/49661	4	V	93,32	99,46	92,26	92,79	95,60
			S	89,32	97,05	53,77	67,13	
			F	†0,00	100,00	0,00	NaN	
Xia ve diğ. (2023)	50969/49661	4	V	72,26	99,69	94,09	81,74	92,81
			S	27,12	97,83	32,44	29,55	
			F	6,70	99,11	5,58	6,09	
Li ve diğ. (2022)	13719/7942	5	V	88,35	94,93	79,82	83,87	89,00
			S	35,22	98,83	65,88	45,94	
			F	42,37	99,22	49,50	45,66	
Liu ve diğ. (2024)	50815/49507	4	V	91,43	99,41	91,46	91,44	96,60
			S	85,64	98,20	64,58	73,63	
			F	65,46	99,22	75,60	70,17	
Fatimah ve diğ. (2024)	50999/49690	5	V	91,06	99,14	88,03	89,52	98,01
			S	83,44	99,86	95,69	89,15	
			F	0,00	99,92	0,00	NaN	
Jangra ve diğ. (2023)	69876/30713	4	V	95,96	99,68	94,54	95,24	98,86
			S	92,94	99,63	87,31	90,04	
			F	75,82	99,92	92,62	83,38	
Li ve diğ. (2022)	50943/49600	5	V	99,97	99,96	99,38	99,67	99,62
			S	99,56	99,68	92,23	95,75	
			F	93,81	100,00	100,00	96,81	
Xu ve diğ. (2022)	110844/49661	4	V	93,46	99,31	90,04	91,72	97,50
			S	83,06	99,32	82,48	82,77	
			F	37,89	100,00	99,32	54,85	
FAY-OMY (62×20)	**5358/49470**	**6**	**V**	**99,94**	**99,99**	**99,88**	**99,91**	**99,78**
			S	**99,95**	**99,87**	**96,68**	**98,29**	
			F	**77,58**	**100,00**	**100,00**	**87,37**	
FAY-OMY (62×30)	**5358/49470**	**6**	**V**	**100,00**	**99,94**	**99,11**	**99,55**	**99,84**
			S	**100,00**	**99,98**	**99,51**	**99,76**	
			F	**85,05**	**100,00**	**100,00**	**91,92**	

7.1.2 Chapman Veri Tabanını Kullanılarak Yapılan Deneylerin Performans Değerlendirmeleri

FAY-OMY tabanlı sınıflandırma yaklaşımının EKG aritmilerini sınıflandırmasındaki genelleme yeteneğini kanıtlamak amacıyla Chapman veri tabanından temin edilen gürültülü ve gürültüsüz EKG işaretleri üzerinden deneyler gerçekleştirilmiştir. Chapman veri tabanındaki tüm kayıtlar farklı bireylere ait olduğu için çalışmalarda hastalar-arası sınıflandırma senaryosu benimsenmiştir. MIT-BIH veri tabanı üzerinde yapılan çalışmaların aksine, EKG işaretleri üzerinde gerçekleştirilen bölütleme işlemi atlanarak işaretler bütün olarak ele alınmıştır. Şekil 7.3'teki öznitelik matrisi elde etme işlemi doğrudan SB, GSVT, AFIB ve SR aritmi sınıflarına ait 10 saniye uzunluklu EKG işaretleri üzerinde gerçekleştirilmiştir. Bu bağlamda EKG işaretlerine Bölüm 7.1'de anlatılan işlemler uygulanarak 62×5000 boyutlu veri matrisleri elde edilmiştir. Veri matrislerine 2BTBA uygulanarak 62×20 ve 62×30 boyutlarındaki öznitelik matrislerine ulaşılmıştır. Sınıflandırma işlemleri MIT-BIH veri tabanıyla yapılan deneylerde olduğu gibi 62×20 ve 62×30 boyutlu öznitelik matrisleri üzerinden gerçekleştirilmiştir.

7.1.2.1 Gürültülü EKG Kayıtlarıyla Yapılan Deneyler

FAY-OMY tabanlı sınıflandırıcı modeli, detayları Tablo 3.2'de Chapman veri tabanında yer alan SB, GSVT, AFIB ve SR sınıflarından rastgele seçilen 1000 EKG kaydı ile eğitilmiş ve kalan kayıtlar üzerinde test edilerek doğrulanmıştır. Modelin sınıflandırma performansı, 62×20 ve 62×30 boyutlu öznitelik matrisleri kullanılarak değerlendirilmiş olup, elde edilen sonuçlar Şekil 7.8'de verilmiştir. Bu sonuçlara göre, FAY-OMY tabanlı modelin 62×20 boyutlu öznitelik matrisleriyle daha yüksek sınıflandırma performansı sergilediği görülmektedir. Spesifik olarak, tüm sınıflar dikkate alındığında, toplam 6646 EKG kaydının yalnızca 28'i yanlış sınıflandırılmıştır.

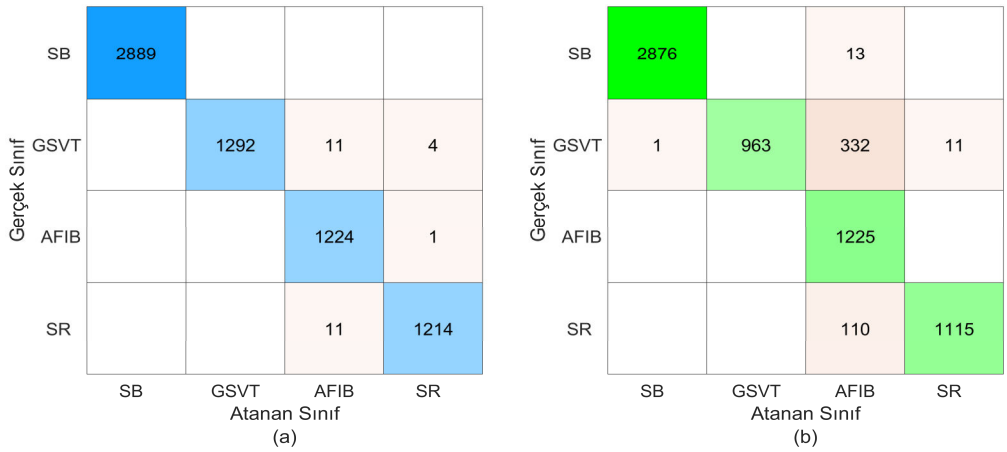

Şekil 7.8: Chapman veri tabanındaki ham (gürültülü) EKG kayıtları kullanılarak elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrisleri ile elde edilen sonuçlar, b) 62×30 öznitelik matrisleri ile elde edilen sonuçlar.

Buna karşılık, 62×30 boyutlu öznitelik matrislerinin kullanıldığı durumda 467 kayıt hatalı sınıfa atanmıştır. Elde edilen bulgular doğrultusunda, 62×20 ve 62×30 boyutlu öznitelik matrisleri için sırasıyla %99,58 ve %93,00 genel doğruluk oranları elde edilmiştir. Gürültülü EKG kayıtlarına ilişkin veri matrislerine 2BTBA uygulanması sonucunda, 62×20 boyutlu öznitelik matrisleri 62×30 olanlara nazaran daha az gürültüye sahiptir. 62×20 öznitelik görüntülerinin sağladığı daha iyi performans, gürültünün azaltılmış etkisinden kaynaklanan artan ayırt edilebilirlikle açıklanabilir. Bu sonuçlar Tablo 7.6'da hesaplanan performans ölçütleriyle de tutarlıdır. 62×20 öznitelik matrisleri için hesaplanan Sen, Spe, Pre ve F1-Skor metrikleri sırasıyla %99,45, %99,87, %99,44 ve %99,44 olarak bulunurken, 62×30 öznitelik matrisleri için sırasıyla %91,10, %97,85, %93,00 ve %90,99 olarak elde edilmiştir.

Tablo 7.6: Chapman veri tabanından sağlanan gürültülü (ham) EKG işaretlerinin sınıflandırılmasına ilişkin performans metrikleri

Öznitelik Boyutu	Sınıf	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
62×20	SB	100,00	100,00	100,00	100,00	99,58
	GSVT	98,85	99,98	99,92	99,38	
	AFIB	99,92	99,59	98,23	99,07	
	SR	99,02	99,91	99,59	99,30	
62×30	SB	99,55	99,97	99,97	99,76	93,00
	GSVT	73,91	100,00	100,00	85,00	
	AFIB	100,00	91,64	73,00	84,40	
	SR	90,94	99,80	99,02	94,81	

7.1.2.2 Gürültüsüz EKG Kayıtlarıyla Yapılan Deneyler

Önerilen sınıflandırıcı modeli, ayrıntıları Tablo 3.2'de verilen Chapman veri tabanından temin edilen gürültüsü temizlenmiş SB, GSVT, AFIB ve SR aritmi sınıflarının her birinden rasgele seçilen 1000 EKG işareti ile eğitilmiş kalan kayıtlar ile test edilmiştir. GSVT sınıfına ait 40 adet kayıt filtreleme işlemlerinde bozulduğundan dolayı veri tabanından çıkartılmıştır. Bu nedenle, eğitilen model 6606 EKG kaydı üzerinden değerlendirilmiştir. Bu doğrultuda her bir aritmi sınıfı için eğitim kümesini oluşturulan EKG işaretlerinin her biri Şekil 7.3'te verilen öznitelik matrisi oluşturma bloğundan geçirilerek 62×20 ve 62×30 boyutunda öznitelik matrislerine dönüştürülmüştür.

Şekil 7.9: Chapman veri tabanından alınan gürültüden arındırılmış EKG işaretleri kullanılarak elde edilen karışıklık matrisleri: a) 62×20 öznitelik matrisleriyle elde edilen sonuçlar, b) 62×30 öznitelik matrisleriyle elde edilen sonuçlar.

Önerilen FAY-OMY yönteminin 62×20 ve 62×30 öznitelik matrisleriyle elde edilen sınıflandırma sonuçları Şekil 7.10'da gösterilmiştir. Şekil 7.9'dan görüldüğü üzere, OMY-FAY yöntemi 62×30 boyutlu öznitelik matrisleriyle daha yüksek tanıma performansı sergilemiştir. 6606 EKG kaydından sadece 63'ü yanlış sınıfa atanmıştır. Diğer taraftan, 62×20 boyutlu öznitelik matrisleri kullanıldığında toplamda 2724 adet denek yanlış sınıfa atanmıştır. Bu bulgulara göre 62×20 ve 62×30 boyutlu öznitelik matrisleri için sırasıyla %58,76 ve %99,05 genel doğruluk oranı elde edilmiştir. Gürültüsü arındırılmış EKG verileriyle yapılan 4 sınıflı aritmi sınıflandırma çalışmasında 62×30 boyutlu öznitelik matrisleriyle gerçekleştirilen deneylerde daha

başarılı sonuçlar alınmıştır. Çünkü gürültü giderme işlemi esnasında ayırt edici bilgiler yok edilmiş ya da uzun süreli işaretlerin önemli bilgileri 2BTBA ile öznitelik matrisi elde etmede elenmiştir. Sınıflandırma sonuçları Tablo 7.7'de verilen performans metrikleri ile tutarlıdır. Bu tabloya göre 62×20 öznitelik matrisleri ile yapılan çalışmada elde edilen Sen, Spe, Pre ve F1-Skor metrikleri sırasıyla %70,37, %87,25, %81,62 ve %65,17 olarak hesaplanırken, 62×30 öznitelik matrisleri için sırasıyla %98,85, %99,70, %98,79 ve %98,80 olarak elde edilmiştir.

Tablo 7.7: Chapman veri tabanından alınan gürültüsüz işaretlerin sınıflandırılması ile ilgili performans metrikleri

Öznitelik Boyutu	Sınıf	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
62×20	SB	23,57	99,97	99,85	38,14	58,76
	GSVT	99,29	49,88	31,98	48,38	
	AFIB	90,94	100,00	100,00	95,25	
	SR	67,67	99,13	94,63	78,91	
62×30	SB	99,69	99,95	99,93	99,81	99,05
	GSVT	96,05	99,98	99,92	97,95	
	AFIB	100,00	98,9	95,4	97,65	
	SR	99,67	99,98	99,92	99,8	

Tablo 7.7'deki sonuçlar, 62×20'lik öznitelik matrisleri ile GSVT sınıfı, en düşük Spe ve Pre metriklerine ulaşıldığı göstermektedir. Bu durum diğer sınıflardaki hatalı sınıflandırılmış kayıtların neredeyse tamamının GSVT sınıfına atandığı anlamına gelmektedir. Öznitelik matrisinin 62×30'a yükseltilmesi, GSVT sınıfının Spe ve Pre metriklerinde önemli bir artışa neden olurken; AFIB sınıfının Spe ve Pre metriklerinde küçük bir düşüşe neden olmuştur. Bu sonuç diğer sınıflardaki hatalı sınıflandırılmış kayıtların neredeyse tamamının AFIB sınıfına atandığı anlamına gelmektedir. Gürültülü ve gürültüsüz EKG kayıtlarına ait dört tip aritmiyi sınıflandırmak için harcanan zaman, Şekil 7.10'da gösterilmiştir. Bu sürelere öznitelik çıkarma için gereken sürenin de dahil olduğunu belirtmekte fayda vardır. Şekil 7.10'a göre, gürültülü EKG kayıtlarıyla 62×20 öznitelik matrisleri üzerinden yapılan sınıflandırma işleminde SB, GSVT, AFIB ve SR sınıflarındaki örnek başına sırasıyla 2,36, 2,26, 2,38 ve 2,09 saniyelik sürede tamamlanmıştır. 62×30 öznitelik matrisleri üzerinden bu süreler örnek başına sırasıyla 2,13, 2,30, 2,40 ve 2,12 saniye olarak kaydedilmiştir. Gürültüsüz EKG kayıtları üzerinden 62×20 öznitelik matrisleri kullanarak yapılan çalışmalarda SB, GSVT, AFIB ve SR aritmi sınıflarına ait EKG örneklerini tanımak için sırasıyla 0,40, 0,60, 0,55 ve 0,38 saniyelik ortalama süreler ihtiyaç duyulmuştur.

62×30'luk öznitelik matrisleri ile sınıflandırma işlemi EKG örneği başına 0,42, 0,63, 0,58 ve 0,41 saniyede tamamlanmıştır.

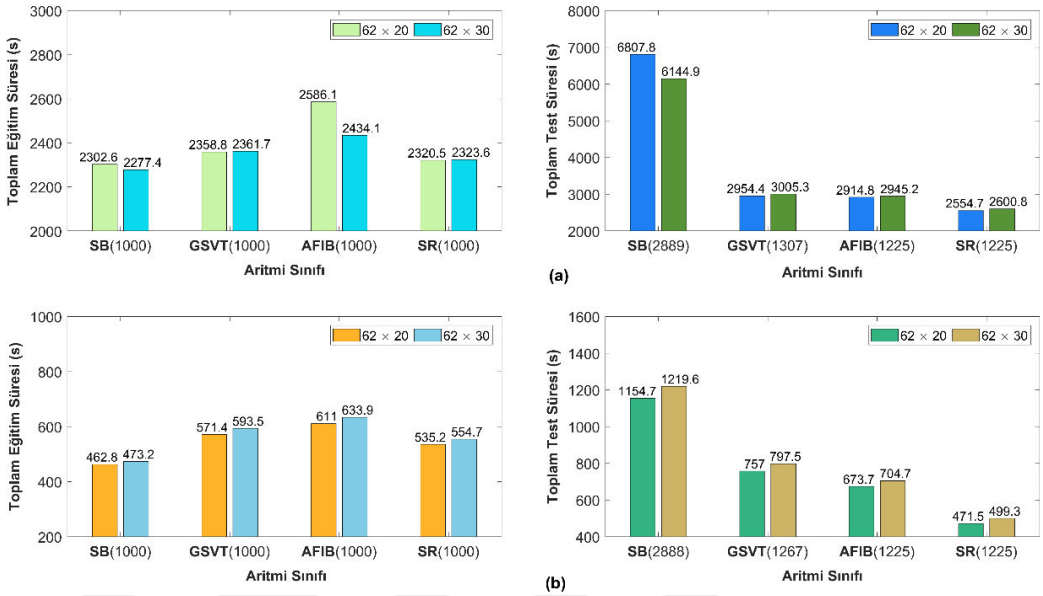

Şekil 7.10: Chapman veri tabanından alınan EKG verileri ile yapılan sınıflandırma işlemi için harcanan toplam eğitim ve test süreleri: a) Gürültü işaretler b) Gürültüsüz işaretler.

Bu sonuçlardan da anlaşılacağı üzere, her iki tür EKG kaydı için format, miktar ve yöntem aynı olsa bile, gürültüsü giderilmiş EKG kayıtlarıyla önerilen yöntemin eğitilmesi ve test edilmesi gürültülü kayıtlara göre daha az zaman almaktadır. Bu beklenen bir sonuçtur. Çünkü gürültülü EKG kayıtları, gürültüden arındırılmış EKG kayıtlarına nazaran çok sayıda farklı frekans bandına sahiptir. Dolayısıyla EKG işaretlerinin FAY tarafından analizi uzamaktadır.

FAY-OMY tabanlı sınıflandırma yönteminin SB, GSVT, AFIB ve SR aritmi sınıfları için sınıflandırma başarımı, güncel EKG sınıflandırma yöntemleriyle Tablo 7.8'te karşılaştırılmıştır. Bu tabloya göre FAY-OMY yönteminin, tüm metrikler açısından en yüksek orana sahip olduğu görülmektedir. Karşılaştırılan yöntemlerin aksine önerilen sınıflandırma yöntemi, eğitimde az veri kullanarak yüksek başarım sonuçları sergilemiştir. Böylece test kısmında daha fazla veri ile sınama yapılması performans değerlendirmesi açısından daha değerlidir.

Tablo 7.8: Chapman veri tabanından alınan EKG işaretlerini kullanan sınıflandırma yöntemleri ile FAY-OMY yönteminin karşılaştırması.

Karşılaştırılan Yöntemler	Örnek Sayısı/Eğitim/Test	Sınıflar	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
Yildirim ve diğ. (2020)	9529/1059	SB	98,75	98,93	98,25	98,50	96,13
		GSVT	89,94	99,30	96,75	93,22	
		AFIB	96,17	98,30	94,16	95,15	
		SR	96,88	98,32	93,96	95,40	
Lee ve Shin (2024)	8516/2130	SB	97,81	97,93	96,45	97,13	88,83
		GSVT	95,45	91,97	76,70	85,05	
		AFIB	69,21	96,62	84,38	76,05	
		SR	85,84	98,87	95,26	90,31	
Shi ve diğ (2024)	7148/2043	SB	99,06	99,38	98,93	98,99	95,11
		GSVT	92,00	97,77	92,58	92,29	
		AFIB	92,08	97,00	89,45	90,75	
		SR	94,74	99,46	97,56	96,13	
FAY-OMY 62×20 (Gürültülü)	**4000/6646**	**SB**	**100,00**	**100,00**	**100,00**	**100,00**	**99,58**
		GSVT	**98,85**	**99,98**	**99,92**	**99,38**	
		AFIB	**99,92**	**99,59**	**98,23**	**99,07**	
		SR	**99,02**	**99,91**	**99,59**	**99,30**	
FAY-OMY 62×20 (Gürültüsüz)	**4000/6606**	**SB**	**99,69**	**99,95**	**99,93**	**99,81**	**99,05**
		GSVT	**96,05**	**99,98**	**99,92**	**97,95**	
		AFIB	**100,00**	**98,90**	**95,40**	**97,65**	
		SR	**99,67**	**99,98**	**99,92**	**99,80**	

7.1.3 PTB-XL Veri Tabanıyla Yapılan Deneylerin Performans Değerlendirmeleri

FAY-OMY yönteminin farklı EKG aritmi türlerini sınıflandırmasındaki genelleme kabiliyeti PTB-XL veri tabanından alınan EKG işaretleri üzerinden yapılan deneylerle doğrulanmıştır. Bu doğrultuda hastalar-arası aritmi sınıflandırma senaryosu çerçevesinde detayları Tablo 3.3'te belirtilen PTB-XL aritmi veri tabanından NORM, CD, MI ve STTC aritmi sınıflarının her birinin 1. derivasyon kanalından toplanmış 1000 EKG işareti ve HYP sınıfından 350 EKG işareti rasgele seçilerek toplamda 4450 EKG işareti ile eğitim kümesi oluşturulmuştur. NORM, CD, HYP, MI ve STTC sınıflarından sırasıyla geriye kalan 7069, 7071, 708, 85, 1532 ve 1400 EKG işareti ile önerilen yöntem test edilmiştir. Bu doğrultuda her bir aritmi sınıfının eğitim kümesinde bulunan EKG işaretleri Şekil 7.2'de gösterilen işlem adımlarında geçirilerek 62×5000 boyutlu veri matrisine dönüştürülmüştür. Veri matrisleri 2BTBA'ta tabi tutularak $d = 20$ ve $d = 30$ ile 62×20 ve 62×30 boyutlarında iki farklı öznitelik matrisleri türetilmiş, sınıflandırma ve performans değerlendirmeleri bu iki farklı boyuttaki öznitelik matrisleri üzerinden gerçekleştirilerek sınıflandırma sonuçları Şekil 7.11'de verilmiştir. Önerilen yöntem 62×20 boyutlu öznitelik matrisleriyle tüm sınıflar için, 11794 EKG kaydından sadece 175'ni yanlış sınıfa atayarak oldukça yüksek tanıma performansı sergilemiştir.

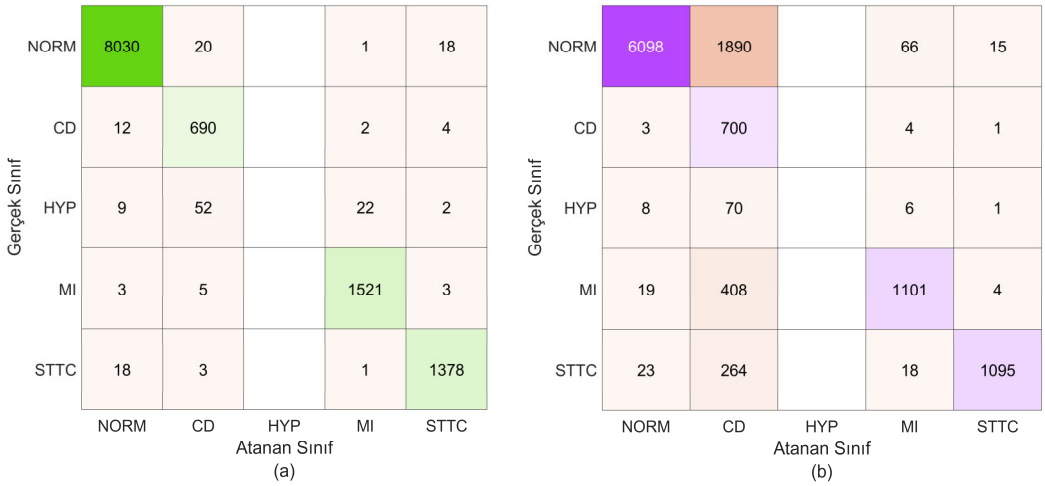

Şekil 7.11: FAY-OMY ile PTB-XL veri tabanından alınan EKG işaretlerinin eğitilmesi ve test edilmesiyle elde edilen karışıklık matrisi sonuçları: a) 62×20'lik öznitelik görüntüleriyle elde edilen sonuçlar, b) 62×30'luk öznitelik görüntüleriyle elde edilen sonuçlar.

Öte yandan, 62×30 boyutlu öznitelik matrisleriyle 2800 denek hatalı sınıflandırılmıştır. Bu bulgulara göre 62×20 ve 62×30 boyutlu öznitelik matrisleri için sırasıyla %98,52 ve %76,26 genel doğruluk oranı elde edilmiştir. Her iki boyuttaki öznitelik matrisleriyle gerçekleştirilen sınıflandırma deneylerinde HYP sınıfına ait işaretler tespit edilememiştir.

Tablo 7.9: PTB-XL veri tabanından alınan gürültülü işaretlerin sınıflandırılmasına ilişkin performans metrikleri

Öznitelik Görüntü Boyutu	Sınıflar	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
62×20	NORM	99,23	99,06	99,56	99,40	98,49
	CD	99,29	99,16	88,32	93,48	
	HYP	0,00	100,00	NaN	NaN	
	MI	99,02	99,62	97,49	98,25	
	STTC	99,21	99,89	99,21	99,21	
62×30	NORM	66,53	99,09	99,37	79,70	69,95
	CD	99,44	70,48	17,70	30,05	
	HYP	0,00	100,00	NaN	NaN	
	MI	70,37	97,92	83,50	76,37	
	STTC	78,57	99,77	97,86	87,16	

Bu durum, PTB-XL veri tabanındaki HYP sınıfına ait kayıt sayısının azlığından kaynaklanmaktadır (Shi ve diğ. 2024). Şekil 7.11'de gösterilen karışıklık matrislerinden hesaplanan performans metrikleri Tablo 7.9'da verilmiştir. Bu tablo FAY-OMY yönteminin 62×20 boyutlu öznitelik matrisleri ile NORM, CD, MI ve STTC aritmi sınıflarını tespit etmede tatmin edici bir performans sergilediğini göstermektedir. Önerilen FAY-OMY yöntemi aynı veri tabanı ve sınıf sayısını

kullanan Shi ve diğ. (2024) tarafından önerilen güncel yaklaşımı performans anlamında geride bırakmıştır. PTB-XL veri tabanından alınan EKG kayıtlarına ilişkin beş tip aritminin sınıflandırılması için harcanan süre, sınıf bazında Şekil 7.12'de verilmiştir.

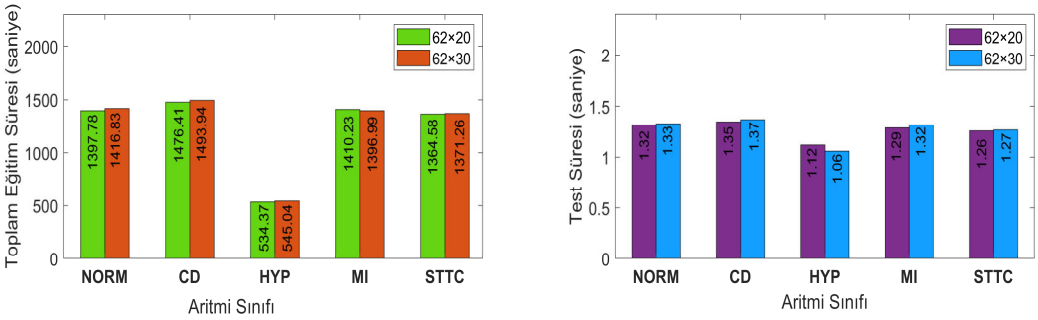

Şekil 7.12: FAY-OMY ile PTB-XL veri tabanından alınan tabanından alınan gürültülü ve gürültüsüz EKG verileri ile yapılan sınıflandırma işlemi için harcanan toplam eğitim ve test süreleri.

Önerilen yöntemde 62×20 boyutlarında öznitelik matrisi kullanıldığında NORM, CD, HYP, MI ve STTC aritmi türlerini tanımak için EKG işareti başına sırasıyla 1,32, 1,35, 1,12, 1,29 ve 1,26 saniyelik ortalama sürelere ihtiyaç duyulmuştur. Aritmi türlerinin 62×30 boyutlu öznitelik matrisiyle sınıflandırılması durumunda elde edilen ortalama süreler işaret başına sırasıyla 1,33, 1,37, 1,06, 1,32 ve 1,27 saniye olarak gerçekleşmiştir. Matris boyutunun artmasından dolayı işlem süresinde küçük artışlar olmuştur.

7.1.4 FAY-OMY Yöntemi İçin Ablasyon Çalışması

Önerilen FAY-OMY tabanlı sınıflandırıcı modelin aritmileri sınıflandırmadaki etkinliği, eğitim sürecinde kullanılan öznitelik matrisleri ile doğrudan etkilenir. Şimdiye kadar yapılan deneylerin tümünde kullanılan 62×20 ve 62×30 boyutlarındaki öznitelik matrisleri, Şekil 7.2'deki aşamalardan geçirilerek elde edilen eri matrislerine 2BTBA uygulanmasıyla oluşturulmuştur. Bu bölümde mevcut veri matrisi yapısına ek olarak üç adet farklı veri matrisi üzerine 2BTBA ile üretilmiş öznitelik matrislerinin sınıflandırma başarımına etkisi incelenmiştir. Bu amaçla, Bölüm 7.1'de tanımlanan alt veri matrislerini kullanarak Eşitlik (7.1)'de verilen dört veri matrisi oluşturulmuştur.

$$\mathbf{D}_1 = [-\ \mathbf{DM}_1\ -] \tag{7.1a}$$

$$\mathbf{D}_2 = \begin{bmatrix} -\ \mathbf{DM}_1\ - \\ -\ \mathbf{DM}_2\ - \end{bmatrix} \tag{7.1b}$$

$$\mathbf{D}_3 = \begin{bmatrix} -\ \mathbf{DM}_1\ - \\ -\ \mathbf{DM}_3\ - \end{bmatrix} \tag{7.1c}$$

$$\mathbf{D} = \begin{bmatrix} -\ \mathbf{DM}_1\ - \\ -\ \mathbf{DM}_2\ - \\ -\ \mathbf{DM}_3\ - \end{bmatrix} \tag{7.1d}$$

Aynı EKG işaretleri kullanarak elde edilen $\mathbf{D}_1$, $\mathbf{D}_2$, $\mathbf{D}_3$ ve **D** veri matrislerine d=10, 20, 30 ve 40 ile 2BTBA uygulanarak sırasıyla 60×d,61×d, 61×d ve 62×d boyutlarında öznitelik matrisleri elde edilmiştir. Farklı boyutlardaki öznitelik matrisleri, FAY-OMY tabanlı sınıflandırma modelinin hem eğitim hem de test aşamalarında kullanılarak modelin performansına yönelik değerlendirmeler, veri matrisleri ile öznitelik matrisi kombinasyonları temelinde gerçekleştirilmiş olup; Sen, F1-skoru ve GD metrikleri üzerinden analiz edilmiştir. Söz konusu değerlendirmelerin karşılaştırmalı sonuçları Tablo 7.10'da sunulmaktadır.

Tablo 7.10: MIT-BIH, Chapman ve PTB-XL veri tabanlarından temin edilen EKG kayıtları ile yapılan ablasyon çalışmaları

Veri Matrisi	d	MIT-BIH			Chapman-Gürültüsüz			Chapman-Gürültülü			PTB-XL		
		GD (%)	Sen (%)	F1-Skor (%)	GD (%)	Sen (%)	F1-Skor (%)	GD (%)	Sen (%)	F1-Skor (%)	GD (%)	Sen (%)	F1-Skor (%)
$\mathbf{D}_1$	10	0,78	16,67	NaN	37,54	42,76	36,01	30,17	38,05	27,64	0,72	20,00	NaN
	20	92,91	73,86	NaN	42,81	50,08	44,51	84,50	84,13	82,88	59,62	48,37	NaN
	30	91,41	76,10	71,80	62,97	68,19	64,56	85,27	84,29	83,47	39,11	40,64	NaN
	40	91,01	79,62	74,76	85,48	84,84	83,94	87,47	85,99	85,34	35,82	39,72	32,01
$\mathbf{D}_2$	10	0,78	16,67	NaN	27,34	33,09	27,34	29,57	36,91	25,80	0,72	20,00	NaN
	20	97,77	82,11	NaN	40,98	47,73	42,21	85,81	85,26	84,14	59,85	48,23	NaN
	30	98,60	83,49	83,44	75,70	78,72	75,33	84,23	83,05	82,16	39,37	40,68	NaN
	40	95,85	83,22	81,80	88,62	87,73	86,97	87,68	86,42	85,71	38,43	40,49	32,85
$\mathbf{D}_3$	10	0,78	16,67	NaN	28,47	30,85	28,13	24,36	30,53	22,60	0,72	20,00	NaN
	20	99,18	89,38	91,51	52,42	62,40	58,33	99,61	99,60	99,54	98,56	79,09	NaN
	30	99,64	94,65	96,39	98,15	98,59	98,11	96,10	95,28	95,07	70,88	63,27	55,57
	40	99,49	94,28	95,98	95,79	95,32	95,06	93,09	91,89	91,53	46,39	46,94	40,06
D	10	0,78	16,67	NaN	27,23	32,54	25,81	29,55	37,13	27,13	0,72	20,00	NaN
	20	99,73	96,80	97,84	60,66	68,25	66,11	99,71	99,73	99,67	98,72	79,36	NaN
	30	99,70	97,32	98,16	99,49	99,56	99,44	96,42	95,72	95,55	74,37	65,01	NaN
	40	99,71	96,96	97,96	97,44	97,04	96,96	93,74	92,72	92,40	52,15	50,43	43,37

Bu tabloya göre üç veri tabanından alınan EKG işaretleri ile yapılan çalışmalarda en iyi performans **D** veri matrisi yapısından türetilen öznitelikler ile elde edilmiştir. Her

üç veri tabanından alınan gürültülü işaretler ile yapılan çalışmalarda $d = 20$ boyut parametresine sahip öznitelik görüntüleri, tatmin edici performans sağlarken $d = 10$ ile sınıflandırma başarımı sağlanmamıştır. Chapman veri tabanına ilişkin kayıtlar üzerinden gerçekleştirilen sınıflandırma deneyinde, boyut parametresi 30'dan küçük olan öznitelik matrisleri ile sınıflandırma başarımları düşük kalmıştır. Chapman veri tabanında başarılı sonuçlar veren veri matrisi kombinasyonları, PTB-XL veri tabanı üzerinden gerçekleştirilen sınıflandırma çalışmalarında da oldukça iyi performans göstermiştir. Tablo 7.10'daki sonuçlara göre öznitelik matrisi boyutunun uzun süreli EKG işaretleri için önemli ancak kısa süreli EKG işaretleri için daha az önem arz ettiği görülmektedir.

7.2 KZFD-OMY Modelinde Kullanılan Veri Matrisinin Oluşturulması ve Öznitelik Matrisinin Elde Edilmesi

Önceki bölümde önerilen FAY-OMY yaklaşımı, yüksek sınıflandırma doğruluğu ile maksimum parametre bağımsızlığı gibi avantajlara sahip olmasına rağmen, uzun süreli işaretlerin FAY ile analiz edilmesi sürecindeki yüksek hesaplama maliyeti, bu yöntemin pratik uygulanabilirliğini kısıtlamaktadır. Bu nedenle yapılan çalışmanın bu bölümünde, EKG işaretlerinden kalp aritmilerinin hızlı ve doğru sınıflandırılması amacıyla ağırlıklı olarak KZFD tabanlı Z-F haritalarından türetilen öznitelik matrislerinin kullanıldığı OMY'ye dayalı sınıflandırma yaklaşımı önerilmiştir. KZFD-OMY olarak adlandırılan yöntemde sınıflandırıcı girişine boyutsal olarak indirgenmiş veri matrisleri, yani öznitelik matrisleri uygulanmaktadır. Bu doğrultuda her bir EKG işaretine ait veri matrisi, EKG işaretinin kendisi, Fourier dönüşümünün mutlak değerinin normalize edilmiş versiyonu ve KZFD ile elde edilen Z-F gösteriminin mutlak değerinin normalize edilmiş versiyonunu alt alta konumlandırarak oluşturulmuştur.

$$\mathbf{Y}_i^{(c)} = \begin{bmatrix} - & \mathbf{X}_i^{(c)}/max\left\{\mathbf{X}_i^{(c)}\right\} & - \\ - & \mathbf{d}_i^{(c)}/max\left\{\mathbf{d}_i^{(c)}\right\} & - \\ - & \mathbf{x}_i^{(c)} & - \end{bmatrix}, \tag{7.2}$$

Eşitlik (7.2)'deki $\mathbf{x}_i^{(c)}$, *c.* aritmi sınıfının *N* uzunluklu normalize edilmiş ve ortalamadan arındırılmış *i.* EKG işaretinin örneklerinden oluşan satır vektörü olup;

$\mathbf{d}_i^{(c)}$, N uzunluklu EKG aritmi sinyalinin AFD katsayılarının mutlak değerinden oluşan bir satır vektörünü temsil eder. $\mathbf{X}_i^{(c)}$ matrisi ise $\mathbf{x}_i^{(c)}$ vektörüne Eşitlik (5.14)'de tanımlanan KZFD uygulanarak elde edilen Z-F temsilinin mutlak değerini ifade eder. Veri matrisindeki alt matrislerin sıralaması başarımı etkilemez. KZFD-OMY kapsamında her bir aritmi sınıfının EKG işaretlerine Eşitlik (7.2)'deki işlem uygulanarak veri matrisleri elde edilir. İlgili aritmi sınıfındaki veri matrislerine 2BTBA uygulanarak her bir sınıf için tek bir projeksiyon matrisi ortaya çıkarılır. Herhangi bir aritmi sınıfına ait öznitelik matrisleri, ilgili sınıfın projeksiyon matrisinin o sınıfa ait veri matrisleriyle ayrı ayrı çarpılmasıyla elde edilir. EKG sinyallerinin öznitelik matrislerini oluşturmak için sınıflandırıcı modelin hem eğitim hem de test aşamalarında aynı projeksiyon matrislerinin kullanılmasına dikkat edilmelidir.

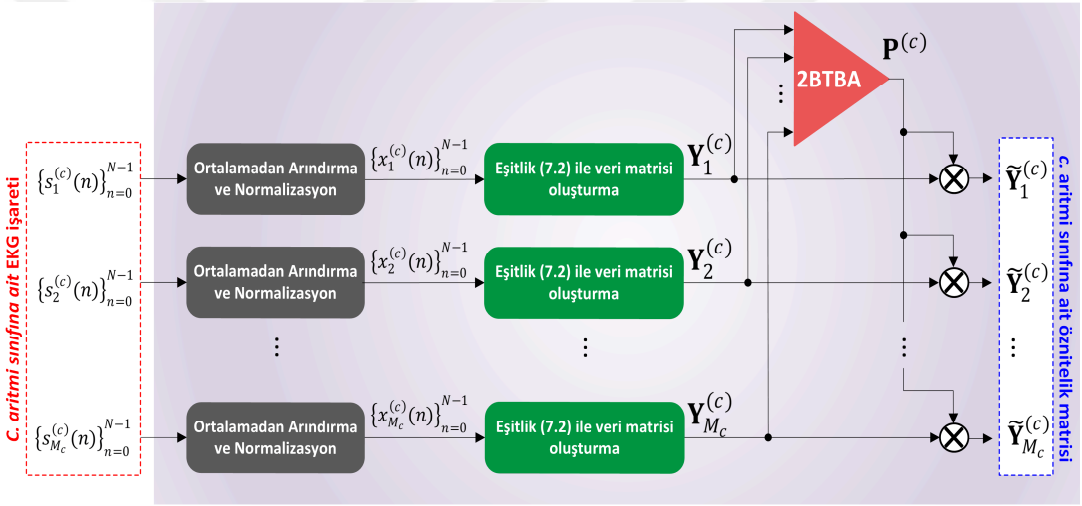

Şekil 7.13: KZFD-OMY yaklaşımında kullanılan öznitelik matrisi elde etme sürecinin blok şeması.

Önerilen KZFD-OMY kapsamında OMY tabanlı sınıflandırıcı girişine uygulanan öznitelik matrisi oluşturma sürecinin şematik gösterimi Şekil 7.13'te sunulmuş olup; performans değerlendirmesi genel kullanıma açık MIT-BIH, Chapman ve PTB-XL veri tabanlarından sağlanan birbirinden farklı aritmi türlerini içeren EKG işaretleri üzerinden gerçekleştirilmiştir (Moody ve Mark 2001, Zhang ve diğ. 2020, Wagner 2020). Simülasyonlar, 2.60 GHz hızında çalışan Intel Core i7-6700HQ CPU ve 16GB RAM'a sahip bir bilgisayar üzerinde gerçekleştirilmiştir. Veri tabanı üzerinden yapılan çalışmaların standart olması için MIT-BIH veri tabanıyla yapılan hasta-için senaryo koşulu bu bölümde atlanmıştır.

7.2.1 MIT-BIH Veri Tabanını Kullanarak Yapılan Performans Değerlendirmeleri

Önerilen KZFD-OMY yönteminin aritmi sınıflandırma performansını daha gerçekçi bir bakış açısıyla değerlendirmek için eğitim ve test kümelerinin tamamen farklı hastalardan toplanan EKG işaretleriyle oluşturulduğu hastalar-arası aritmi sınıflandırma paradigması benimsenmiştir (Xu ve Xiao 2023; Xia ve diğ. 2023). Bu doğrultuda, MIT-BIH veri tabanını oluşturan EKG kayıtları Tablo 7.11'de gösterildiği gibi DS1 ve DS2 olmak üzere iki farklı kümeye ayrılmıştır. DS1 kümesindeki kayıtlar R tepelerine göre segmentasyona tabi tutularak N sınıfı için 45811, V sınıfı için 3788, S sınıfı için 944 ve F sınıfı için 414 EKG örneği ait olmak üzere toplamda 50957 kalp atışı örneği elde edilmiştir. Benzer segmentasyon işlemi DS2 kümesindeki kayıtlar üzerinde gerçekleştirilerek, N sınıfına ait 44025 kalp atışı, V sınıfına ait 3220 kalp atışı, S sınıfına ait 1837 kalp atışı ve F sınıfı için 388 kalp atışı elde edilmiştir. Segmentasyon işlemi çerçevesinde R tepesinin sağından ve solundan 150'şer örnek alınarak oluşturulan 301 örnekli kalp atışı işaretlerine karşı düşen veri matrisleri, Eşitlik (7.2)'ye göre oluşturulmuştur. Z-F haritalarının elde edilmesinde kullanılan KZFD'nin pencere tipi Hanning, pencere uzunluğu 128 örnek ve örtüşme uzunluğu da 127 örnek olarak seçildiğinden 65×301 boyutlarında Z-F haritaları elde edilmiştir. Z-F temsillerine orijinal işaretin kendisi ve AFD katsayılarının eklenmesiyle 67×301 boyutlu veri matrisleri oluşturulmuştur. Veri matrisleri üzerine $d = 20$ ile 2BTBA işlemi uygulanarak içerikçe zengin 67×20 öznitelik matrisleri elde edilmiştir. KZFD-OMY kapsamında tüm sınıflandırma işlemleri 67×20 boyutlu öznitelik matrisleri üzerinden yürütülmüştür. KZFD-OMY tabanlı sınıflandırıcı model, DS1 veri kümesinde yer alan N, V, S ve F sınıflarından rastgele seçilen 100 EKG kaydı ile eğitilmiş ve DS2 veri kümesindeki kayıtlar üzerinden test edilerek doğrulanmıştır. FAY-OMY kapsamında yapılan çalışmalarda kullanılan R ve L sınıfına ait kayıtlar N sınıfında toplanmıştır.

Tablo 7.11: Hastalar-arası paradigma temelinde sınıflandırma başarımı için MIT-BIH veri tabanında kullanılan veri kümeleri

Veri Kümesi	N	S	V	F	Veri kayıtları
DS1	45811	944	3788	414	101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223, 230
DS2	44025	1837	3220	388	100, 103, 105, 111, 113,117, 121, 123, 200, 202, 210, 212, 213, 214,219, 221, 222, 228 231, 232, 233, 234

Hastalar-arası paradigma temelinde dört aritmi sınıfı için KZFD-OMY yöntemi ile elde edilen sınıflandırma sonuçlarına karşı düşen karışıklık matrisi Şekil 7.14'te verilmiş olup; bu matristen hesaplanan performans metrikleri Tablo 7.12'te gösterilmiştir. Önerilen KZFD-OMY tabanlı model, dört farklı aritmi türünü tespit etme konusunda yüksek performans sergilemiştir. N sınıfından 13 adet test örneği yanlış sınıfa atanırken diğer tüm örnekler doğru şekilde sınıflandırılmıştır.

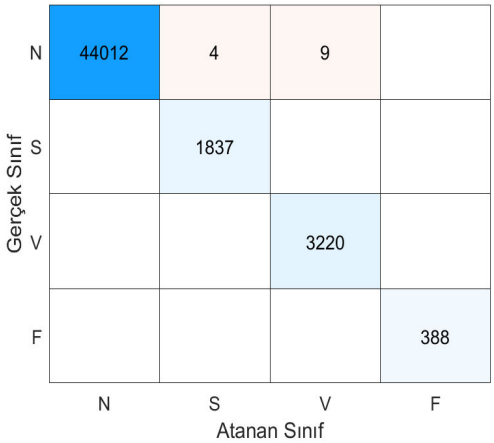

Şekil 7.14: KZFD-OMY sınıflandırma modelinin hastalar-arası sınıflandırma senaryosu altında eğitilmesi ve test edilmesi neticesinde elde edilen karışıklık matrisi.

Tablo 7.12'deki sonuçlara göre beş performans metriğinin hepsinde üstün bir sınıflandırma performansında ulaşılmış olduğu gözükmektedir. En düşük performans V sınıfındaki F1-Skor metriğinde %99,72 olarak elde edilmiştir. S ve V sınıfındaki aritmilerin tespiti, ani kalp durmasına neden olabilecek kalp ritmi bozukluklarının tanısında hayati öneme sahiptir. Tablo 7.12'de verilen sonuçlara göre önerilen yöntem bu gereksinimi karşılamaktadır.

Tablo 7.12: MIT-BIH veri tabanında hastalar-arası senaryosu altında KZFD-OMY yöntemi ile elde edilen sınıflandırma sonuçlarına karşı düşen karışıklık matrisinden hesaplanan performans metrikleri

Öznitelik Matrisi Boyutu	Sınıf	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
67×20	N	99,97	99,97	100,00	100,00	99,97
	S	99,99	100,00	99,99	99,78	
	V	99,98	100,00	99,98	99,72	
	F	100,00	100,00	100,00	100,00	

Ayrıca elde edilen sonuçlara göre KZFD-OMY yöntemi gerek performans metriği gerekse işlem süresi açısından Bölüm 7.2.4 içerisinde yapılan ve karşılaştırılan

yöntemleri geride bırakarak üstün bir performans sergilemiştir. Yapılan ölçümlere göre işaret başına N, S, V ve F aritmi türlerini tanımlamak için yaklaşık 3 milisaniyelik süreye ihtiyaç duyulmuştur.

7.2.2 Chapman Veri Tabanını Kullanılarak Yapılan Deneylerin Performans Değerlendirmeleri

KZFD-OMY yönteminin EKG aritmilerini sınıflandırmadaki genelleme yeteneğini göstermek amacıyla Chapman veri tabanından temin edilen gürültülü (ham) ve gürültüsüz EKG işaretleri üzerinden performans değerlendirmeleri yapılmıştır. Chapman veri tabanındaki tüm kayıtlar farklı bireylere ait olduğu için çalışmalarda hastalar-arası sınıflandırma senaryosu benimsenmiştir. Şekil 7.13'te gösterilen öznitelik matrisi elde etme işlemi SB, GSVT, AFIB ve SR aritmi sınıflarına ait 5000 örnek uzunluklu EKG işaretleri üzerinden gerçekleştirilmiştir. Eşitlik (7.2) kullanılarak her bir EKG işareti 67×5000 boyutlu veri matrislerine dönüştürülmüştür. Veri matrislerine 2BTBA uygulanarak 67×20 boyutlarında öznitelik matrisleri elde edilerek sınıflandırma işlemine geçilmiştir. Her bir aritmi sınıfının öznitelik matrislerini elde ederken kullanılan projeksiyon matrisleri, OMY tabanlı sınıflandırıcı modelin test aşamasındaki EKG işaretlerinin öznitelik matrislerini dönüştürmede kullanılmak üzere saklanmıştır.

7.2.2.1 Gürültülü EKG Kayıtlarıyla Yapılan Deneyler

KZFD-OMY tabanlı sınıflandırıcı model, Chapman veri tabanındaki SB, GSVT, AFIB ve SR sınıflarının her birinden rastgele alınan 500 gürültülü (ham) EKG işareti ile eğitilmiş ve geriye kalan gürültülü işaretler ile sınanmıştır. 67×20 boyutlu öznitelik matrislerinin ile elde edilen sınıflandırma sonuçları Şekil 7.15'te gösterilmiştir.

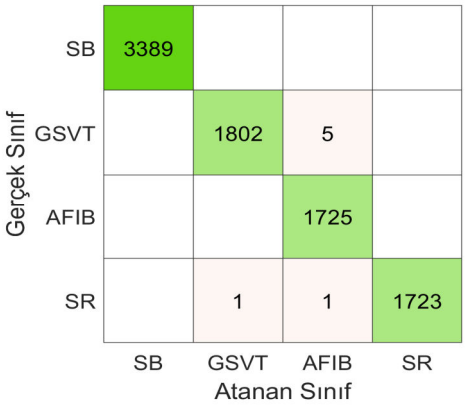

Şekil 7.15: Chapman veri tabanındaki gürültülü EKG işaretleri ile gerçekleştirilen sınıflandırma deneyleri sonrası elde edilen sonuçlar

Şekil 7.15'ten görüldüğü üzere önerilen yöntem tüm sınıflar için olağanüstü başarım sağlarken, 8646 EKG kaydından sadece 7'si yanlış sınıflandırılmıştır. SB ve AFIB sınıfıyla ilgili tüm kayıtlar doğru şekilde tanınmış, %99,92 genel doğruluk oranına ulaşılmıştır. Bu sonuçlar Tablo 7.13'te hesaplanan performans ölçütleriyle de tutarlıdır.

Tablo 7.13:Chapman veri tabanındaki gürültülü ve gürültüsüz EKG kayıtlarını kullanarak gerçekleştirilen sınıflandırmaya ilişkin performans metrikleri

	GÜRÜLTÜLÜ						GÜRÜLTÜSÜZ					
Boyut	Sınıf	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)	Sınıf	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	GD (%)
67×20	SB	100,00	100,00	100,00	100,00	99,92	SB	100,00	100,00	100,00	100,00	99,90
	GSVT	99,88	100,00	100,00	99,94		GSVT	99,94	100,00	100,00	99,97	
	AFIB	99,72	99,99	99,94	99,83		AFIB	99,55	100,00	100,00	99,77	
	SR	99,94	99,25	97,07	98,49		SR	100	98,82	95,51	97,71	

Gürültülü işaretlere ilişkin Sen, Spe, Pre ve F1-Skor metriklerinin ortalama değerleri SB, GSVT, AFIB ve SR aritmi sınıfları için sırasıyla %99,9, %99,97, %99,89 ve %99,9 olarak hesaplanmıştır. Bu sonuçlar Tablo 7.13'te hesaplanan performans ölçütleriyle de tutarlıdır.

7.2.2.2 Gürültüsüz EKG Kayıtlarıyla Yapılan Deneyler

Bu bölümde, KZFD-OMY tabanlı sınıflandırıcı model, Chapman veri tabanından SB, GSVT, AFIB ve SR aritmi sınıflarının her birinden rasgele seçilen 500 adet gürültüsüz EKG işareti ile eğitilmiş geriye kalan EKG işaretleri ile test edilmiştir. GSVT sınıfındaki 40 adet kayıt filtreleme işlemlerinde tüm değerleri silindiğinden dolayı veri tabanından çıkartılmıştır. Her bir aritmi sınıfı için eğitim kümesini oluşturulan EKG işaretleri Şekil 7.13'te verilen öznitelik matrisi oluşturma bloğundan geçirilerek 67×20 boyutunda öznitelik matrisleri elde edilmiştir. Sınıflandırma işlemine tabi tutulan öznitelik matrisleri ile elde edilen sonuçlar Şekil 7.16'da gösterilmiştir.

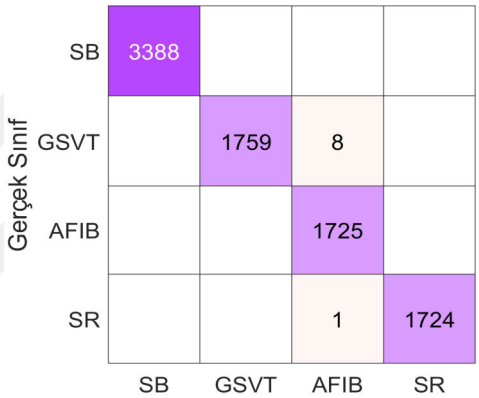

Şekil 7.16: Chapman veri tabanındaki gürültüsüz EKG işaretleri ile gerçekleştirilen sınıflandırma deneyleri sonrası elde edilen sonuçlar

Şekil 7.16'dan görüldüğü üzere, KZFD-OMY tabanlı model, yüksek düzeyde sınıflandırma performansı sergilemiştir. Toplamda 8606 EKG kaydından sadece 9'u yanlış sınıfa atanmış olup %99,90'lık genel doğruluk oranı elde edilmiştir. Tablo 7.13'teki performans ölçütlerine göre gürültüsüz EKG işaretleri için Sen, Spe, Pre ve F1-Skor metriklerinin ortalama değerleri SB, GSVT, AFIB ve SR aritmi sınıfları için sırasıyla %99,87, %99,96, %99,87 ve %99,87 olarak bulunmuştur. Gürültüsü giderilmiş EKG kayıtları kullanılarak yapılan sınıflandırmada, yanlış atamaların neredeyse tamamı GSVT sınıfında ortaya çıkmıştır. Ek olarak, SR sınıfından yalnızca bir kayıt hatalı sınıflandırılmıştır. Sonuç olarak, Tablo 7.13'te verilen beş performans metriği ve toplam doğruluk oranları, önerilen yöntemin gürültüye karşı dayanıklı olduğunu göstermektedir.

7.2.3 PTB-XL Veri Tabanını Kullanarak Yapılan Deneylerin Performans Değerlendirmeleri

KZFD-OMY yönteminin farklı EKG aritmi türlerini sınıflandırmadaki genelleme kapasitesi, PTB-XL veri tabanından elde edilen EKG sinyalleri üzerinden gerçekleştirilen deneyler aracılığıyla doğrulanmıştır. Bu kapsamda, PTB-XL veri tabanından elde edilen kayıtlar kullanılarak beş sınıflı örüntü tanıma problemi ele alınmıştır. Önerilen KZFD-OMY tabanlı sınıflandırıcı model, NORM, CD, MI, HYP ve STTC aritmi sınıflarının her birinden rasgele 500 EKG işareti seçilerek toplamda 2500 EKG işareti ile eğitilmiş, geriye kalan toplam 13744 EKG işareti ile test edilmiştir. Öznitelik görüntüsü çıkarma işlemi doğrudan NORM, CD, HYP, MI ve STTC sınıflarına ait 5000 örnek uzunluklu EKG işaretleri üzerinde Şekil 7.13 ile gösterilen süreç ile gerçekleştirilmiştir. Önerilen yöntemin başarım sonuçları Şekil 7.17'de ve performans metrikleri Tablo 7.14'te paylaşılmıştır. Elde edilen Sen, Spe, Pre ve F1-Skor metrikleri için ortalama değerler sırasıyla %99,96, %99,99, %99,25, %99,60 olarak bulunmuştur.

Tablo 7.14: PTB-XL veri tabanından sağlanan EKG işaretleri ile gerçekleştirilen sınıflandırma sürecine ilişkin performans metrikleri.

Öznitelik Boyutu	Sınıf	Sen (%)	Spe (%)	Pre (%)	F1-Skor (%)	TD (%)
67×20	NORM	99,99	100,00	100,00	99,99	99,97
	CD	100,00	99,98	99,83	99,92	
	HYP	100,00	99,99	97,22	98,59	
	MI	99,9	100,00	100,00	99,95	
	STTC	99,95	99,99	99,95	99,95	

Tablo 7.14'ten görüldüğü üzere performans metrikleri açısından en düşük oran HYP sınıfındaki Pre metriğinde ortaya çıkmıştır. Fakat elde edilen sonuçlar FAY-OMY yöntemiyle elde edilenlerden daha başarılıdır. Çünkü eğitim kümesinde oluşan sınıf dengesizliği problemi, KZFD-OMY yönteminde ortadan kalkmıştır.

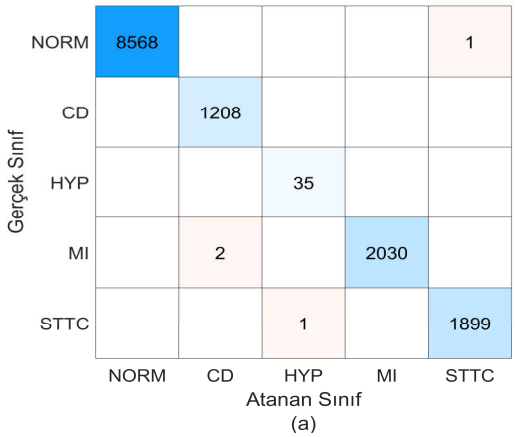

Şekil 7.17: PTB-XL veri tabanından sağlanan EKG işaretleri kullanılarak gerçekleştirilen sınıflandırma sürecine ilişkin karışıklık matrisi.

7.2.4 KZFD-OMY Yaklaşımın Diğer Yöntemler ile Karşılaştırılması

KZFD-OMY tabanlı aritmi sınıflandırma yönteminin aynı veri tabanı ve aritmi türlerini kullanan yöntemler ile genel doğruluk metriği üzerinden karşılaştırılmaları Tablo 7.15'te verilmiştir. Xu ve diğ. (2023) tarafından önerilen yöntemde, modelin eğitimi için toplamda 51013 kalp atışı kullanılmış, test süreci ise 49705 kalp atışı üzerinden değerlendirilmiştir. Söz konusu yöntem, MIT-BIH veri tabanından elde edilen veriler doğrultusunda dört farklı kalp atım türünü (N, V, S ve F) sınıflandırmak amacıyla uygulanmıştır. Elde edilen sonuçlara göre, geliştirilen model %96,15 oranında genek doğruluk sağlamıştır (Xu ve diğ. 2023). Jangra ve diğ. (2023) tarafından yapılan çalışmada, EKG sinyallerinin uzaysal ve spektral özelliklerini öğrenen bir evrişimli sinir ağı modeli önerilmiştir. Söz konusu model, dört farklı aritmi sınıfı üzerinde gerçekleştirilen deneysel değerlendirmeler kapsamında 69876 kalp atışından oluşan bir eğitim seti ile eğitilmiş ve 30713 kalp atışı içeren bir test kümesi ile değerlendirilmiştir. Bu çalışma sonucunda ilgili model, %98,86 genel sınıflandırma sağlamıştır (Jangra ve diğ. 2023). Xia ve diğ. (2023) tarafından gerçekleştirilen çalışmada, eğitim kümesindeki EKG işaret sayısı derin öğrenme ağları kullanılarak genişletilmiş ve aritmi türleri uzun kısa süreli bellek ağları ile sınıflandırılmıştır. Modelin eğitimi için 54469 EKG işareti, testi için ise 49661 EKG işareti kullanılmıştır. Yapılan deneyler sonucunda, dört farklı aritmi türünün sınıflandırılmasında %94,69 oranında toplam doğruluk oranı elde edilmiştir (Xia ve diğ. 2023). Ma ve diğ. (2023) tarafından geliştirilen çoklu-görünüm temsili öğrenme

Tablo 7.15: KZFD-OMY yönteminin başarımının genel karşılaştırılması

Veri Tabanı	Referans	Öznitelik Türetme Yöntemi	Sınıflandırıcı	Örnek Sayısı Eğitim/Test	GD (%)
MIT-BIH	Xu ve diğ. (2023)	Zaman-Bölgesi Öznitelikler, Morfolojik, istatistiksel, Spektral ve HBF dönüşümü tabanlı öznitelikler	ICC-WKELM	51013/49705	96,15
	Jang ve diğ. (2023)	Zaman-Bölgesi ve Spektral-Bölge Öznitelikleri	O-WCNN	69876/30713	98,86
	Xia ve diğ. (2023)	Çok katmanlı Conv1d + BİLSTM	Softmax	54469/49661	94,69
	Ma ve diğ. (2023)	Skalogram ve ESA'dan elde edilen dinamik ve morfolojik öznitelikler	Uzman bilgisi ve MMD'nin hastalar-arası adaptasyonu	-/-	97,27
	Zhou ve diğ. (2023)	MWCapsuleNets ağlardan üretilen öznitelikler	Seq2Seq Ağları	50935/49639	99,88
	Liu ve diğ. (2024)	Geçici uzaysal öznitelikler	Çift-Kanal SE-ResNet	50815/49507	96,60
	Zhou ve diğ. (2024)	Çok ölçekli evrişim modülü, Frekans evrişim dikkat bloğu ve RR aralığı karakteristikleri	MLP	66354/49661	95,60
	KZFD-OMY	**Veri matrisi + 2BTBA**	**OMY**	**400/49470**	**99,99**
Chapman	Shi ve diğ. (2024)	GCL ile VGGNet mimarisinden elde edilen öznitelikler	Doğrusal sınıflandırıcı	7147/2043	95,10
	Qiang ve diğ. (2024[a])	Her biri iki evrişimli katman, bir yoğun bağlantı katmanı ve bir dikkat modülünden oluşan, beş FEB'den gelen öznitelikler	MT-MVT-net	8492/1062	97,09
		Her biri iki evrişimli katman, bir yoğun bağlantı katmanı ve bir dikkat modülünden oluşan, beş FEB'den gelen öznitelikler	MT-DSVS-net	8492/1062	97,19
	Qiang ve diğ. (2024[b])	Evrişimsel yapıdan elde edilen geçici öznitelikler + RGNN'den elde edilen uzaysal öznitelikler	Conv-RGNN	8516/1065	98,08
	KZFD-OMY	**Veri matrisi + 2BTBA**	**OMY**	**2000/8646**	**99,65**
				2000/8605	**99,82**
PTB-XL	Shi ve diğ. (2024)	GCL ile VGGNet mimarisinden elde edilen öznitelikler	Doğrusal sınıflandırıcı	12978/1652	77,06
	Qiang ve diğ. (2024[b])	Evrişimsel yapıdan elde edilen geçici öznitelikler + RGNN'den elde edilen uzaysal öznitelikler	Conv-RGNN	17084/2158	88,18
	KZFD-OMY	**Veri matrisi + 2BTBA**	**OMY**	**2000/14244**	**99,92**

yöntemiyle çıkarılan öznitelikler, hastalar-arası adaptasyon mekanizması kullanılarak sınıflandırılmış ve bu yaklaşım ile %97,27 genel doğruluğa ulaşılmıştır (Ma ve diğ. 2023). Zhou ve diğ. (2023) EKG tabanlı aritmi örüntülerinin sınıflandırılması için hibrit bir derin öğrenme modeli önermiştir. Söz konusu çalışmada, çok katmanlı algılayıcı tabanlı ağırlık kapsül ağı (MLP-WCNet) ile çıkarılan öznitelikler, bir dizi-dizi (seq2seq) sınıflandırıcıya beslenmiş ve bu yaklaşım dört farklı aritmi sınıfının tanınmasında %99,88 gibi dikkat çekici bir sınıflandırma doğruluğu sağlamıştır. Liu ve diğ. (2024) geçici uzaysal öznitelikleri kullanan çift kanallı SE-ResNet sınıflandırıcı model önermiş olup; modelin eğitimi 50815 EKG örneği kullanılarak gerçekleştirilmiş ve 49507 kalp atışı üzerinde test edilmiştir. Dört farklı aritmi tipinin sınıflandırılmasında %96,60 oranında genel doğruluğa ulaşılmıştır (Liu ve diğ. 2024). Zhou ve diğ. (2024) tarafından gerçekleştirilen çalışmada, 66354 kalp atışı kullanılarak elde edilen öznitelikler ile çok katmanlı algılayıcı (MLP) sınıflandırıcısı eğitilmiştir. Modelin performansı, 49661 test örneği üzerinde değerlendirilerek olup dört aritmi tipinin sınıflandırılmasında %95,60 oranında genel doğruluk elde edilmiştir (Zhou ve diğ. 2024). Önerilen KZFD-OMY yöntem tüm yöntemi, tüm bu yöntemlerin başarımlarını geride bırakarak %99,99 genel doğruluk oranına ulaşmıştır.

Chapman veri tabanı üzerinden Shi ve diğ. (2024) tarafından gerçekleştirilen çalışmada, kendini denetleyen karşıt ve üretken öğrenme şemalarını harmanlayan bir model önerilmiştir. Modelin değerlendirilmesi Chapman veri tabanından elde edilen 12 kanallı EKG kayıtları kullanılarak gerçekleştirilmiştir. Eğitim sürecinde 7147 EKG işareti, test aşamasında ise 2043 EKG işareti kullanılmıştır. Dört aritmi tipinin sınıflandırılmasında %95,10 oranında toplam doğruluk oranı elde edilmiştir. Aynı model, PTB-XL veri tabanından elde edilen beş farklı aritmi sınıfına ait EKG işaretleri ile değerlendirilmiş ve %77,06'lık genel doğruluk oranına ulaşılmıştır. Modelin eğitim ve test süreçlerinde sırasıyla 12978 ve 1652 EKG işareti kullanılmıştır (Shi ve diğ.2024). Qiang ve diğ. (2024[a]) tarafından, miyokard enfarktüsünün tespiti ve lokalizasyonu için çoklu görevli tek görünüm ağı (MT-SVS-net) ve çoklu görevli çoklu görünüm ağı (MT-MVT-net) mimarilerinden oluşan birleşik bir derin öğrenme modeli önerilmiştir. MT-MVT-net'in gizli bilgisinin MT-SVS-net'e aktarılmasıyla daha hafif bir model olan damıtılmış öğrenci ağı (MT-DSVS-net) mimarisi geliştirilmiştir. Chapman veri seti kullanılarak gerçekleştirilen deneylerde, dört aritmi türünü ayırt etmede MT-MVT-net %97,09 ve MT-DSVS-net %97,19 genel doğruluk

oranı sergilemiştir (Qiang ve diğ. 2024[a]). Qiang ve diğ. (2024[b]) tarafından yapılan yakın zamanlı başka bir çalışmada, grafik sinir ağı (GNN) ve evrişimli sinir ağlarının birleştirilmesiyle elde edilen karma yapının üretmiş olfduğu uzaysal ve zamansal öznitelikler kullanılarak sınıflandırma performansı Chapman ve PTB-XL veri tabanları üzerinden değerlendirilmiştir. Chapman veri tabanında dört aritmi türünün sınıflandırılmasında %98,08 genel doğruluk oranı elde edilirken, PTB-XL veri tabanında beş aritmi sınıfının teşhisinde %88,18 genel doğruluk oranı sağlanmıştır. Eğitim ve test süreçlerinde Chapman veri tabanından, sırasıyla 8516 ve 1065 kayıt, PTB-XL veri tabanından ise 17084 ve 2158 kayıt kullanılmıştır. Önerilen KZFD-OMY tabanlı model gürültülü ve gürültüsüz işaretlerde sırasıyla %99,65 ve %99,82 toplam doğruluk oranı sağlarken, PTB-XL veri tabanıyla yapılan çalışmalarda %99,82 toplam doğruluk oranı ile diğer yöntemleri geride bırakmıştır.

7.2.5 KZFD-OMY Yöntemi ile Gerçekleştirilen Sınıflandırma Sürecinde Harcanan Sürenin Analizi

KZFD-OMY tabanlı aritmi sınıflandırma modelinin zaman gereksinimi hastalar-arası aritmi sınıflandırma senaryosu altında üç farklı veri tabanı kullanılarak test edilmiştir. Bu doğrultuda, okuyuculara tarafsız bir değerlendirme imkanı sunmak için, önerilen KZFD-OMY tabanlı sınıflandırma işleminde harcanan süre, Monte Carlo çapraz doğrulamaya (MCÇD) karşılık gelen beş bağımsız koşturma üzerinden değerlendirilmiştir. Harcanan süreye öznitelik çıkarma işlemi de dahil edilmiştir. Aritmetik ortalamaya dayalı elde edilen zaman gereksinimleri ile MCÇD sonuçlarını karakterize eden standart sapma (*std*) değerleri Tablo 7.16'da paylaşılmıştır. Burada eğitim süresi (saniye cinsinden) her bir veri tabanı için eğitim kümesini kullanarak sınıflandırıcı modeli eğitmek için gereken ortalama süreyi ifade ederken, test süresi (milisaniye cinsinden) ilgili veri tabanındaki her bir kaydı sınamak için gereken ortalama süreyi ifade etmektedir. Tablo 7.16'ya göre, önerilen yöntem MIT-BIH veri tabanını kullanarak diğerlerine kıyasla daha az eğitim ve test süresi gerektirdiğini göstermektedir. Bunun nedeni, sınıflandırma görevinde hem eğitim hem de test için daha kısa süreli EKG kayıtlarının kullanılması ve eğitim için daha az EKG örneğinden yararlanılmasıdır.

Tablo 7.16: KZFD-OMY yöntemi ile gerçekleştirilen sınıflandırma süreçlerinde harcanan süreler

Veri Tabanı	Eğitimde Kullanılan Örnek Sayısı	Eğitimde Harcanan *Ort*. Süre ve *Std*.	Testte Harcanan *Ort*. Süre ve *Std*
MIT-BIH	400	$1{,}08 \pm 3{,}03 \times 10^{-2}$	$3{,}49 \pm 5{,}21 \times 10^{-3}$
Chapman Gürültüsüz	2000	$353{,}34 \pm 1{,}84$	$25{,}02 \pm 2{,}24 \times 10^{-2}$
Chapman Gürültülü	2000	$351{,}50 \pm 1{,}50$	$24{,}63 \pm 2{,}47 \times 10^{-2}$
PTB-XL	2000	$351{,}56 \pm 2{,}34$	$24{,}43 \pm 2{,}03 \times 10^{-2}$

7.2.6 KZFD-OMY Yöntemi İçin Ablasyon Çalışması

Önerilen KZFD-OMY tabanlı sınıflandırıcı modelin aritmileri hızlı ve güvenilir şekilde sınıflandırmadaki başarımı KZFD'de kullanılan pencere özelliklerinden ziyade öznitelik matrisinin türetildiği veri matrisinin tasarımına bağlıdır. Bu durum göz önünde bulundurularak, önceki çalışmalarda kullanılan veri matrisini oluşturan alt matrislerin sınıflandırma performansına olan etkileri bu bölümde incelenmiştir. Bu bağlamda Eşitlik (7.3) ile üç farklı veri matrisi yapısı oluşturulup üzerlerine 2BTBA uygulayarak elde edilen 65×20, 66×20 ve 66×20 boyutlu öznitelik matrisleri ile sınıflandırma deneyleri gerçekleştirilmiştir. Tarafsız bir değerlendirme için, önceki deneyler ile aynı koşullar altında aynı veri kümeleri üzerinden eğitim ve test işlemleri gerçekleştirilmiştir. KZFD-OMY yönteminin sınıflandırma performansının değerlendirilmesi, Eşitlik (7.3)'ten elde edilen $\mathbf{DM}_1$, $\mathbf{DM}_2$ ve $\mathbf{DM}_3$ veri matrisleri ile Eşitlik (7.2)'ye karşı düşen **DM** veri matrisinin öznitelik matrisleri temelinde gerçekleştirilmiş olup, GD metriği üzerinden değerlendirilmiştir.

$$\mathbf{DM}_1^{(c)} = \begin{bmatrix} - & \mathbf{X}_i^{(c)}/max\left\{\mathbf{X}_i^{(c)}\right\} & - \end{bmatrix} \tag{7.3a}$$

$$\mathbf{DM}_2^{(c)} = \begin{bmatrix} - & \mathbf{X}_i^{(c)}/max\left\{\mathbf{X}_i^{(c)}\right\} & - \\ - & \mathbf{x}_i^{(c)} & - \end{bmatrix} \tag{7.3b}$$

$$\mathbf{DM}_3^{(c)} = \begin{bmatrix} - & \mathbf{X}_i^{(c)}/max\left\{\mathbf{X}_i^{(c)}\right\} & - \\ - & \mathbf{d}_i^{(c)}/max\left\{\mathbf{d}_i^{(c)}\right\} & - \end{bmatrix}, \tag{7.3c}$$

Söz konusu değerlendirmelerin karşılaştırmalı sonuçları Şekil 7.18'de görsel olarak sunulmuştur. Elde edilen sonuçlara göre KZFD-OMY tabanlı sınıflandırıcı model, uzun süreli EKG kayıtlarındaki aritmileri tespit etme söz konusu olduğunda, **DM** ve

DM$_3$ veri matrisleriyle oldukça iyi performans sergilemiştir. Kısa süreli EKG kayıtlarında ise dört veri matrisi yapısı ile birbirine oldukça yakın yüksek genel doğruluk oranlarına ulaşıldığı görülmektedir.

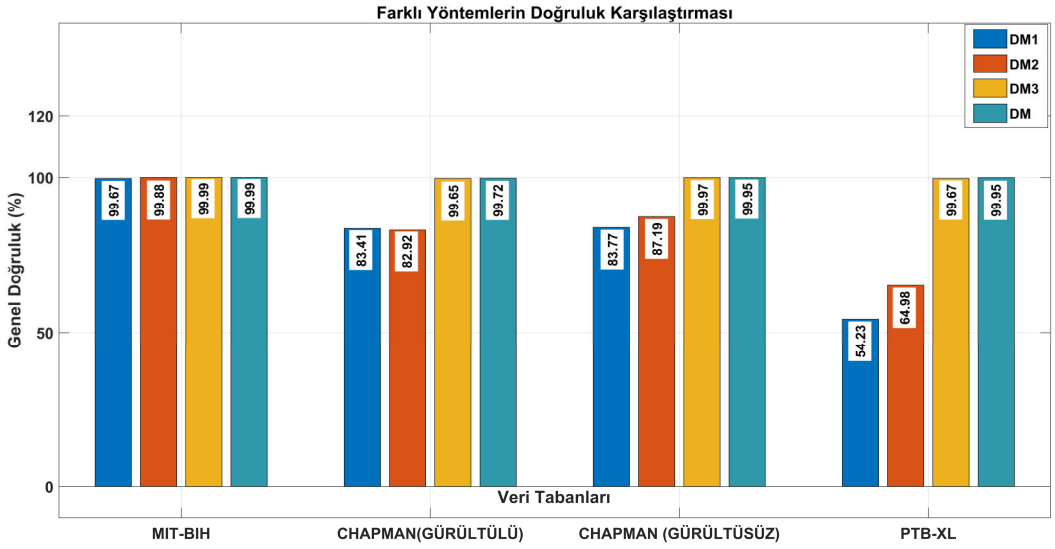

Şekil 7.18: Veri matrisini oluşturan matrislerin sınıflandırmaya etkisi.

8. TARTIŞMA

EKG işaretlerinden kalp aritmilerinin otomatik olarak sınıflandırılması amacıyla kullanıcı müdahalelerinden olabildiğince bağımsız yöntemlerin önerilmesi, bu çalışmanın ana fikrini oluşturmaktadır. Bu amaç doğrultusunda mevcut çalışmada, iki farklı yöntem önerilmiştir. FAY-OMY tabanlı aritmi sınıflandırma yönteminde Z-F gösterimlerinin elde edilmesinde FAY'dan yararlanılmıştır. FAY'ın tercih edilmesinin sebebi yüksek frekans çözünürlüğü vaat etmesi ve parametre gerektirmeyen veri güdümlü bir yöntem olmasıdır. Fakat FAY'ın hesapsal karmaşıklığı fazla olduğundan uzun süreli işaretler ve gürültülü işaretlerin Z-F temsillerinin elde edilmesi uzun zaman almaktadır. Yapılan çalışmalarda MIT-BIH veri tabanından sağlanan EKG işaretleri bölütlendiği için FAY ile analizleri kısa sürmüştür. Fakat Chapman ve PTB-XL veri tabanından alınan gürültülü işaretlerin FAY ile analizi gerçek zamanlı uygulamalarda kullanılamayacak kadar uzun sürmektedir.

KZFD-OMY tabanlı aritmi sınıflandırma yönteminde ise Z-F gösterimlerinin elde edilmesinde KZFD'den yararlanılmıştır. KZFD'nin tercih edilmesinin sebebi hesapsal karmaşıklığının az olması nedeniyle gerçek zamanlı uygulamalarda kullanılabilmesidir. KZFD ile uzun ve gürültülü işaretlerin Z-F temsilleri birkaç milisaniye içerisinde elde edilebilmektedir. Fakat, KZFD'nin en büyük eksikliği kullanıcı tarafından problem bazlı tanımlanması gereken üç adet parametreye sahip olmasıdır. Bunlar pencere uzunluğu, pencere tipi ve örtüşme miktarıdır. Pencere uzunluğu frekans çözünürlüğünü direk etkilediğinden sınıflandırma başarımını değiştirmektedir. Fakat üç veri tabanı üzerinden yapılan deneylerde KZFD parametrelerinin EKG işaretlerini sınıflandırmada etkisinin olmadığı görülmüştür. O neden gelecekte planlanan pratik uygulama çalışmalarında KZFD üzerinden devam edilmesi planlanmaktadır.

Yapılan çalışmada sınıflandırıcı olarak kullanılan OMY, EKG işaretlerini sınıflandırılmasındaki ilk girişimdir. Doğrusal sınıflandırıcı grubuna giren OMY, derin öğrenme yapılarının aksine kapalı matematiksel formül ile hesaplandığından kullanıcı tarafından belirlenen parametrelere ihtiyaç duymaz. Yetersiz sayıda veriye sahip veri kümelerinin sınıflandırılmasında hızlı ve doğru sonuçlar üretir. Derin

öğrenme ağlarının aksine, OMY tabanlı sınıflandırma modelinin yüksek miktarda veri ile eğitilmesi dezavantaj oluşturmaktadır. Çünkü ortak matris hesabında kullanılan fonksiyon sayısı arttığı zaman test safhasında sınama süresi uzamaktadır. OMY yönteminin bir başka dezavantajı eğitim kümesinin veri sayısı dengesizliğinden etkilenebiliyor olmasıdır. Fakat bu olumsuzluk eğitimde kullanılan veri sayısını minimuma çekerek aşılabilmektedir.

9. SONUÇ

Aritmilerin en erken aşamada doğru bir şekilde teşhis edilmesi, kardiyak rahatsızlıkların tanısı için çok önemlidir. Alınacak basit önlemler ile bireylerin hayata tutunması sağlanır. Bu amaçla yapılan çalışmada az sayıda EKG işareti kullanarak kardiyak aritmilerinin hızlı ve yüksek başarımla sınıflandırılması problemi ele alınmıştır. Bu probleme makul bir çözüm bulmak için farklı öznitelik türetme yaklaşımları ile OMY'ye dayalı sınıflandırıcı modelin birleştirilerek kullanılması önerilmiştir. Sınıflandırıcı modele girdi olarak uygulanan öznitelik matrisleri; EKG sinyallerinin zaman bölgesi, frekans bölgesi ve Z-F bölgesi gösterimlerinden oluşturulan veri matrislerine iki boyutlu temel bileşen analizi uygulanarak elde edilmiştir. Bu çerçevede, bir EKG işareti için veri matrisi, en büyük genliğine normalize edilmiş sıfır- ortalamalı EKG sinyalini ve bu sinyalin Fourier dönüşümünün mutlak değerini, en büyük genlik değerine normalize edilmiş Z-F gösterim matrisinin sonuna ekleyerek oluşturulmuştur. Ağırlıklı olarak öznitelik matrislerini oluşturan EKG verilerinin Z-F gösterimlerinin oluşturulmasında FAY ile KZFD yöntemleri kullanılmıştır. Veri matrisleri, iki farklı Z-F gösterim biçimi ile ayrı ayrı oluşturulduğundan dolayı EKG aritmi sınıflandırması amacıyla önerilen yöntemler FAY-OMY ve KZFD-OMY şeklinde iki farklı başlık altında sunulmuştur. Bu yöntemlerin etkinliği, halka açık MIT-BIH, Chapman ve PTB-XL veri tabanlarından sağlanan EKG işaretleri üzerinde gerçekleştirilen sınıflandırma deneyleriyle gösterilmiştir. MIT-BIH veri tabanı kullanılarak yapılan değerlendirmelerde, hasta-içi ve hastalar-arası sınıflandırma senaryoları altında altı aritmi türüne ilişkin EKG sinyallerinin sınıflandırılmasında FAY-OMY ile sırasıyla %99,87 ve %99,84 genel doğruluk oranlarına ulaşılmıştır. MIT-BIH veri tabanı kullanılarak KZFD-OMY yöntemiyle 4 sınıf üzerinden hastalar-arası senaryosu altında yapılan deneylerde %99,97 başarı oranı elde edilmiştir. Her iki yöntem ile V ve S tip aritmilerin teşhisinde neredeyse beş performans ölçütünde %99'u aşan oranlara ulaşılarak güncel çalışmaların çoğundan daha iyi sınıflandırma başarımı yakalamıştır. Önerilen yöntemlerin EKG sinyallerinde gürültü mevcudiyeti durumunda sınıflandırma performansını test etmek için Chapman veri tabanından sağlanan gürültülü ve gürültüsüz EKG sinyalleri üzerinden deneyler gerçekleştirilmiştir. Dört aritmi sınıfına ilişkin gürültülü ve gürültüsüz EKG kayıtları ile eğitilen ve test edilen FAY-OMY yöntemi ile sırasıyla %99,58 ve %99,05 genel sınıflandırma doğruluğuna ulaşılırken;

bu oranlar KZFD-OMY ile %99,92 ve %99,90 olarak elde edilmiştir. PTB-XL veri tabanından sağlanan EKG işaretlerine ait olduğu beş farklı aritmi türü üzerinde yapılan sınıflandırma deneylerinde, FAY-OMY ve KZFD-OMY yöntemleri sırasıyla %98,49 ve %99,97 genel doğruluk oranı ile sonuçlanmıştır. Başarım anlamında mükemmel sonuçlar veren KZFD-OMY yönteminin sınıflandırma işlemi süresi FAY-OMY'ye göre oldukça düşüktür. FAY-OMY yöntemiyle 301 örnekli EKG işaretlerinin sınıflandırılmasında minimum 18,55 milisaniye gerekirken, 5000 örnekli EKG işaretlerinin sınıflandırılmasında ortalama 1,73 saniyelik süreye ihtiyaç duyulmuştur. KZFD-OMY yönteminde ise 301 örnek uzunluklu işaretlerin sınıflandırılması 3,03 milisaniyede gerçekleşirken 5000 örnekten oluşan EKG'lerin sınıflandırılması minimum 16,80 milisaniyede gerçekleşmiştir. Elde edilen sonuçlar, önerilen yöntemlerin veri tabanından bağımsız olarak az sayıda eğitim verisi ile makul sürelerde zamanda yüksek sınıflandırma başarımı sergilediğini kanıtlamaktadır.

10. KAYNAKLAR

Acharya, U. R., Oh, S. L., Hagiwara, Y., Tan, J. H., Adam, M. Gertych, A. and San Tan, R., "A deep convolutional neural network model to classify heartbeats", *Computers in Biology and Medicine*, 89, 389–396, (2017).

Agrippina, S., Yusuf, A. and Hidayat, R. "Mfcc feature extraction and 192knn classification in ecg signals", *6th International Conference on Information Technology, Computer and Electrical Engineering (ICITACEE)*, 1–5, (2019).

Alarsan, F.I. and Younes, M., "Analysis and classification of heart diseases using heartbeat features and machine learning algorithms", *J Big Data*, 6, 81 (2019).

AlGhatrif M. and Lindsay, J., "A brief review: history to understand fundamentals of electrocardiography", *Journal of community hospital internal medicine perspectives*, 2(1), 14383, (2012).

Allam, J. P., Samantray, S. and Ari, S., "SpEC: A system for patient specific ECG beat classification using deep residual network", *Biocybern. Biomed. Eng*., 40, 4, 1446–1457, (2020).

Alqudah, A. M., Qazan, S., Al-Ebbini, L., Alquran, H. and Qasmieh, I. A., "ECG heartbeat arrhythmias classification: a comparison study between different types of spectrum representation and convolutional neural networks architectures", *J. Ambient Intell. Hum. Comput*., 13, 4877–4907, (2022).

Arif, M., Akram, M. U. and Minhas, F. U. A. A., "Pruned fuzzy k-nearest neighbor classifier for beat classification", *Journal of Biomedical Science and Engineering*, 3(04), 380, (2010).

Arora, N. and Mishra, B., "Origins of ECG and evolution of automated DSP techniques: A review", *IEEE Access*, 9, 140853–140880, (2021).

Atlee, J. L., Complications in Anesthesia E-Book. Amsterdam, The Netherlands: Elsevier, (2006).

Bajestani, M. N., Neshati, J. and Siadati, M. H., “Development of time-frequency analysis in electrochemical noise for detection of pitting corrosion”, *Corrosion*, 75, 2, 183–191, (2019).

Bechinia, H., Benmerzoug, D. and Khlifa, D., “Approach based lightweight custom convolutional neural network and fine-tuned mobileNet-V2 for ECG arrhythmia signals classification”, *IEEE Access*, 12, 40827–40841, (2024).

Berkaya, S. K., Uysal, A. K., Gunal, E. S., Ergin, S., Gunal, S. and Gulmezoglu, M. B., “A survey on ECG analysis”, *Biomed. Signal Process. Control*, 43, 216–235, (2018).

Beuter C. and Oleskovicz, M., “S-transform: from main concepts to some power quality applications”, *IET Signal Process*., 14, 3, 115–123, (2020).

Bi, S., Lu, R., Xu, Q. and Zhang, P., “Accurate arrhythmia classification with multi-branch multi-head attention temporal convolutional networks”, *Sensors*, 24, 8124, (2024).

Bing, P. P., Liu, Y., Liu, W., Zhou, J. and Zhu, L. M., “Electrocardiogram classification using TSST-based spectrogram and ConViT”, *Front. Cardiovasc. Med*., 9, 983543, (2022).

Bong, S. Z., Murugappan, M. and Yaacob, S., “Analysis of electrocardiogram (ecg) signals for human emotional stress classification”, *International Conference on Intelligent Robotics, Automation, and Manufacturing*, 198– 205, (2012).

Cinar A. and Tuncer, S. A., “Classification of normal sinus rhythm, abnormal arrhythmia and congestive heart failure ECG signals using LSTM and hybrid CNN-SVM deep neural networks”, *Comput. Methods Biomech. Biomed. Eng*., 24, 203–214, (2021).

Eltrass, A. S., Tayel, M. B. and Ammar, A. I. “A new automated CNN deep learning approach for identification of ECG congestive heart failure and arrhythmia using constant-Q non-stationary gabor transform”, *Biomed. Signal Process. Control*, 65, 102326, (2021).

Ergin, S., Cakir, S., Gerek, O. N. and Gülmezoglu, M.B., “A new implementation of common matrix approach using third-order tensors for face recognition”, *Expert Syst. Appl*.,38, 4, 3246–3251, (2011).

Ergin, S., Gerek, O. N., Gülmezoglu, M. B. and Barkana, A., “On the realization of common matrix classifier using covariance tensors”, *Digit. Signal Process*., 41, 110–117, (2015).

Fatimah, B., Singh, P., Singhal A., and Pachori, R. B., “Biometric identification from ECG signals using Fourier decomposition and machine learning”, *IEEE Trans. Instrum. Meas*., 71, 1–9, (2022).

Fatimah, B., Singh, P., Singhal, A. and Pachori, R. B., “Detection of apnea events from ECG segments using Fourier decomposition method”, *Biomed. Signal Process. Control*, 61, (2020).

Fatimah, B., Singh, P., Singhal, A. and Pachori, R. B., “Hand movement recognition from sEMG signals using Fourier decomposition method”, *Biocybern. Biomed. Eng*., 41, 2, 690–703, (2021).

Fatimah, B., Singh, P., Singhal, A., Pramanick, D., Pranav, S. and Pachori, R. B., “Efficient detection of myocardial infarction from single lead ECG signal”, *Biomed. Signal Process. Control*, 68, (2021).

Fatimah, B., Singhal, A. and Singh, P. “ECG arrhythmia detection in an inter-patient setting using Fourier decomposition and machine learning”, *Med. Eng. Phys*., 124, 104102, (2024).

Fukuta, H. and Little, W. C., “The cardiac cycle and the physiologic basis of left ventricular contraction, ejection, relaxation, and filling”, *Heart failure clinics*, 4(1), 1‑11, (2008).

Gargiulo, G.D., “True unipolar ECG machine for Wilson Central Terminal measurements”, *Biomed Res Int.* 2015, 586397, (2015).

Golgowski, M. and Osowski, S., “Anomaly detection in ECG using wavelet transformation”, *IEEE 21st International Conference on Computational Profozal,* (2020).

Gulmezoglu, M. B., Dzhafarov, V., and Barkana A., “The common vector approach and its relation to principal component analysis”, *IEEE Transactions on Speech and Audio Processing*, 9, 6, 655-662, (2001).

Gupta, V. and Mittal, M, “Arrhythmia detection in ecg signal using fractional wavelet transform with principal component analysis”, *Journal of The Institution of Engineers*, 101(5), 451‑461, (2020).

Hassan, S. U., Zahid, M. S. M., Abdullah, T. A. and Husain, K., “Classification of cardiac arrhythmia using a convolutional neural network and bi-directional long short-term memory”, *Digit. Health*., 8, 20552076221102766, (2022).

He, R., Wang, K., Zhao, N., Liu, Y., Yuan, Y. Li, Q. and Zhang, H., “Automatic detection of atrial fibrillation based on continuous wavelet transform and 2D convolutional neural networks”, *Front. Physiol*., 9, 1206, (2018).

He, R., Wang, K., Zhao, N., Liu, Y., Yuan, Y., Li, Q. and Zhang, H. “Automatic detection of atrial fibrillation based on continuous wavelet transform and 2D convolutional neural networks”, *Front. Physiol*., 9, 1206, (2018).

Huang, J. S., Chen, B. Q., Yao, B. and He, W. P. “ECG arrhythmia classification using STFT-based spectrogram and convolutional neural network”, *IEEE Access*, 7, 92871–92880, (2019).

Huang, J.-S.; Chen, B.; Yao, B. He,W., “ECG arrhythmia classification using STFT-based spectrogram and convolutional neural network”, *IEEE Access*, 7, 92871‑92880, (2019).

Huikuri H.V., Castellanos A. and Myerburg R.J., “Sudden death due to cardiac arrhythmias” *N Engl J Med*., 15, 345(20), 1473-82, (2001).

Ince T., Kiranyaz, S. and Gabbouj, M., “A generic and robust system for automated patient-specific classification of ecg signals”, *IEEE Transactions on Biomedical Engineering*, 56(5), 1415–1426, (2009).

Ingale, M., Cordeiro, R., Thentu, S., Park, Y., and Karimian, N., “Ecg biometric authentication: A comparative analysis”, *IEEE Access*, 8, 117853‑117866, (2020).

Isik S., and Ozkan, K., “Common matrix approach-based multispectral image fusion and its application to edge detection”, *J. Appl. Remote Sens.*, 13, 1, 1–17, (2019).

Islam, M. R., Qaraqe, M., Qaraqe, K. and Serpedin, E. “CAT-Net: convolution, attention, and transformer based network for single-lead ECG arrhythmia classification”, *Biomed. Signal Process. Control*, 93, 106211, (2024).

Jafari, M. A., “Comparative application of time-frequency methods on strong motion signals”, *Adv. Civil Eng*., 2021, 9933078, (2021).

Jangra, M., Dhull, S. K., Singh, K. K., Singh, A. and Cheng, X. C., “O-WCNN: an optimized integration of spatial and spectral feature map for arrhythmia classification”, *Complex Intell. Syst.*, 9, 3, 2685–2698, (2023).

Jeon, H., Jung, Y., Lee, S., and Jung, Y., “Area-Efficient Short-Time Fourier Transform Processor for Time–Frequency Analysis of Non-Stationary Signals”, *Applied Sciences*, 10(20), 7208, (2020).

Jeong D. U. and Lim K. M., “Convolutional neural network for classification of eight types of arrhythmia using 2D time-frequency feature map from standard 12-lead electrocardiogram”, *Sci. Rep*., 11,1, 20396, (2021).

K. Luo, J. Q. Li, Z. G. Wang, and Cuschieri, A. “Patient-specific deep architectural model for ECG classification”, *J. Healthcare Eng.*, 2017,4108720, (2017).

Kampouraki, A., Manis, G. and Nikou. C., “Heartbeat time series classification with support vector machines”, “IEEE transactions on information technology in biomedicine”, 13(4), 512–518, (2008).

Kim, Y. K., Lee, M., Song H. S., and Lee, S. -W., “Automatic Cardiac Arrhythmia Classification Using Residual Network Combined With Long Short-Term Memory”, *IEEE Transactions on Instrumentation and Measurement,* 71, 1-17, (2022).

Kizilkaya A., and Elbi, M. D., “A fast approach of implementing the Fourier decomposition method for nonlinear and non-stationary time series analysis”, *Signal Process*., 206,108916, (2023).

Klabunde., R.E., “Electrocardiogram (ekg, ecg), image for cardiovascular physiology concepts [online]”, (14 March,2025), https://cvphysiology.com/arrhythmias/a009 (2023).

Lai, D., Fan, X., Zhang, Y. and Chen, W. “Intelligent and efficient detection of life-threatening ventricular arrhythmias in short segments of surface ECG signals”, *IEEE Sensors J*., 21,13,14110–14120, (2021).

Lee, J. and Shin, M., “Using beat score maps with successive segmentation for ECG classification without R-peak detection”, *Biomed. Signal Process. Control*, 91, 105982, (2024).

Li, T. and Zhou, M. “ECG Classification Using Wavelet Packet Entropy and Random Forests”, *Entropy ,*18, 285, (2016).

Li, X., Zhang, J., Chen, W., Chen, Y., Zhang, C., Xiang, W. and Li, Dong., “Inter-patient automated arrhythmia classification: A new approach of weight capsule and sequence to sequence combination”, *Comput. Methods Programs Biomed*., 214, 106533, (2022).

Li, Y., Qian, R. and Li, K. “Inter-patient arrhythmia classification with improved deep residual convolutional neural network”, *Comput. Methods Programs Biomed.*,214, 106582, (2022).

Lilly L. S. and Braunwald, E., Braunwald’s Heart Disease: A Textbook of Cardiovascular Medicine, vol. 2. Amsterdam, The Netherlands: Elsevier, (2012).

Liu, J. L., Liu, Y., Jin, Y., Li, Z., Qia, C., Chen, X., Zhao, L. and Liu, C., "A novel diagnosis method combined dual-channel SE-ResNet with expert features for inter-patient heartbeat classification", *Med. Eng. Phys*., 130, 104209, (2024).

Martis, R. J., Acharya, U. R. and Min, L. C., "Ecg beat classification using pca, lda, ica and discrete wavelet transform", *Biomedical Signal Processing and Control*, 8(5),437–448, (2013).

Martis, R. J., Acharya, U. R., Mandana, K. M., Ray, A. K. and Chakraborty C., "Application of principal component analysis to ecg signals for automated diagnosis of cardiac health", *Expert Systems with Applications*, 39(14), 11792–11800, (2012).

McLaren, P. W., Vincent, R. and Willson, K., Clinical Echocardiography, Springer, (2020).

Mehla, V. K., Singhal, A. and Singh, P., "A novel approach for automated alcoholism detection using Fourier decomposition method", *J. Neurosci. Methods*, 346, (2020).

Mehla, V. K., Singhal, A., Singh, P., and Pachori, R. B., "An efficient method for identification of epileptic seizures from EEG signals using Fourier analysis", *Phys. Eng. Sci. Med*., 44, 2, 443–456, (2021).

Mert, A., Kilic, N. and Akan, A., "Ecg signal classification using ensemble decision tree", *J Trends Dev Mach Assoc Technol*, 16(1),179–182, (2012).

Mjahad, A., Rosado-Munoz, A., Bataller-Mompean, M., Frances-Víllora, J. V. and Guerrero-Martínez, J. F., "Ventricular fibrillation and tachycardia detection from surface ECG using time-frequency representation images as input dataset for machine learning", *Comput. Methods Programs Biomed.*, 141, 119–127, (2017).

Mohonta, S. C., Motin, M. A. and Kumar, D. K. "Electrocardiogram based arrhythmia classification using wavelet transform with deep learning model", *Sens. Bio-Sens. Res.*, 37,100502, (2022).

Moody G. A. and Mark, R. G., "The impact of the MIT-BIH arrhythmia database", *IEEE Eng. Med. Biol. Mag.*, 20, 3, 45–50, (2001).

Oliveira A. T. and Nobrega, E. G. O. “A novel arrhythmia classification method based on convolutional neural networks interpretation of electrocardiogram images”, *Proc. IEEE Int. Conf. Ind. Technol. (ICIT)*, 841–846, (2019).

Ozaltin, O. and Yeniay, O. “A novel proposed CNN-SVM architecture for ECG scalograms classification”, *Soft Comput*., 27, 8, 4639–4658, (2023).

P. Wagner et al., “PTB-XL, a large publicly available electrocardiography dataset”, *Sci. Data*, 7, 1, 154, (2020).

Parmar, K. S., Kumar, A. and Kalita, U., “ECG signal based automated hypertension detection using Fourier decomposition method and cosine modulated filter banks”, *Biomed. Signal Process. Control*, 76, (2022).

Paul, A., Das, A. K., Rakshit, M., Chowdhury, A. R., Saha, S., Roy, H., Sarkar, S., Prasanth, D. and Saicharan, E., “Development of automated cardiac arrhythmia detection methods using single channel ecg signal”, *arXiv preprint arXiv*, 2308.02405, (2023).

Peng X., Shu, W., Pan, C., Ke, Z., Zhu, H. and Zhou, X., “DSCSSA: A classification framework for spatiotemporal features extraction of arrhythmia based on the Seq2Seq model with attention mechanism”, *IEEE Trans. Instrum. Meas*., 71, 1–12, (2022).

Peng, H. Y., Chang, X. H., Yao, Z. J., Shi, D. L. and Chen, Y. R., “A deep learning framework for ECG denoising and classification”, *Biomed. Signal Process. Control*, 94, 106441, (2024).

Peterkova A., and Stremy, M., “The raw ecg signal processing and the detection ofqrs complex”, *IEEE European modelling symposium*, 80‑85, (2015).

Radhakrishnan, T., Karhade, J., Ghosh, S. K., Muduli, P. R., Tripathy, R. K. and Acharya, U. R., “AFCNNet: Automated detection of AF using chirplet transform and deep convolutional bidirectional long short term memory network with ECG signals”, *Comput. Biol. Med*., 137,104783, (2021).

Rahhal, M. M. A., Bazi, Y., Al Zuair, M., Othman, E. and BenJdira, B., “Convolutional neural networks for electrocardiogram classification”, *J. Med. Biol. Eng*., 38, 6, 1014–1025, (2018).

Raj, S., Ray, K. C. and Shankar, O., “Cardiac arrhythmia beat classification using dost and pso tuned svm”, *Computer Methods and Programsin Biomedicine*, 136, 163–177, (2016).

Rao, P. T., Rao, S. K., Manikanta, G. and Kumar, S. R., “Distinguishingnormal and abnormal ecg signal”, *Indian Journal of Science and Technology,* 9(10), 1‑5, (2016).

Rashed-Al-Mahfuz, M., Moni, M. A., Lio, P., Islam, S. M. S., Berkovsky, S., Khushi, M., Quinn, J. M. W. “Deep convolutional neural networks based ECG beats classification to diagnose cardiovascular conditions”, *Biomed Eng. Lett*., 11, 2, 147–162, (2021).

Reznichenko, S., Whitaker, J., Ni, Z. and Zhou, S., “Comparing ECG Lead Subsets for Heart Arrhythmia/ECG Pattern Classification: Convolutional Neural Networks and Random Forest”, *CJC Open*, 7, 2, 176-186, (2025).

Salem, M. Taheri, S. and Yuan, J. S. “ECG arrhythmia classification using transfer learning from 2-dimensional deep CNN features”, *Proc. IEEE Biomed. Circuits Syst. Conf. (BioCAS)*, 211–214, (2018).

Sattar Y.and Chhabra L., Electrocardiogram , StatPearls, (2019).

SCORE2 working group and ESC Cardiovascular risk collaboration, “SCORE2 risk prediction algorithms: new models to estimate 10-year risk of cardiovascular disease in Europe”, *Eur Heart J.*, 42(25), 2439-2454, (2021).

Shi, J., Liu, W., Zhang, H., Li, Z., Chang, S., Wang, H., He, J. nd Huang, Q., “Universal 12-lead ECG representation for signal denoising and cardiovascular disease detection by fusing generative and contrastive learning”, *Biomed. Signal Process. Control*, 94, 106253, (2024).

Singh, P., Joshi, S. D., Patney, R. K. and Saha, K., “The Fourier decomposition method for nonlinear and non-stationary time series analysis”, *Proc. R. Soc. A*, 473, 2199, 20160871, (2017).

Singh, P., Singhal, A. and Joshi, S. D., “Time-frequency analysis of gravitational waves”, *Proc. IEEE Int. Conf. Signal Process. Commun. (SPCOM)*, 197–201, (2018).

Strauss, D. G., Selvester, R. H., and Wagner, G. S., “Defining left bundle branch block in the era of cardiac resynchronization therapy”, *The American journal of cardiology*, 107(6), 927‑934, (2011).

Toma T. I. and Choi, S. “A comparative analysis of 2D deep CNN models for arrhythmia detection using STFT-based long duration ECG spectrogram”, *Proc. IEEE 13th Int. Conf. Ubiquitous, Future Networks (ICUFN)*, 483–488, (2022).

Tripathi, P. M., Kumar, A., Kumar, M. and Komaragiri, R., “Multilevel classification and detection of cardiac arrhythmias with high-resolution superlet transform and deep convolution neural network”, *IEEE Trans. Instrum. Meas*., 71, 1–13, (2022).

Tripathy, K., “Application of intrinsic band function technique for automated detection of sleep apnea using HRV and EDR signals”, *Biocybern. Biomed. Eng*., 38, 1, 136–144, (2018).

Turhal, U. C., Gülmezoglu, M. B. and Barkana, A. “Face recognition using common matrix approach”, *Proc. IEEE 13th Eur. Signal Process. Conf. (EUSIPCO 2005)*, 4-8, (2005).

Ullah, A., Anwar, S. M., Bilal, M. and Mehmood, R. M. “Classification of arrhythmia by using deep learning with 2-D ECG spectral image representation”, *Remote Sens*., 12,10, 1–14, (2020).

Venkatesan, C., Karthigaikumar, P. and Varatharajan, R. J. M. T., “A novel lms algorithm for ecg signal preprocessing and knn classifier based abnormality detection”, *Multimedia Tools and Applications*, 77(8), 10365–10374, (2018).

Wang, Y., Yang, G. C., Li, S. B., Li, Y., He, L., and Liu, D., "Arrhythmia classification algorithm based on multi-head self-attention mechanism", *Biomed. Signal Process. Control*, 79, 104206, (2023).

Wasimuddin, M., "Multiclass Ecg Signal Analysis Using Global average-Based 2-D Convolutional Neural Network Modeling", Ph.D Thesis, University of Bridgeport, Connecticut, (2023).

Wasimuddin, M., Elleithy, K., Abuzneid, A-S., Faezipour, M. and Abuzaghleh, O. "Stages-based ECG signal analysis from traditional signal processing to machine learning approaches: A survey", *IEEE Access*, 8, 177782–177803, (2020).

Wu, Z. Q., Lan, T. J., Yang, C. W. and Nie, Z. N. "A novel method to detect multiple arrhythmias based on time-frequency analysis and convolutional neural networks", *IEEE Access*, 7, 170820–170830, (2019).

Xia, Y. Wulan, N., Wang, K. Q. and Zhang, H. G., "Detecting atrial fibrillation by deep convolutional neural networks", *Comput. Biol. Med.*, 93, 84–92, (2018).

Xia, Y., Xiong, Y. Q., and Wang, K. Q., "A transformer model blended with CNN and denoising autoencoder for inter-patient ECG arrhythmia classification", *Biomed. Signal Process. Control*, 86, 105271, (2023).

Xia, Y., Xu, Y. Y., Chen, P., Zhang, J. and Zhang, Y. L., "Generative adversarial network with transformer generator for boosting ECG classification", *Biomed. Signal Process. Control*, 80, 104276, (2023).

Xie, Q. S., Tu, S. K., Wang, G. X., Lian, Y. and Xu, L., "Feature enrichment based convolutional neural network for heartbeat classification from electrocardiogram", *IEEE Access*, 7,153751–153760, (2019).

Xu, P. Y., Liu, H., Xie, X.Y., Zhou, S. W., Shu, M. L. and Wang, Y. L., "Interpatient ECG arrhythmia detection by residual attention CNN", *Comput. Math. Methods Med.*, 2022, 2323625, (2022).

Xu, S. S., Mak, M. and Cheung, C., “Towards end-to-end ECG classification with raw signal extraction and deep neural networks”, *IEEE J. Biomed. Health Inform.,* 23, 4, 574–1584, (2019).

Xu, S. Y., Zhang, F. and Xiao, W. D., “Inter-patient ECG classification with intra-class coherence based weighted kernel extreme learning machine”, *Expert Syst. Appl*., 227, 120095, (2023).

Xu, X. Y., Wei, S. S., Ma, C. Y., Luo, K., Zhang, L. and Liu, C. Y. “Atrial fibrillation beat identification using the combination of modified frequency slice wavelet transform and convolutional neural networks”, *J. Healthcare Eng*., 2018, 2102918, (2018).

Yang, J. and Liu, C., “Horizontal and vertical 2DPCA-Based discriminant analysis for face verification on a large-scale database”, *IEEE Trans. on Information Forensics and Security*, 2, 4, 781-792, (2007).

Yang, J. And Yan, R. “A multidimensional feature extraction and selection method for ECG arrhythmias classification”, *IEEE Sensors J.*, 21, 13, 14180–14190, (2021).

Yang, J., Zhang, D., Frangi, A. F. and Yang, J.-Y., “Two-dimensional PCA: a new approach to appearance-based face representation and recognition”, *IEEE Trans. Pattern Anal. Mach. Intell*., 26, 1, 131–137, (2004).

Yildirim, O., Talo, M., Ciaccio, E. J., Tan, R. S. and Acharya, U. R., “Accurate deep neural network model to detect cardiac arrhythmia on more than 10.000 individual subject ECG records”, *Comput. Methods Programs Biomed.*, vol. 197, 105740, (2020).

Zhang, J. W., Zhang, J. M., Danioko, S., Yao, H., Guo, H. Y. and Rakovski, C., “A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients”, *Sci. Data*, 7, 1, 48, (2020).

Zhang, L., Peng, Hu. and Yu, C., “An approach for ecg classification based on wavelet feature extraction and decision tree”, *International Conference on Wireless Communications & Signal Processing (WCSP)*, 1–4, (2010).

Zhang, Y. T., Li, J. Y., Wei, S. S., Zhou, F. Y., and Li, D. “Heartbeats classification using hybrid time-frequency analysis and transfer learning based on ResNet”, *IEEE J. Biomed. Health Inform*., 25, 11, 4175–4184, (2021).

Zhao, Y., Ren, J., Zhang, B., Wu, J. and Lyu, Y., “An explainable attention based TCN heartbeats classification model for arrhythmia detection”, *Biomed. Signal Process. Control*, 80, 104337, (2023).

Zhao, Z., Sarkka, S. and Rad, A.B., “Kalman-based spectro-temporal ECG analysis using deep convolutional networks for atrial fibrillation detection”, *J. Signal Process. Syst*., 92, 7, 621–636, (2020).

Zhou F. Y., and Fang, D. S., “Multimodal ECG heartbeat classification method based on a convolutional neural network embedded with FCA”, *Sci. Rep*., 14, 1, 8804, (2024).

Zhou F. Y., and Wang, J. N., “Heartbeat classification method combining multi-branch convolutional neural networks and transformer”, *Iscience*, 27, 3, 109307, (2024).

Zhou, F. Y., Sun, Y. H. and Wang, Y. W., “Inter-patient ECG arrhythmia heartbeat classification network based on multiscale convolution and FCBA”, *Biomed. Signal Process. Control*, 90, 105789, (2024).